



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Дальневосточный федеральный университет»
(ДВФУ)

**ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
(ШКОЛА)**

Департамент математического и компьютерного моделирования

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по образовательной программе подготовки бакалавров
по направлению 02.03.01 «Математика и компьютерные науки»
профиль « Сквозные цифровые технологии »

**Разработка модели прогнозирования страховых рисков в системе ОСАГО с
использованием гибридного подхода и телематических данных**

Работа защищена
с оценкой _____

Студент группы № Б9122-01.03.02мкт

(подпись) Винницкая Д.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

Регистрационный номер _____
« __ » _____ 20 __ г.

Руководитель _____
(должность, учёное звание)

(подпись) Кузнецов К.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

г. Владивосток

2026

Содержание

Аннотация	3
Введение	4
Термины, определения и сокращения	8
1 Анализ предметной области и существующих решений	11
1.1 Модели, используемые для расчета страховых тарифов	11
1.2 Методы машинного обучения в мировой практике страхования . .	12
1.3 Особенности российской практики страхования и система бонус-малус	14
1.4 Математическое обоснование необходимости применения методов машинного обучения	16
1.5 Методы машинного обучения в данной работе	18
1.6 Выводы по главе	20

АННОТАЦИЯ

Данная выпускная квалификационная работа посвящена разработке интеллектуальной системы прогнозирования страховых рисков и динамического расчета страховых тарифов в автостраховании на основе методов машинного обучения.

В ходе работы был проведен анализ традиционных методов, нацеленных на оценку рисков и обоснована необходимость перехода к вероятностной модели прогнозирования. В качестве основополагающего алгоритма был выбран CatBoost, который обеспечивает высокую точность в работе с категориальными признаками и гетерогенными данными. Разработана математическая модель бинарной классификации и формула динамического расчета коэффициента бонус-малус на основе предсказанной вероятности ДТП. Реализованы программные модули предобработки данных, обучения модели и расчета страхового тарифа с веб-интерфейсом, а тестирование модели метриками качества классификации подтвердило её предсказательную способность и чувствительность к ключевым факторам риска.

Разработанное решение может быть применено в сфере автострахования для внедрения персонализированного ценообразования, которое повысит точность оценки рисков и оптимизирует тарифную политику данной области.

ВВЕДЕНИЕ

В настоящее время, на фоне активной цифровизации и глобальной автоматизации финансовой отрасли и усиления конкурентной борьбы в сегменте автострахования, вопросы, касающиеся точного прогнозирования страховых рисков и научно обоснованного расчета тарифов, выходят на первый план, становясь определяющим фактором устойчивого развития и финансовой стабильности страховых организаций. В связи с ежегодным заключением договоров обязательного и добровольного страхования миллионами водителей, формируется постоянно растущий объем данных о страховых случаях, поведенческих факторах водителей, характеристиках транспортных средств, требующий детализированный, структурированный анализ для принятия взвешенных, обоснованных управленческих решений.

Формируется ряд фундаментальных проблем, вызванных тем, что существующие технологические решения в области актуарных расчетов в полной мере не удовлетворяют критериям и требованиям современного страхового рынка. Во-первых, наблюдается методологическая ограниченность традиционных подходов, а именно: страховые организации вынуждены использовать статические формулы с фиксированными коэффициентами, основанные на линейных зависимостях между признаками и уровнем риска. Такой процесс не учитывает нелинейный характер реальных взаимосвязей и приводит к искажению прогнозов, особенно при работе со сложными, неоднозначными профилями клиентов.

Во-вторых, традиционные бонус-малус системы и регрессионные модели не учитывают корреляцию между факторами риска, что приводит к упрощённой оценке и значительному снижению точности тарифов. Не менее важные данные, такие как стиль вождения, погодные условия, плотность трафика в населенном пункте и технические характеристики автомобиля, обычно не используются в полной мере, что ограничивает возможность персонализированной, точной оценки риска.

В-третьих, существующие методы не обладают способностью к динамической адаптации, а именно тарифы: пересматриваются редко и носят сугубо статичный характер, что, в свою очередь, не позволяет адаптироваться к изменяющимся поведенческим характеристикам водителя. Динамика улучшения или, наоборот, ухудшения стиля вождения не отражается на тарифе до следующего отчетного периода, а новые риски, связанные с изменениями в инфраструктуре или автомо-

бильных технологиях, учитываются с существенной, значимой задержкой. Таким образом, на данный момент на рынке отсутствует универсальная, адаптивная и технологически

Указанные обстоятельства обуславливают актуальность реализации модульной программной системы, которая обеспечивает полный цикл обработки страховых данных, используя алгоритмы градиентного бустинга и поддерживая идею персонализированного расчета тарифа.

Проблематика прогнозирования страховых рисков исследуется в работах как зарубежных, так и отечественных деятелей науки. Весомый вклад в развитие методов актуарного анализа внесли фундаментальные исследования в области теории риска, математической теории страхования и основ страховой математики. Современные подходы к оценке финансовых рисков рассмотрены в ряде работ, посвящённых моделированию неопределённости и управлению рисками в страховой сфере. Особое внимание в последние годы уделяется применению алгоритмов машинного обучения, в частности методов градиентного бустинга, таких как CatBoost, которые демонстрируют высокую эффективность при работе с гетерогенными данными, содержащими как числовые, так и категориальные признаки. В то же время вопросы проектирования интегрированных систем машинного обучения для автострахования, объединяющих алгоритмы классификации с механизмами динамического ценообразования и ориентированных на практическое внедрение в российские страховые компании, остаются недостаточно проработанными.

Цель работы — реализация интеллектуальной системы прогнозирования страховых рисков и расчета страхового тарифа в автостраховании на основе машинного обучения.

Для достижения поставленной цели необходимо решить комплекс взаимосвязанных **задач**:

1. провести анализ традиционных актуарных методов и систем бонус-малус для выявления их ограничений;
2. исследовать эффективность алгоритмов классификации и обосновать выбора модели CatBoost;
3. разработать методику предварительной обработки входных данных, включающую очистку выбросов, нормализацию числовых признаков и автоматическое кодирование категориальных переменных;

4. реализовать алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между возрастом водителя, стажем вождения и историей страховых обращений;
5. разработать программный модуль динамического расчета страхового тарифа, трансформирующий предсказанную вероятность риска в финансовый показатель с использованием коэффициента чувствительности;
6. разработать веб-интерфейс на базе Flask для взаимодействия с пользователем, обеспечивающий ввод параметров водителя и транспортного средства через форму и загрузку файлов;
7. разработать программный конвейер обработки данных, объединяющий этапы предобработки, загрузки обученной модели и получения прогноза в единый автоматизированный процесс;
8. оценить качества модели с использованием метрик accuracy, precision, recall и F1-меры.

Объектом исследования является процесс управления страховыми рисками в сфере автострахования.

Предметом исследования выступают математические методы и алгоритмы машинного обучения, направленные на прогнозирование вероятности наступления страховых случаев и расчет персонализированных страховых тарифов.

Методы исследования. В работе используются методы математической статистики и теории вероятностей для анализа данных и оценки рисков, алгоритмы машинного обучения с учителем, в частности градиентный бустинг на базе CatBoost, методы разведочного анализа данных для выявления корреляции между признаками, методы кросс-валидации для оценки обобщающей способности модели, метрики качества классификации для сравнительного анализа, а также методы визуализации данных для интерпретации результатов моделирования.

Практическая значимость работы определяется возможностью применения разработанной модели в реальных страховых компаниях для повышения точности оценки рисков, оптимизации тарифной политики и внедрения персонализированных страховых продуктов. Интеграция интеллектуальной системы прогнозирования позволит страховым компаниям сократить количество необоснованных выплат, повысить точность оценки профилей клиентов и усилить доверие

к страховой системе за счет более прозрачного, чуткого и справедливого ценообразования.

Структура работы. Выпускная квалификационная работа состоит из введения, трёх глав, заключения, списка литературы и приложений.

В первой главе проводится анализ предметной области автострахования: формализуется задача прогнозирования страховых рисков, выполняется обзор традиционных актуарных методов, систем бонус-малус и современных подходов на основе машинного обучения [prokhorenkova2018catboost], а также сравнительный анализ существующих программных решений. По результатам анализа обосновывается выбор алгоритма CatBoost для решения задачи бинарной классификации и формулируются требования к разрабатываемой системе.

Во второй главе описывается разработка прогнозной модели: этапы подготовки и предобработки данных, архитектурная структура модели, процесс обучения классификатора, тестирование метриками качества (accuracy, precision, recall, F1), а также реализация веб-интерфейса для динамического расчета страховых тарифов на основе предсказанной вероятности ДТП.

В третьей главе представлены перспективы внедрения системы: рассмотрены организационные и технические аспекты интеграции модели в практику страховых компаний, регуляторные требования Центрального банка РФ, возможности масштабирования и расширения признаков (телематические данные), а также оценка потенциального экономического эффекта от внедрения интеллектуального ценообразования.

ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ

Термины и определения

Актuariальные модели — это математические и статистические инструменты, используемые для оценки рисков, прогнозирования финансовых последствий неопределённостей, а также для расчёта страховых взносов, управления активами и обязательствами в различных сферах, прежде всего в страховании.

Бонус-малус система (БМС) — механизм индивидуализации страхового тарифа на основе страховой истории клиента, предусматривающий применение скидок (бонусов) за безаварийную езду и надбавок (малусов) за наличие страховых выплат; в работе рассматривается как традиционный метод, подлежащий оптимизации средствами машинного обучения.

Градиентный бустинг (Gradient Boosting) — ансамблевый алгоритм машинного обучения, основанный на последовательном построении композиции моделей, где каждая следующая модель обучается минимизировать ошибки предыдущих; в работе используется как основной метод прогнозирования вероятности ДТП.

Страховой риск — предполагаемое событие, обладающее признаками вероятности и случайности, при наступлении которого возникает обязательство страховщика произвести страховую выплату; в контексте работы: вероятность наступления дорожно-транспортного происшествия (ДТП).

Страховой тариф — цена страхового риска, выраженная в денежной сумме, относящаяся к единице страховой суммы или процентной доле от нее; в работе рассчитывается на основе прогнозной вероятности ДТП, полученной моделью машинного обучения.

Телематическое страхование (Usage-Based Insurance, UBI) — вид страхования, при котором страховой тариф формируется на основе данных о реальном поведении водителя (скорость, пробег, стиль вождения), фиксируемых специальными устройствами; рассматривается в работе как перспективное направление расширения признаков модели.

Переобучение (Overfitting) — ситуация в машинном обучении, при которой модель чрезмерно точно воспроизводит закономерности обучающей выборки, включая шум и выбросы, что приводит к снижению качества предсказаний на новых данных; для предотвращения используется метод Ordered Boosting в алго-

ритме CatBoost.

Важность признаков (Feature Importance) — метрика, оценивающая вклад каждого входного параметра в прогноз модели машинного обучения; используется в работе для интерпретации результатов и выявления ключевых факторов риска.

Метрики классификации — количественные показатели качества работы модели бинарной классификации; в работе используются Accuracy (точность), Precision (точность положительного класса), Recall (полнота), F1-score (гармоническое среднее) и ROC-AUC (площадь под ROC-кривой).

Конвейер обработки данных (Data Pipeline) — последовательность этапов обработки информации, включающая в себя сбор, очистку, нормализацию данных, обучение модели и получение прогноза; в работе реализован в виде программного класса InsuranceRiskModel.

Целевая переменная (Target) — бинарный индикатор факта дорожно-транспортного происшествия, соответствующий значению 1 при наличии страхового случая и 0 при его отсутствии; является объектом прогнозирования в задаче классификации.

Категориальный признак — переменная, которая принимает дискретный набор значений (например, тип автомобиля, регион, погодные условия); в работе обрабатывается алгоритмом CatBoost без предварительного кодирования.

Базовая ставка тарифа — минимальная стоимость страхового полиса, устанавливаемая страховой компанией для низкорисковых клиентов; служит основой для динамического расчета итогового тарифа.

Коэффициент чувствительности к риску — параметр, отвечающий за степень влияния прогнозируемой вероятности ДТП на итоговую стоимость страхового полиса; регулируется экспертно в зависимости от бизнес-политики страховщика.

Перечень сокращений

ОСАГО	Обязательное страхование гражданской ответственности владельцев транспортных средств
КАСКО	Комплексное автострахование, кроме ответственности (добровольное страхование транспортного средства от ущерба и угона)
ДТП	Дорожно-транспортное происшествие
ПДД	Правила дорожного движения
ЦБ РФ	Центральный банк Российской Федерации (регулятор страхового рынка)
ФАС	Федеральная антимонопольная служба
МЛ / ML	Machine Learning — машинное обучение
ИИ / AI	Artificial Intelligence — искусственный интеллект
EDA	Exploratory Data Analysis — разведочный анализ данных
CatBoost	Categorical Boosting — алгоритм градиентного бустинга
XGBoost	eXtreme Gradient Boosting — алгоритм градиентного бустинга
LightGBM	Light Gradient Boosting Machine — алгоритм градиентного бустинга
ROC-AUC	Receiver Operating Characteristic – Area Under Curve
F1-score	Гармоническое среднее между Precision и Recall
Precision	Доля правильно предсказанных положительных случаев
Recall	Доля правильно предсказанных случаев среди всех истинных
Accuracy	Доля правильно классифицированных объектов
UBI	Usage-Based Insurance — телематическое страхование
GAP	Guaranteed Asset Protection — страхование разницы стоимости
API	Application Programming Interface — программный интерфейс
CPU	Central Processing Unit — центральный процессор
GPU	Graphics Processing Unit — графический процессор
JSON	JavaScript Object Notation — формат обмена данными

1 Анализ предметной области и существующих решений

1.1 Модели, используемые для расчета страховых тарифов

В современных условиях автострахования выделяют несколько основополагающих подходов, применяемых для расчета страховых тарифов, каждый из которых основывается на специфических математических моделях оценки риска.

Традиционная модель ОСАГО применяет мультипликативную формулу:

$$O_{\text{ОСАГО}} = T_{\text{баз}} \times \prod K_i, \quad (1)$$

где итоговая стоимость определяется произведением базовой ставки на набор фиксированных коэффициентов, что создает ограничения из-за предположения о линейной независимости факторов риска.

Модели КАСКО, в свою очередь, оперируют аддитивным принципом расчета ожидаемых убытков, выражаемым формулой:

$$S_{\text{КАСКО}} = P_{\text{ДТП}} \times C_{\text{ремонт}} + P_{\text{угон}} \times C_{\text{выпл}} + C_{\text{админ}}, \quad (2)$$

где вероятность наступления страхового случая оценивается с помощью алгоритмов классификации, таких как логистическая регрессия:

$$P(y = 1) = \frac{1}{1 + e^{-z}} \quad (3)$$

или градиентный бустинг.

Наиболее прогрессивным направлением является телематическое страхование (Usage-Based Insurance, UBI), применяющее динамическую формулу:

$$S_{\text{UBI}} = T_{\text{баз}} \times K_{\text{пробег}} \times K_{\text{стиль}} \times K_{\text{время}}, \quad (4)$$

которая позволяет в реальном времени подстраивать тариф под фактическое поведение водителя, фиксируемое датчиками.

Тем не менее, широкое применение телематических моделей ограничено потребностью в масштабных массивах данных и необходимостью оснащения автомобилей специализированным оборудованием, в то время как алгоритмы машинного обучения в рамках КАСКО уже продемонстрировали высокую результативность при обнаружении скрытых нелинейных взаимосвязей между параметрами.

1.2 Методы машинного обучения в мировой практике страхования

В международной практике страхования наблюдается устойчивая тенденция к применению различных алгоритмов машинного обучения, предназначенных для решения задач прогнозирования рисков, каждый из которых имеет свою математическую основу и специфическую область практического применения.

Ансамблевые методы на основе деревьев решений, в частности алгоритм Random Forest, характеризуются высокой устойчивостью к переобучению и способностью выявлять нелинейные закономерности в данных. Математическая формализация модели случайного леса представляет собой ансамбль из M решающих деревьев, где итоговый прогноз формируется посредством усреднения предсказаний отдельных деревьев:

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x) \quad (5)$$

где $T_m(x)$ — прогноз m -го дерева для входного вектора признаков x . Для задач бинарной классификации применяется голосование большинством:

$$\hat{y} = \operatorname{argmax}_k \sum_{m=1}^M \mathbb{I}(T_m(x) = k) \quad (6)$$

Данный подход обеспечивает снижение дисперсии модели за счёт декорреляции отдельных деревьев через бутстрэппинг и случайный выбор признаков.

Алгоритмы градиентного бустинга, такие как XGBoost и LightGBM, проявили себя как эффективные инструменты, подходящие для задач бинарной классификации, обеспечивая, в свою очередь, высокую точность предсказаний при работе с табличными данными. Принцип работы основывается на поэтапном построении ансамбля деревьев, в котором каждое новое дерево обучается минимизировать остатки предыдущих:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x) \quad (7)$$

где $F_t(x)$ — прогноз на шаге t , η — скорость обучения, $h_t(x)$ — новое дерево, обученное на градиентах функции потерь. XGBoost использует регуляризованный обьектив:

$$\mathcal{L} = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (8)$$

где $\Omega(f_k)$ — штраф за сложность дерева, который предотвращает переобучение.

Архитектуры глубокого обучения и искусственные нейронные сети эффективно применяются для решения задач высокой сложности, требующих обработки неструктурированных данных. В частности, данные методы используются в области компьютерного зрения для автоматизированной оценки ущерба транспортных средств после дорожно-транспортных происшествий, а также в задачах обработки естественного языка для семантического анализа текстовой документации страховых заявлений. Архитектуры глубокого обучения обеспечивают аппроксимацию высокосложных нелинейных зависимостей в высокоразмерных пространствах признаков посредством иерархической композиции нелинейных преобразований:

$$a^{[l]} = \sigma(W^{[l]}a^{[l-1]} + b^{[l]}) \quad (9)$$

где $a^{[l]}$ — активации l -го слоя, $W^{[l]}$ — матрица весов, $b^{[l]}$ — вектор смещений, σ — функция активации. Тем не менее такие модели требуют значительных вычислительных ресурсов и больших размеченных выборок для обучения.

Методы кластеризации, такие как K-means и DBSCAN, используются для сегментации клиентов по уровню риска, что позволяет страховым компаниям разрабатывать дифференцированные тарифные планы. Алгоритм K-means минимизирует внутрикластерную дисперсию:

$$J = \sum_{j=1}^K \sum_{i=1}^N \mathbb{I}(x_i \in C_j) \|x_i - \mu_j\|^2 \quad (10)$$

где μ_j — центроид кластера C_j . Методы снижения размерности, включая РСА, применяются для визуализации многомерных данных и ускорения обучения моделей. Метод главных компонент (РСА) находит ортогональные направления максимальной дисперсии:

$$\max_w w^T \Sigma w \quad \text{при условии} \quad \|w\| = 1 \quad (11)$$

где Σ — ковариационная матрица признаков.

В области телематического страхования повсеместно применяются методы обучения с подкреплением для задач динамического ценообразования, в которых модель обучается выбирать оптимальные тарифы, получая обратную связь от системы. Данный процесс формализуется через марковский процесс принятия решений (MDP), в котором агент максимизирует ожидаемую награду:

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (12)$$

где π — политика выбора действий, R — функция награды, γ — коэффициент дисконтирования.

Современные исследования также демонстрируют хорошие показатели эффективности внедрения ансамблевых методов, которые комбинируют несколько алгоритмов в целях повышения точности прогнозов. Стекинг объединяет предсказания базовых моделей через мета-обучение:

$$\hat{y} = g(h_1(x), h_2(x), \dots, h_k(x)) \quad (13)$$

где g — мета-модель, обученная на выходах базовых алгоритмов h_i . Данный подход предоставляет возможность компенсировать индивидуальные слабости отдельных моделей и достигать более стабильных результатов, что подтверждает целесообразность использования интеллектуальных алгоритмов в современном страховании.

1.3 Особенности российской практики страхования и система бонус-малус

Российскому рынку автострахования характерна высокая доля обязательного страхования гражданской ответственности, где тарифное регулирование осуществляется государством в лице Центрального банка Российской Федерации.

Ключевым компонентом индивидуализации стоимости полиса в российской практике является система бонус-малус, которая представляет собой механизм поощрения безаварийной езды и наказания за страховые случаи.

Математически система КБМ может быть описана как дискретная марковская цепь с 15 классами страхования. Начальный класс для большей части водителей равен 3, что соответствует коэффициенту $K_{\text{БМС}} = 1,00$. Переход между классами осуществляется ежегодно в зависимости от количества страховых выплат N_{claims} :

$$K_{\text{БМС}}^{t+1} = f(K_{\text{БМС}}^t, N_{\text{claims}}),$$

где $K_{\text{БМС}}^t$ — коэффициент в текущем периоде, $K_{\text{БМС}}^{t+1}$ — коэффициент в следующем периоде. При отсутствии страховых случаев водитель переходит в класс с меньшим коэффициентом, достигая максимальной скидки в классе 13 ($K_{\text{БМС}} = 0,50$). При наличии выплат происходит понижение класса, что может увеличить коэффициент до 3,92.

Независимо от широкого распространения, традиционная система КБМ в Российской Федерации имеет ряд существенных ограничений:

1. Во-первых, она основывается на дискретных шагах, в которых не учитывается тяжесть страховых случаев: например, одна мелкая царапина и одно крупное ДТП с жертвами влияют на коэффициент одинаково.
2. Во-вторых, обновление данных происходит раз в год. Подобная периодичность не позволяет оперативно реагировать на изменения в стиле вождения.
3. В-третьих, система не учитывает дополнительные факторы риска, такие как погодные условия, плотность трафика в регионе эксплуатации или технические характеристики транспортного средства.

Формула расчета итоговой стоимости полиса ОСАГО в российской практике имеет вид:

$$C_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{тер}} \cdot K_{\text{БМС}} \cdot K_{\text{возр-стаж}} \cdot K_{\text{мощн}} \cdot K_{\text{сезон}},$$

где $T_{\text{баз}}$ — базовый тариф в рамках коридора, установленного регулятором. Данная мультипликативная модель предполагает независимость коэффициентов, что в реальности не всегда верно. Например, риск молодого водителя может существенно различаться в зависимости от региона, типа и состояния транспортного средства, но традиционная формула не учитывает подобные взаимодействия.

Описанные ограничения формируют предпосылки для внедрения более гибких методов оценки рисков. Интеграция алгоритмов машинного обучения позволяет перейти от дискретной системы классов к непрерывной оценке вероятности риска, учитывая при этом нелинейные зависимости и широкий спектр признаков и факторов, которые особенно актуальны в условиях цифровизации российского страхового рынка.

1.4 Математическое обоснование необходимости применения методов машинного обучения

Традиционные подходы к расчету страховых тарифов, рассмотренные в предыдущих разделах, имеют фундаментальные математические ограничения, значительно снижающие точность прогнозирования и оценки рисков в условиях современного страхового рынка. Мультипликативная модель ОСАГО, представленная формулой

$$C_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{возр}} \cdot K_{\text{рег}} \cdot K_{\text{стаж}} \cdot K_{\text{БМС}} \cdot K_{\text{мощн}},$$

предполагает отсутствие корреляции между коэффициентами. Для реальной практики подобное упущение может стать критическим, создавая неточность в итоговой стоимости. Математически это означает, что совместное распределение признаков факторизуется как произведение маргинальных распределений:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i),$$

однако эмпирические данные отражают наличие существенных корреляций между факторами риска. Например, взаимодействие между возрастом водителя и регионом эксплуатации создает эффект, который не может быть адекватно описан произведением независимых коэффициентов, так как риск молодого водителя существенно различается в зависимости от плотности трафика в мегаполисе или сельской местности.

Кроме того, традиционные модели предполагают линейную или кусочно-линейную зависимость между признаками и уровнем риска. Функция риска в таких системах имеет вид

$$R(\mathbf{x}) = \sum_i \beta_i x_i,$$

где каждый признак вносит аддитивный вклад независимо от значений других признаков. Реальная зависимость вероятности ДТП от характеристик водителя и автомобиля носит нелинейный характер и может быть описана только сложной функцией

$$R(\mathbf{x}) = f(x_1, x_2, \dots, x_n),$$

где f — нелинейное отображение, учитывающее взаимодействия между признаками. Игнорирование перекрестных членов в модели приводит к тому, что сложные паттерны поведения, такие как сочетание агрессивного стиля вождения с эксплуатацией мощного автомобиля в зимний период, не выявляются и не тарифицируются корректно.

Система бонус-малус, представляющая собой дискретную марковскую цепь с конечным числом состояний, также имеет математические ограничения. Переход между классами определяется только количеством страховых случаев N_{claims} без учета тяжести ущерба, обстоятельств ДТП и других факторов. С точки зрения математической оценки это означает, что функция перехода между состояниями

$$\pi_{ij} = P(K_{t+1} = j \mid K_t = i)$$

зависит только от текущего класса и числа выплат, игнорируя остальную информацию о водителе. Такой подход приводит к потере информации и снижению точности оценки индивидуального риска, так как одна мелкая царапина и одно крупное ДТП с жертвами влияют на итоговый коэффициент одинаково. Кроме того, обновление данных происходит раз в год, что не позволяет оперативно реагировать на изменения в стиле вождения владельца транспортного средства.

Переход к вероятностной формулировке задачи позволяет преодолеть указанные ограничения. Вместо дискретных классов бонус-малус система рассматривает непрерывную вероятность страхового случая

$$P(y = 1 \mid \mathbf{x}) \in [0, 1],$$

где $\mathbf{x}$ — вектор признаков водителя и автомобиля. Это позволяет использовать весь спектр доступной информации и строить более точные прогнозы. Задача прогнозирования страховых рисков формулируется как задача бинарной классификации, где целевая переменная $y \in \{0, 1\}$ указывает на наличие или отсутствие страхового случая в течение периода страхования.

Математическая постановка задачи заключается в нахождении функции $f: \mathbb{R}^d \rightarrow [0, 1]$, минимизирующей математическое ожидание функции потерь

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} [L(y, f(x))]$$

на распределении данных $\mathcal{D}$. В случае бинарной классификации используется функция потерь бинарной кросс-энтропии

$$L(y, p) = -[y \log p + (1 - y) \log(1 - p)],$$

где $p = f(x)$ — предсказанная вероятность положительного класса. Минимизация этой функции потерь эквивалентна максимизации правдоподобия данных при условии Бернуллиевского распределения целевой переменной.

Преимущество машинного обучения перед традиционными методами заключается в способности автоматически выявлять сложные нелинейные зависимости и взаимодействия между признаками без необходимости их явного задания аналитически. Ансамблевые методы, такие как градиентный бустинг, аппроксимируют целевую функцию через сумму базовых функций

$$f(x) = \sum_{m=1}^M \alpha_m h_m(x),$$

где каждая h_m — простое дерево решений, а коэффициенты α_m подбираются в процессе обучения. Такая модель способна аппроксимировать произвольную непрерывную функцию с любой заданной точностью при достаточном числе базовых функций, что обеспечивает высокую гибкость и точность прогнозов.

Таким образом, теоретическое обоснование необходимости применения методов машинного обучения сводится к неспособности традиционных линейных и мультипликативных моделей достоверно описывать сложные нелинейные зависимости между факторами риска и вероятностью страхового случая. Переход к вероятностной постановке задачи классификации с использованием гибких нелинейных моделей позволит повысить точность прогнозирования, обеспечить персонализацию тарифов и снизить уровень перекрестного субсидирования между клиентами с различным уровнем риска.

1.5 Методы машинного обучения в данной работе

В рамках настоящего исследования рассматривается задача построения предиктивной модели f , оценивающей вероятность наступления страхового случая.

Пусть $\mathcal{D} = \{1, \dots, N\}$ — множество клиентов, где каждому i -му клиенту соответствует вектор признаков $\mathbf{x}_i \in \mathbb{R}^d$, включающий персональные, технические, категориальные данные и информацию о стиле вождения. Цель исследования заключается в построении отображения $f: \mathbb{R}^d \rightarrow [0, 1]$, оценивающего вероятность страхового случая $y_i \in \{0, 1\}$ путём оптимизации функции потерь $L(f)$ на выборке $(X_{\text{train}}, Y_{\text{train}})$ и интеграции прогноза $P(y_i = 1 \mid \mathbf{x}_i)$ в систему расчёта коэффициента бонус-малус.

В качестве основного алгоритма выбран CatBoost, разработанный компанией Яндекс. Выбор данного метода обусловлен рядом преимуществ, критически важных для решения задачи прогнозирования страховых рисков. Алгоритм специализируется на работе с категориальными признаками, автоматически обрабатывая их без необходимости предварительного кодирования. Данная особенность особенно актуальна при наличии таких признаков, как тип автомобиля, регион эксплуатации, погодные условия и тип дорожной инфраструктуры.

Модель CatBoost обучается на функции потерь бинарной кросс-энтропии:

$$L(f) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(f(\mathbf{x}_i)) + (1 - y_i) \log(1 - f(\mathbf{x}_i)) \right]$$

с применением взвешивания классов для компенсации дисбаланса выборки, характерного для страховых данных, в которых количество аварий существенно ниже количества безаварийных случаев. Алгоритм CatBoost реализует метод Ordered Boosting, обеспечивающий высокую устойчивость к переобучению на малых и средних выборках, что критично в случае страховых данных. Встроенные механизмы регуляризации и предобработки категорий позволяют модели демонстрировать стабильные результаты без необходимости сложной инженерной подготовки признаков.

После обучения модель возвращает вероятность $P(y_i = 1 \mid \mathbf{x}_i)$. Бинарный прогноз формируется по пороговой функции

$$\hat{y}_i = \mathbb{I} \left[P(y_i = 1 \mid \mathbf{x}_i) \geq \theta \right],$$

где порог подбирается для максимизации метрики F1 при условии $\text{Recall} \geq \tau$:

$$\theta^* = \arg \max_{\theta'} F1_{\theta'} \quad \text{при условии} \quad \text{Recall}_{\theta'} \geq \tau.$$

Метрика F1 вычисляется как гармоническое среднее точности и полноты:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}},$$

где Recall — доля правильно предсказанных положительных случаев среди всех истинно положительных, Precision — доля правильно предсказанных положительных случаев среди всех предсказанных положительных, а $F1$ отражает баланс между точностью и полнотой.

Итоговый коэффициент бонус-малус вычисляется по формуле:

$$\text{КБМ}_{\text{итог}} = \text{КБМ}_{\text{базовый}} \cdot (1 + \beta \cdot (P_{\text{risk}} - P_{\text{avg}})) ,$$

где $P_{\text{risk}} = f(\mathbf{x}_i)$ — предсказанная моделью вероятность, P_{avg} — средняя вероятность по выборке, $\beta > 0$ — коэффициент чувствительности. Данная формула представляет собой линейную аппроксимацию влияния ML-модели на традиционный КБМ, позволяющую динамически адаптировать тариф под индивидуальный риск водителя.

В качестве базовой модели для сравнительного анализа также используется логистическая регрессия, которая, несмотря на простоту, служит отправной точкой для оценки эффективности более сложных алгоритмов. Логистическая регрессия обеспечивает высокую интерпретируемость результатов и позволяет оценить вклад каждого признака в уровень риска.

1.6 Выводы по главе

Проведённый в первой главе анализ предметной области и существующих методов оценки страховых рисков позволил выявить фундаментальные ограничения, характерные для традиционных подходов. Установлен факт, подтверждающий, что классические актуарные модели и мультипликативные формулы расчёта тарифов, применяемые в ОСАГО и КАСКО, базируются на предположении о линейной независимости факторов, что в корне не соответствует реальной структуре данных и приводит к снижению точности прогнозирования. Сравнительный анализ методов машинного обучения продемонстрировал эффективность ансамблевых алгоритмов, в частности градиентного бустинга, в задачах бинарной классификации на гетерогенных данных, содержащих как числовые, так и категориальные признаки.

Обоснован выбор алгоритма CatBoost в качестве основного инструмента прогнозирования благодаря его способности работать с категориальными признаками без предварительного кодирования, устойчивости к переобучению на малых выборках и высокой интерпретируемости результатов. Математическое обосно-

вание необходимости перехода к вероятностной формулировке задачи подтвердило целесообразность использования функции потерь бинарной кросс-энтропии для оценки индивидуального риска, что позволяет преодолеть ограничения дискретных систем бонус-малус и обеспечить непрерывную оценку вероятности ДТП.

Результаты теоретического исследования создают необходимую базу для практической реализации модели. Во второй главе будет произведена подготовка данных, обучение модели CatBoost, тестирование её качества на метриках классификации, а также разработка программного алгоритма динамического расчёта страхового тарифа на основе предсказанной вероятности. Для обеспечения визуального удобства оценки результатов и интерактивной демонстрации работы алгоритма будет реализован веб-интерфейс, позволяющий вводить параметры водителя и транспортного средства, загружать наборы данных и наглядно отображать прогнозы с детализацией ключевых показателей. Это позволит перейти от теоретического обоснования к созданию полнофункционального прототипа системы интеллектуального страхования.