



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Дальневосточный федеральный университет»
(ДВФУ)

**ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
(ШКОЛА)**

Департамент математического и компьютерного моделирования

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по образовательной программе подготовки бакалавров
по направлению 02.03.01 «Математика и компьютерные науки»
профиль « Сквозные цифровые технологии »

**Разработка модели прогнозирования страховых рисков в системе ОСАГО с
использованием гибридного подхода и телематических данных**

Работа защищена
с оценкой _____

Студент группы № Б9122-01.03.02мкт

_____ Винницкая Д.С.
(подпись) (Ф.И.О.)

« __ » _____ 20 __ г.

Регистрационный номер _____
« __ » _____ 20 __ г.

Руководитель _____
(должность, учёное звание)

_____ Кузнецов К.С.
(подпись) (Ф.И.О.)

« __ » _____ 20 __ г.

г. Владивосток

2026

Содержание

Аннотация	4
Введение	5
Термины, определения и сокращения	9
1 Анализ предметной области и существующих решений	12
1.1 Модели, используемые для расчета страховых тарифов	12
1.2 Методы машинного обучения в мировой практике страхования . .	13
1.3 Особенности российской практики страхования и система бонус- малус	15
1.4 Математическое обоснование необходимости применения методов машинного обучения	17
1.5 Методы машинного обучения в данной работе	19
1.6 Выводы по главе	21
2 Разработка прогнозной модели страховых рисков на основе машинно- го обучения	23
2.1 Описание данных и их подготовка	23
2.1.1 Источники данных	23
2.1.2 Структура признаков	24
2.1.3 Методы очистки и нормализации данных	27
2.2 Определение факторов, влияющих на вероятность ДТП	28
2.2.1 Генерация производных признаков	29
2.3 Разработка модели прогнозирования аварийности	30
2.3.1 Архитектурная структура модели	30
2.3.2 Этапы построения модели	32
2.3.3 Анализ важности признаков	36
2.4 Тестирование модели и анализ результатов	37
2.4.1 Метрики оценки качества и результаты тестирования	38
2.4.2 Анализ зависимости тарифов от ключевых факторов риска	39
2.4.3 Интерпретация результатов и практическая значимость . .	40
2.5 Реализация веб-интерфейса	41

2.5.1	Проектирование пользовательского интерфейса и прототипирование	41
2.5.2	Архитектура веб-приложения и механизмы межкомпонентного взаимодействия	43
2.5.3	Разработка серверной части и интеграция с моделью машинного обучения	47
2.5.4	Реализация клиентской части и механизмов визуализации данных	53
2.5.5	Пользовательские сценарии и функциональное тестирование интерфейса	53

АННОТАЦИЯ

Данная выпускная квалификационная работа посвящена разработке интеллектуальной системы прогнозирования страховых рисков и динамического расчета страховых тарифов в автостраховании на основе методов машинного обучения.

В ходе работы был проведен анализ традиционных методов, нацеленных на оценку рисков и обоснована необходимость перехода к вероятностной модели прогнозирования. В качестве основополагающего алгоритма был выбран CatBoost, который обеспечивает высокую точность в работе с категориальными признаками и гетерогенными данными. Разработана математическая модель бинарной классификации и формула динамического расчета коэффициента бонус-малус на основе предсказанной вероятности ДТП. Реализованы программные модули предобработки данных, обучения модели и расчета страхового тарифа с веб-интерфейсом, а тестирование модели метриками качества классификации подтвердило её предсказательную способность и чувствительность к ключевым факторам риска.

Разработанное решение может быть применено в сфере автострахования для внедрения персонализированного ценообразования, которое повысит точность оценки рисков и оптимизирует тарифную политику данной области.

ВВЕДЕНИЕ

В настоящее время, на фоне активной цифровизации и глобальной автоматизации финансовой отрасли и усиления конкурентной борьбы в сегменте автострахования, вопросы, касающиеся точного прогнозирования страховых рисков и научно обоснованного расчета тарифов, выходят на первый план, становясь определяющим фактором устойчивого развития и финансовой стабильности страховых организаций. В связи с ежегодным заключением договоров обязательного и добровольного страхования миллионами водителей, формируется постоянно растущий объем данных о страховых случаях, поведенческих факторах водителей, характеристиках транспортных средств, требующий детализированный, структурированный анализ для принятия взвешенных, обоснованных управленческих решений.

Формируется ряд фундаментальных проблем, вызванных тем, что существующие технологические решения в области актуарных расчетов в полной мере не удовлетворяют критериям и требованиям современного страхового рынка. Во-первых, наблюдается методологическая ограниченность традиционных подходов, а именно: страховые организации вынуждены использовать статические формулы с фиксированными коэффициентами, основанные на линейных зависимостях между признаками и уровнем риска. Такой процесс не учитывает нелинейный характер реальных взаимосвязей и приводит к искажению прогнозов, особенно при работе со сложными, неоднозначными профилями клиентов.

Во-вторых, традиционные бонус-малус системы и регрессионные модели не учитывают корреляцию между факторами риска, что приводит к упрощённой оценке и значительному снижению точности тарифов. Не менее важные данные, такие как стиль вождения, погодные условия, плотность трафика в населенном пункте и технические характеристики автомобиля, обычно не используются в полной мере, что ограничивает возможность персонализированной, точной оценки риска.

В-третьих, существующие методы не обладают способностью к динамической адаптации, а именно тарифы: пересматриваются редко и носят сугубо статичный характер, что, в свою очередь, не позволяет адаптироваться к изменяющимся поведенческим характеристикам водителя. Динамика улучшения или, наоборот, ухудшения стиля вождения не отражается на тарифе до следующего отчетного периода, а новые риски, связанные с изменениями в инфраструктуре или автомо-

бильных технологиях, учитываются с существенной, значимой задержкой. Таким образом, на данный момент на рынке отсутствует универсальная, адаптивная и технологически

Указанные обстоятельства обуславливают актуальность реализации модульной программной системы, которая обеспечивает полный цикл обработки страховых данных, используя алгоритмы градиентного бустинга и поддерживая идею персонализированного расчета тарифа.

Проблематика прогнозирования страховых рисков исследуется в работах как зарубежных, так и отечественных деятелей науки. Весомый вклад в развитие методов актуарного анализа внесли фундаментальные исследования в области теории риска, математической теории страхования и основ страховой математики. Современные подходы к оценке финансовых рисков рассмотрены в ряде работ, посвящённых моделированию неопределённости и управлению рисками в страховой сфере. Особое внимание в последние годы уделяется применению алгоритмов машинного обучения, в частности методов градиентного бустинга, таких как CatBoost, которые демонстрируют высокую эффективность при работе с гетерогенными данными, содержащими как числовые, так и категориальные признаки. В то же время вопросы проектирования интегрированных систем машинного обучения для автострахования, объединяющих алгоритмы классификации с механизмами динамического ценообразования и ориентированных на практическое внедрение в российские страховые компании, остаются недостаточно проработанными.

Цель работы — реализация интеллектуальной системы прогнозирования страховых рисков и расчета страхового тарифа в автостраховании на основе машинного обучения.

Для достижения поставленной цели необходимо решить комплекс взаимосвязанных **задач**:

1. провести анализ традиционных актуарных методов и систем бонус-малус для выявления их ограничений;
2. исследовать эффективность алгоритмов классификации и обосновать выбора модели CatBoost;
3. разработать методику предварительной обработки входных данных, включающую очистку выбросов, нормализацию числовых признаков и автоматическое кодирование категориальных переменных;

4. реализовать алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между возрастом водителя, стажем вождения и историей страховых обращений;
5. разработать программный модуль динамического расчета страхового тарифа, трансформирующий предсказанную вероятность риска в финансовый показатель с использованием коэффициента чувствительности;
6. разработать веб-интерфейс на базе Flask для взаимодействия с пользователем, обеспечивающий ввод параметров водителя и транспортного средства через форму и загрузку файлов;
7. разработать программный конвейер обработки данных, объединяющий этапы предобработки, загрузки обученной модели и получения прогноза в единый автоматизированный процесс;
8. оценить качества модели с использованием метрик accuracy, precision, recall и F1-меры.

Объектом исследования является процесс управления страховыми рисками в сфере автострахования.

Предметом исследования выступают математические методы и алгоритмы машинного обучения, направленные на прогнозирование вероятности наступления страховых случаев и расчет персонализированных страховых тарифов.

Методы исследования. В работе используются методы математической статистики и теории вероятностей для анализа данных и оценки рисков, алгоритмы машинного обучения с учителем, в частности градиентный бустинг на базе CatBoost, методы разведочного анализа данных для выявления корреляции между признаками, методы кросс-валидации для оценки обобщающей способности модели, метрики качества классификации для сравнительного анализа, а также методы визуализации данных для интерпретации результатов моделирования.

Практическая значимость работы определяется возможностью применения разработанной модели в реальных страховых компаниях для повышения точности оценки рисков, оптимизации тарифной политики и внедрения персонализированных страховых продуктов. Интеграция интеллектуальной системы прогнозирования позволит страховым компаниям сократить количество необоснованных выплат, повысить точность оценки профилей клиентов и усилить доверие

к страховой системе за счет более прозрачного, чуткого и справедливого ценообразования.

Структура работы. Выпускная квалификационная работа состоит из введения, трёх глав, заключения, списка литературы и приложений.

В первой главе проводится анализ предметной области автострахования: формализуется задача прогнозирования страховых рисков, выполняется обзор традиционных актуарных методов, систем бонус-малус и современных подходов на основе машинного обучения [prokhorenkova2018catboost], а также сравнительный анализ существующих программных решений. По результатам анализа обосновывается выбор алгоритма CatBoost для решения задачи бинарной классификации и формулируются требования к разрабатываемой системе.

Во второй главе описывается разработка прогнозной модели: этапы подготовки и предобработки данных, архитектурная структура модели, процесс обучения классификатора, тестирование метриками качества (accuracy, precision, recall, F1), а также реализация веб-интерфейса для динамического расчета страховых тарифов на основе предсказанной вероятности ДТП.

ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ

Термины и определения

Актuariальные модели — это математические и статистические инструменты, используемые для оценки рисков, прогнозирования финансовых последствий неопределённостей, а также для расчёта страховых взносов, управления активами и обязательствами в различных сферах, прежде всего в страховании.

Бонус-малус система (БМС) — механизм индивидуализации страхового тарифа на основе страховой истории клиента, предусматривающий применение скидок (бонусов) за безаварийную езду и надбавок (малусов) за наличие страховых выплат; в работе рассматривается как традиционный метод, подлежащий оптимизации средствами машинного обучения.

Градиентный бустинг (Gradient Boosting) — ансамблевый алгоритм машинного обучения, основанный на последовательном построении композиции моделей, где каждая следующая модель обучается минимизировать ошибки предыдущих; в работе используется как основной метод прогнозирования вероятности ДТП.

Страховой риск — предполагаемое событие, обладающее признаками вероятности и случайности, при наступлении которого возникает обязательство страховщика произвести страховую выплату; в контексте работы: вероятность наступления дорожно-транспортного происшествия (ДТП).

Страховой тариф — цена страхового риска, выраженная в денежной сумме, относящаяся к единице страховой суммы или процентной доле от нее; в работе рассчитывается на основе прогнозной вероятности ДТП, полученной моделью машинного обучения.

Телематическое страхование (Usage-Based Insurance, UBI) — вид страхования, при котором страховой тариф формируется на основе данных о реальном поведении водителя (скорость, пробег, стиль вождения), фиксируемых специальными устройствами; рассматривается в работе как перспективное направление расширения признаков модели.

Переобучение (Overfitting) — ситуация в машинном обучении, при которой модель чрезмерно точно воспроизводит закономерности обучающей выборки, включая шум и выбросы, что приводит к снижению качества предсказаний на новых данных; для предотвращения используется метод Ordered Boosting в алго-

ритме CatBoost.

Важность признаков (Feature Importance) — метрика, оценивающая вклад каждого входного параметра в прогноз модели машинного обучения; используется в работе для интерпретации результатов и выявления ключевых факторов риска.

Метрики классификации — количественные показатели качества работы модели бинарной классификации; в работе используются Accuracy (точность), Precision (точность положительного класса), Recall (полнота), F1-score (гармоническое среднее) и ROC-AUC (площадь под ROC-кривой).

Конвейер обработки данных (Data Pipeline) — последовательность этапов обработки информации, включающая в себя сбор, очистку, нормализацию данных, обучение модели и получение прогноза; в работе реализован в виде программного класса InsuranceRiskModel.

Целевая переменная (Target) — бинарный индикатор факта дорожно-транспортного происшествия, соответствующий значению 1 при наличии страхового случая и 0 при его отсутствии; является объектом прогнозирования в задаче классификации.

Категориальный признак — переменная, которая принимает дискретный набор значений (например, тип автомобиля, регион, погодные условия); в работе обрабатывается алгоритмом CatBoost без предварительного кодирования.

Базовая ставка тарифа — минимальная стоимость страхового полиса, устанавливаемая страховой компанией для низкорисковых клиентов; служит основой для динамического расчета итогового тарифа.

Коэффициент чувствительности к риску — параметр, отвечающий за степень влияния прогнозируемой вероятности ДТП на итоговую стоимость страхового полиса; регулируется экспертно в зависимости от бизнес-политики страховщика.

Перечень сокращений

ОСАГО	Обязательное страхование гражданской ответственности владельцев транспортных средств
КАСКО	Комплексное автострахование, кроме ответственности (добровольное страхование транспортного средства от ущерба и угона)
ДТП	Дорожно-транспортное происшествие
ПДД	Правила дорожного движения
ЦБ РФ	Центральный банк Российской Федерации (регулятор страхового рынка)
ФАС	Федеральная антимонопольная служба
МЛ / ML	Machine Learning — машинное обучение
ИИ / AI	Artificial Intelligence — искусственный интеллект
EDA	Exploratory Data Analysis — разведочный анализ данных
CatBoost	Categorical Boosting — алгоритм градиентного бустинга
XGBoost	eXtreme Gradient Boosting — алгоритм градиентного бустинга
LightGBM	Light Gradient Boosting Machine — алгоритм градиентного бустинга
ROC-AUC	Receiver Operating Characteristic – Area Under Curve
F1-score	Гармоническое среднее между Precision и Recall
Precision	Доля правильно предсказанных положительных случаев
Recall	Доля правильно предсказанных случаев среди всех истинных
Accuracy	Доля правильно классифицированных объектов
UBI	Usage-Based Insurance — телематическое страхование
GAP	Guaranteed Asset Protection — страхование разницы стоимости
API	Application Programming Interface — программный интерфейс
CPU	Central Processing Unit — центральный процессор
GPU	Graphics Processing Unit — графический процессор
JSON	JavaScript Object Notation — формат обмена данными

1 Анализ предметной области и существующих решений

1.1 Модели, используемые для расчета страховых тарифов

В современных условиях автострахования выделяют несколько основополагающих подходов, применяемых для расчета страховых тарифов, каждый из которых основывается на специфических математических моделях оценки риска.

Традиционная модель ОСАГО применяет мультипликативную формулу:

$$P_{\text{ОСАГО}} = T_{\text{баз}} \times \prod K_i,$$

где итоговая стоимость определяется произведением базовой ставки на набор фиксированных коэффициентов, что создает ограничения из-за предположения о линейной независимости факторов риска.

Модели КАСКО, в свою очередь, оперируют аддитивным принципом расчета ожидаемых убытков, выражаемым формулой:

$$P_{\text{КАСКО}} = P_{\text{ДТП}} \times C_{\text{ремонт}} + P_{\text{угон}} \times C_{\text{выпл}} + C_{\text{админ}},$$

где вероятность наступления страхового случая оценивается с помощью алгоритмов классификации, таких как логистическая регрессия:

$$P(y = 1) = \frac{1}{1 + e^{-z}}$$

или градиентный бустинг.

Наиболее прогрессивным направлением является телематическое страхование (Usage-Based Insurance, UBI), применяющее динамическую формулу:

$$S_{\text{UBI}} = T_{\text{баз}} \times K_{\text{пробег}} \times K_{\text{стиль}} \times K_{\text{время}},$$

которая позволяет в реальном времени подстраивать тариф под фактическое поведение водителя, фиксируемое датчиками.

Тем не менее, широкое применение телематических моделей ограничено потребностью в масштабных массивах данных и необходимостью оснащения автомобилей специализированным оборудованием, в то время как алгоритмы машинного обучения в рамках КАСКО уже продемонстрировали высокую результативность при обнаружении скрытых нелинейных взаимосвязей между параметрами.

1.2 Методы машинного обучения в мировой практике страхования

В международной практике страхования наблюдается устойчивая тенденция к применению различных алгоритмов машинного обучения, предназначенных для решения задач прогнозирования рисков, каждый из которых имеет свою математическую основу и специфическую область практического применения.

Ансамблевые методы на основе деревьев решений, в частности алгоритм Random Forest, характеризуются высокой устойчивостью к переобучению и способностью выявлять нелинейные закономерности в данных. Математическая формализация модели случайного леса представляет собой ансамбль из M решающих деревьев, где итоговый прогноз формируется посредством усреднения предсказаний отдельных деревьев:

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x)$$

где $T_m(x)$ – прогноз m -го дерева для входного вектора признаков x . Для задач бинарной классификации применяется голосование большинством:

$$\hat{y} = \operatorname{argmax}_k \sum_{m=1}^M \mathbb{I}(T_m(x) = k)$$

Данный подход обеспечивает снижение дисперсии модели за счёт декорреляции отдельных деревьев через бутстрэппинг и случайный выбор признаков.

Алгоритмы градиентного бустинга, такие как XGBoost и LightGBM, проявили себя как эффективные инструменты, подходящие для задач бинарной классификации, обеспечивая, в свою очередь, высокую точность предсказаний при работе с табличными данными. Принцип работы основывается на поэтапном построении ансамбля деревьев, в котором каждое новое дерево обучается минимизировать остатки предыдущих:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

где $F_t(x)$ – прогноз на шаге t , η – скорость обучения, $h_t(x)$ – новое дерево, обученное на градиентах функции потерь. XGBoost использует регуляризованный объектив:

$$\mathcal{L} = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

где $\Omega(f_k)$ – штраф за сложность дерева, который предотвращает переобучение.

Архитектуры глубокого обучения и искусственные нейронные сети эффективно применяются для решения задач высокой сложности, требующих обработки неструктурированных данных. В частности, данные методы используются в области компьютерного зрения для автоматизированной оценки ущерба транспортных средств после дорожно-транспортных происшествий, а также в задачах обработки естественного языка для семантического анализа текстовой документации страховых заявлений. Архитектуры глубокого обучения обеспечивают аппроксимацию высокосложных нелинейных зависимостей в высокоразмерных пространствах признаков посредством иерархической композиции нелинейных преобразований:

$$a^{[l]} = \sigma(W^{[l]}a^{[l-1]} + b^{[l]})$$

где $a^{[l]}$ – активации l -го слоя, $W^{[l]}$ – матрица весов, $b^{[l]}$ – вектор смещений, σ – функция активации. Тем не менее такие модели требуют значительных вычислительных ресурсов и больших размеченных выборок для обучения.

Методы кластеризации, такие как K-means и DBSCAN, используются для сегментации клиентов по уровню риска, что позволяет страховым компаниям разрабатывать дифференцированные тарифные планы. Алгоритм K-means минимизирует внутрикластерную дисперсию:

$$J = \sum_{j=1}^K \sum_{i=1}^N \mathbb{I}(x_i \in C_j) \|x_i - \mu_j\|^2$$

где μ_j – центроид кластера C_j . Методы снижения размерности, включая РСА, применяются для визуализации многомерных данных и ускорения обучения моделей. Метод главных компонент (РСА) находит ортогональные направления максимальной дисперсии:

$$\max_w w^T \Sigma w \quad \text{при условии} \quad \|w\| = 1$$

где Σ – ковариационная матрица признаков.

В области телематического страхования повсеместно применяются методы обучения с подкреплением для задач динамического ценообразования, в которых

модель обучается выбирать оптимальные тарифы, получая обратную связь от системы. Данный процесс формализуется через марковский процесс принятия решений (MDP), в котором агент максимизирует ожидаемую награду:

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right]$$

где π – политика выбора действий, R – функция награды, γ – коэффициент дисконтирования.

Современные исследования также демонстрируют хорошие показатели эффективности внедрения ансамблевых методов, которые комбинируют несколько алгоритмов в целях повышения точности прогнозов. Стекинг объединяет предсказания базовых моделей через мета-обучение:

$$\hat{y} = g(h_1(x), h_2(x), \dots, h_k(x))$$

где g – мета-модель, обученная на выходах базовых алгоритмов h_i . Данный подход предоставляет возможность компенсировать индивидуальные слабости отдельных моделей и достигать более стабильных результатов, что подтверждает целесообразность использования интеллектуальных алгоритмов в современном страховании.

1.3 Особенности российской практики страхования и система бонус-малус

Российскому рынку автострахования характерна высокая доля обязательного страхования гражданской ответственности, где тарифное регулирование осуществляется государством в лице Центрального банка Российской Федерации. Ключевым компонентом индивидуализации стоимости полиса в российской практике является система бонус-малус, которая представляет собой механизм поощрения безаварийной езды и наказания за страховые случаи.

Математически система КБМ может быть описана как дискретная марковская цепь с 15 классами страхования. Начальный класс для большей части водителей равен 3, что соответствует коэффициенту $K_{\text{БМС}} = 1,00$. Переход между классами осуществляется ежегодно в зависимости от количества страховых выплат N_{claims} :

$$K_{\text{БМС}}^{t+1} = f(K_{\text{БМС}}^t, N_{\text{claims}}),$$

где $K_{\text{БМС}}^t$ — коэффициент в текущем периоде, $K_{\text{БМС}}^{t+1}$ — коэффициент в следующем периоде. При отсутствии страховых случаев водитель переходит в класс с меньшим коэффициентом, достигая максимальной скидки в классе 13 ($K_{\text{БМС}} = 0,50$). При наличии выплат происходит понижение класса, что может увеличить коэффициент до 3,92.

Независимо от широкого распространения, традиционная система КБМ в Российской Федерации имеет ряд существенных ограничений:

1. Во-первых, она основывается на дискретных шагах, в которых не учитывается тяжесть страховых случаев: например, одна мелкая царапина и одно крупное ДТП с жертвами влияют на коэффициент одинаково.
2. Во-вторых, обновление данных происходит раз в год. Подобная периодичность не позволяет оперативно реагировать на изменения в стиле вождения.
3. В-третьих, система не учитывает дополнительные факторы риска, такие как погодные условия, плотность трафика в регионе эксплуатации или технические характеристики транспортного средства.

Формула расчета итоговой стоимости полиса ОСАГО в российской практике имеет вид:

$$P_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{тер}} \cdot K_{\text{БМС}} \cdot K_{\text{возр-стаж}} \cdot K_{\text{мощн}} \cdot K_{\text{сезон}},$$

где $T_{\text{баз}}$ — базовый тариф в рамках коридора, установленного регулятором. Данная мультипликативная модель предполагает независимость коэффициентов, что в реальности не всегда верно. Например, риск молодого водителя может существенно различаться в зависимости от региона, типа и состояния транспортного средства, но традиционная формула не учитывает подобные взаимодействия.

Описанные ограничения формируют предпосылки для внедрения более гибких методов оценки рисков. Интеграция алгоритмов машинного обучения позволяет перейти от дискретной системы классов к непрерывной оценке вероятности риска, учитывая при этом нелинейные зависимости и широкий спектр признаков и факторов, которые особенно актуальны в условиях цифровизации российского страхового рынка.

1.4 Математическое обоснование необходимости применения методов машинного обучения

Традиционные подходы к расчету страховых тарифов, рассмотренные в предыдущих разделах, имеют фундаментальные математические ограничения, значительно снижающие точность прогнозирования и оценки рисков в условиях современного страхового рынка. Мультипликативная модель ОСАГО, представленная формулой

$$P_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{возр}} \cdot K_{\text{рег}} \cdot K_{\text{стаж}} \cdot K_{\text{БМС}} \cdot K_{\text{мощн}},$$

предполагает отсутствие корреляции между коэффициентами. Для реальной практики подобное упущение может стать критическим, создавая неточность в итоговой стоимости. Математически это означает, что совместное распределение признаков факторизуется как произведение маргинальных распределений:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i),$$

однако эмпирические данные отражают наличие существенных корреляций между факторами риска. Например, взаимодействие между возрастом водителя и регионом эксплуатации создает эффект, который не может быть адекватно описан произведением независимых коэффициентов, так как риск молодого водителя существенно различается в зависимости от плотности трафика в мегаполисе или сельской местности.

Кроме того, традиционные модели предполагают линейную или кусочно-линейную зависимость между признаками и уровнем риска. Функция риска в таких системах имеет вид

$$R(\mathbf{x}) = \sum_i \beta_i x_i,$$

где каждый признак вносит аддитивный вклад независимо от значений других признаков. Реальная зависимость вероятности ДТП от характеристик водителя и автомобиля носит нелинейный характер и может быть описана только сложной функцией

$$R(\mathbf{x}) = f(x_1, x_2, \dots, x_n),$$

где f — нелинейное отображение, учитывающее взаимодействия между признаками. Игнорирование перекрестных членов в модели приводит к тому, что сложные паттерны поведения, такие как сочетание агрессивного стиля вождения с эксплуатацией мощного автомобиля в зимний период, не выявляются и не тарифицируются корректно.

Система бонус-малус, представляющая собой дискретную марковскую цепь с конечным числом состояний, также имеет математические ограничения. Переход между классами определяется только количеством страховых случаев N_{claims} без учета тяжести ущерба, обстоятельств ДТП и других факторов. С точки зрения математической оценки это означает, что функция перехода между состояниями

$$\pi_{ij} = P(K_{t+1} = j \mid K_t = i)$$

зависит только от текущего класса и числа выплат, игнорируя остальную информацию о водителе. Такой подход приводит к потере информации и снижению точности оценки индивидуального риска, так как одна мелкая царапина и одно крупное ДТП с жертвами влияют на итоговый коэффициент одинаково. Кроме того, обновление данных происходит раз в год, что не позволяет оперативно реагировать на изменения в стиле вождения владельца транспортного средства.

Переход к вероятностной формулировке задачи позволяет преодолеть указанные ограничения. Вместо дискретных классов бонус-малус система рассматривает непрерывную вероятность страхового случая

$$P(y = 1 \mid \mathbf{x}) \in [0, 1],$$

где $\mathbf{x}$ — вектор признаков водителя и автомобиля. Это позволяет использовать весь спектр доступной информации и строить более точные прогнозы. Задача прогнозирования страховых рисков формулируется как задача бинарной классификации, где целевая переменная $y \in \{0, 1\}$ указывает на наличие или отсутствие страхового случая в течение периода страхования.

Математическая постановка задачи состоит в поиске оптимальной функции $f: \mathbb{R}^d \rightarrow [0, 1]$, минимизирующей математическое ожидание функции потерь

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} [L(y, f(x))]$$

на распределении данных $\mathcal{D}$. В случае бинарной классификации используется функция потерь бинарной кросс-энтропии

$$L(y, p) = -[y \log p + (1 - y) \log(1 - p)],$$

где $p = f(x)$ — предсказанная вероятность положительного класса. Минимизация этой функции потерь эквивалентна максимизации правдоподобия данных при условии Бернуллиевского распределения целевой переменной.

Преимущество машинного обучения перед традиционными методами заключается в способности автоматически выявлять сложные нелинейные зависимости и взаимодействия между признаками без необходимости их явного задания аналитически. Ансамблевые методы, такие как градиентный бустинг, аппроксимируют целевую функцию через сумму базовых функций

$$f(x) = \sum_{m=1}^M \alpha_m h_m(x),$$

где каждая h_m — простое дерево решений, а коэффициенты α_m подбираются в процессе обучения. Такая модель способна аппроксимировать произвольную непрерывную функцию с любой заданной точностью при достаточном числе базовых функций, что обеспечивает высокую гибкость и точность прогнозов.

Таким образом, теоретическое обоснование необходимости применения методов машинного обучения сводится к неспособности традиционных линейных и мультипликативных моделей достоверно описывать сложные нелинейные зависимости между факторами риска и вероятностью страхового случая. Переход к вероятностной постановке задачи классификации с использованием гибких нелинейных моделей позволит повысить точность прогнозирования, обеспечить персонализацию тарифов и снизить уровень перекрестного субсидирования между клиентами с различным уровнем риска.

1.5 Методы машинного обучения в данной работе

В рамках настоящего исследования рассматривается задача построения предиктивной модели f , оценивающей вероятность наступления страхового случая. Пусть $\mathcal{D} = \{1, \dots, N\}$ — множество клиентов, где каждому i -му клиенту соответствует вектор признаков $\mathbf{x}_i \in \mathbb{R}^d$, включающий персональные, технические, категориальные данные и информацию о стиле вождения. Цель исследования заключается в построении отображения $f: \mathbb{R}^d \rightarrow [0, 1]$, оценивающего вероятность страхового случая $y_i \in \{0, 1\}$ путём оптимизации функции потерь $L(f)$ на выборке $(X_{\text{train}}, Y_{\text{train}})$ и интеграции прогноза $P(y_i = 1 \mid \mathbf{x}_i)$ в систему расчёта коэффициента бонус-малус.

В качестве основного алгоритма выбран CatBoost, разработанный компанией Яндекс. Выбор данного метода обусловлен рядом преимуществ, критически важных для решения задачи прогнозирования страховых рисков. Алгоритм специализируется на работе с категориальными признаками, автоматически обрабатывая их без необходимости предварительного кодирования. Данная особенность особенно актуальна при наличии таких признаков, как тип автомобиля, регион эксплуатации, погодные условия и тип дорожной инфраструктуры.

Модель CatBoost обучается на функции потерь бинарной кросс-энтропии:

$$L(f) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(f(\mathbf{x}_i)) + (1 - y_i) \log(1 - f(\mathbf{x}_i)) \right]$$

с применением взвешивания классов для компенсации дисбаланса выборки, характерного для страховых данных, в которых количество аварий существенно ниже количества безаварийных случаев. Алгоритм CatBoost реализует метод Ordered Boosting, обеспечивающий высокую устойчивость к переобучению на малых и средних выборках, что критично в случае страховых данных. Встроенные механизмы регуляризации и предобработки категорий позволяют модели демонстрировать стабильные результаты без необходимости сложной инженерной подготовки признаков.

После обучения модель возвращает вероятность $P(y_i = 1 \mid \mathbf{x}_i)$. Бинарный прогноз формируется по пороговой функции

$$\hat{y}_i = \mathbb{I} \left[P(y_i = 1 \mid \mathbf{x}_i) \geq \theta \right],$$

где порог подбирается для максимизации метрики F1 при условии $\text{Recall} \geq \tau$:

$$\theta^* = \arg \max_{\theta'} F1_{\theta'} \quad \text{при условии} \quad \text{Recall}_{\theta'} \geq \tau.$$

Метрика F1 вычисляется как гармоническое среднее точности и полноты:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}},$$

где Recall — доля правильно предсказанных положительных случаев среди всех истинно положительных, Precision — доля правильно предсказанных положительных случаев среди всех предсказанных положительных, а F1 отражает баланс между точностью и полнотой.

Итоговый коэффициент бонус-малус вычисляется по формуле:

$$\text{КБМ}_{\text{итог}} = \text{КБМ}_{\text{базовый}} \cdot (1 + \beta \cdot (P_{\text{risk}} - P_{\text{avg}})),$$

где $P_{\text{risk}} = f(\mathbf{x}_i)$ — предсказанная моделью вероятность, P_{avg} — средняя вероятность по выборке, $\beta > 0$ — коэффициент чувствительности. Данная формула представляет собой линейную аппроксимацию влияния ML-модели на традиционный КБМ, позволяющую динамически адаптировать тариф под индивидуальный риск водителя.

В качестве базовой модели для сравнительного анализа также используется логистическая регрессия, которая, несмотря на простоту, служит отправной точкой для оценки эффективности более сложных алгоритмов. Логистическая регрессия обеспечивает высокую интерпретируемость результатов и позволяет оценить вклад каждого признака в уровень риска.

1.6 Выводы по главе

Проведённый в первой главе анализ предметной области и существующих методов оценки страховых рисков позволил выявить фундаментальные ограничения, характерные для традиционных подходов. Установлен факт, подтверждающий, что классические актуарные модели и мультипликативные формулы расчёта тарифов, применяемые в ОСАГО и КАСКО, базируются на предположении о линейной независимости факторов, что в корне не соответствует реальной структуре данных и приводит к снижению точности прогнозирования. Сравнительный анализ методов машинного обучения продемонстрировал эффективность ансамблевых алгоритмов, в частности градиентного бустинга, в задачах бинарной классификации на гетерогенных данных, содержащих как числовые, так и категориальные признаки.

Обоснован выбор алгоритма CatBoost в качестве основного инструмента прогнозирования благодаря его способности работать с категориальными признаками без предварительного кодирования, устойчивости к переобучению на малых выборках и высокой интерпретируемости результатов. Математическое обоснование необходимости перехода к вероятностной формулировке задачи подтвердило целесообразность использования функции потерь бинарной кросс-энтропии для оценки индивидуального риска, что позволяет преодолеть ограничения дискретных систем бонус-малус и обеспечить непрерывную оценку вероятности ДТП.

Результаты теоретического исследования создают необходимую базу для практической реализации модели. Во второй главе будет произведена подготовка данных, обучение модели CatBoost, тестирование её качества на метриках клас-

сификации, а также разработка программного алгоритма динамического расчёта страхового тарифа на основе предсказанной вероятности. Для обеспечения визуального удобства оценки результатов и интерактивной демонстрации работы алгоритма будет реализован веб-интерфейс, позволяющий вводить параметры водителя и транспортного средства, загружать наборы данных и наглядно отображать прогнозы с детализацией ключевых показателей. Это позволит перейти от теоретического обоснования к созданию полнофункционального прототипа системы интеллектуального страхования.

2 Разработка прогнозной модели страховых рисков на основе машинного обучения

В данной главе осуществляется описание процесса разработки, обучения и верификации модели прогнозирования страховых рисков. Рассматриваются этапы подготовки и нормализации данных, архитектурная структура разработанной системы, процедура обучения классификатора на базе алгоритма CatBoost, реализация веб-интерфейса, необходимого для интерактивного взаимодействия с моделью, а также результаты экспериментального тестирования и последующего анализа качества модели.

2.1 Описание данных и их подготовка

2.1.1 Источники данных

Для реализации модели прогнозирования страховых рисков в работе использовались два независимых набора данных, различающихся по природе, структуре и целевому назначению.

Основной синтетический датасет для обучения классификационной модели, а именно CatBoostClassifier, был сформирован методом агрегации и нормализации открытых источников. Структура и распределения признаков имитируют поведение клиентов страховой компании и основаны на обобщённой информации из:

- публичных баз данных по дорожно-транспортным происшествиям (Госавтоинспекция РФ, открытые датасеты платформы Kaggle по автострахованию);
- агрегированной статистики страховых выплат и историй обращений российских страховых компаний;
- климатических справочников и сведений о дорожных условиях, характерных для различных субъектов Российской Федерации;
- методических рекомендаций и актуарных отчётов Центрального банка РФ по тарификации ОСАГО.

Используемый набор данных структурирован в табличном формате, где каждая строка представляет собой одно наблюдение (страховой случай или период страхования), а каждый столбец соответствует отдельному признаку, потенциально влияющему на вероятность наступления страхового события. Общий объём выборки составил 10 000 наблюдений, что обеспечивает статистическую значимость результатов обучения модели при сохранении баланса классов.

Датасет телематических данных использовался для верификации гипотезы о влиянии поведенческих факторов вождения на вероятность ДТП и потенциального расширения признаков модели. В качестве источника выступил набор данных *Levin Vehicle Telematics*, содержащий анонимизированные показатели стиля вождения, зафиксированные телематическими устройствами: скорость, ускорение, резкость торможения, время суток поездок и геолокационные метки. Данный датасет позволил провести корреляционный анализ между поведенческими паттернами и частотой страховых случаев, а также обосновать включение производных признаков (`night_driving_ratio`, `avg_trips_per_week`) в финальную структуру модели.

Оба набора данных прошли процедуру предварительной обработки, которая включала в себя удаление повторяющихся строк и значений, нормализацию форматов и согласование семантики признаков, что обеспечило их совместимость в рамках единого конвейера машинного обучения.

2.1.2 Структура признаков

Окончательная структура данных включает количественные и категориальные признаки, выбранные на основе многофакторного анализа предметной области и верифицированные на информативность посредством предварительного обучения модели `CatBoostClassifier`. Селекция признаков осуществлялась с учётом следующих критериев:

- статистическая значимость корреляции с целевой переменной, под которой подразумевается коэффициент корреляции Пирсона $|r| > 0.1$;
- отсутствие мультиколлинеарности между признаками (коэффициент вариации инфляции $VIF < 5$);
- практическая интерпретируемость с точки зрения страховой методологии;

- доступность данных для сбора в реальных условиях страхования.

Все признаки, в свою очередь, классифицированы на следующие логические группы:

Персональные данные водителя:

- **driver_age** - возраст водителя в годах (числовой, интервал [18; 80]). Согласно статистике ГИБДД, водители возрастных категорий 18-25 лет и 65+ лет демонстрируют повышенную аварийность вследствие недостатка опыта и возрастных изменений когнитивных функций соответственно;
- **driver_experience** - водительский стаж в годах (числовой, интервал [0; 60]). Стаж вождения является одним из ключевых предикторов риска, используемых в традиционных актуарных моделях и бонус-малус системах;
- **occupation_type** - тип занятости (категориальный: офисный работник, студент, пенсионер, фрилансер, профессиональный водитель, владелец бизнеса). Род деятельности влияет на частоту и интенсивность использования транспортного средства, а также на стиль и характер вождения;
- **num_claims** - количество страховых обращений в прошлом (числовой, интервал [0; 10]). История страховых случаев является одним из наиболее значимых предикторов будущей аварийности, что подтверждается актуарной практикой;
- **violation_count** – количество нарушений правил дорожного движения (числовой, интервал [0; 20]). Нарушения ПДД коррелируют с агрессивным стилем вождения и повышенным риском ДТП;
- **days_since_last_claim** – количество дней с момента последнего страхового случая (числовой, интервал [30; 1095]). Временной промежуток с последнего страхового случая отражает динамику изменения риска во времени;
- **avg_trips_per_week** – среднее количество поездок в неделю (числовой, интервал [1; 50]). Частота использования транспортного средства прямо пропорциональна вероятности наступления страхового события;

- **night_driving_ratio** – доля поездок в ночное время (числовой, интервал [0; 1]). Ночные поездки статистически связаны с повышенной аварийностью из-за ограниченной видимости и усталости водителя.

Характеристики транспортного средства:

- **vehicle_age** – возраст транспортного средства в годах (числовой, интервал [0; 30]). Возраст автомобиля влияет на частоту технических неисправностей и стоимость восстановительного ремонта;
- **vehicle_type** – тип транспортного средства (категориальный: седан, хэтчбек, внедорожник, грузовик, фургон). Различные типы ТС имеют разную статистику аварийности и стоимость ремонта;
- **engine_power** – мощность двигателя в лошадиных силах (числовой, интервал [60; 300]). Мощность двигателя коррелирует с динамическими характеристиками автомобиля и стилем вождения владельца;
- **vehicle_purpose** – целевое назначение использования транспортного средства (категориальный: личное, коммерческое, такси, доставка). Коммерческое использование увеличивает пробег и время эксплуатации, повышая риск;
- **num_owned_vehicles** – количество транспортных средств в собственности (числовой, интервал [1; 5]). Количество автомобилей в собственности может отражать финансовое положение и опыт владельца.

Внешние и региональные факторы:

- **region** – регион эксплуатации транспортного средства (категориальный: субъекты РФ). Региональные различия в плотности трафика, дорожной инфраструктуре и климатических условиях существенно влияют на аварийность;
- **pct_days_with_snow** – доля дней со снегом в календарном году (числовой, интервал [0; 1]). Зимние погодные условия увеличивают вероятность ДТП из-за скользкого дорожного покрытия;
- **pct_days_with_rain** – доля дней с осадками в календарном году (числовой, интервал [0; 1]). Дождь снижает видимость и сцепление шин с дорогой, повышая риск аварий;

- `winter_duration_months` – продолжительность зимнего периода в месяцах (числовой, интервал $[0; 12]$). Длительность зимнего сезона влияет на совокупное воздействие неблагоприятных погодных условий.

Базовые страховые коэффициенты:

- `base_kbm` – базовый коэффициент бонус-малус (числовой, интервал $[0.46; 3.92]$). Традиционный коэффициент, используемый в системе ОСАГО для индивидуализации тарифа;
- `ko_multiplier` – коэффициент ограниченного использования транспортного средства (числовой, интервал $[1.0; 1.8]$). Учитывает количество водителей, допущенных к управлению транспортным средством.

Целевой признак:

- `target` – бинарный индикатор факта наступления страхового случая (1 – страховой случай произошёл, 0 – не произошёл). Бинарная постановка задачи соответствует природе страхового события и упрощает интерпретацию результатов модели.

Полный перечень признаков с указанием типов данных, диапазонов значений и семантического описания представлен в таблице формата, приведённого в Приложении А. Дополнительно Приложении Б представлен фрагмент исходного кода, иллюстрирующий процесс генерации и предобработки признаков, а также обучение и валидацию модели.

2.1.3 Методы очистки и нормализации данных

Обработка данных осуществлялась в несколько последовательных этапов, в совокупности обеспечивающих качество и согласованность входной информации:

Устранение пропусков. Наблюдения с критически неполными данными, а именно более 50% пропущенных признаков, были исключены из выборки. Оставшиеся пропуски в числовых признаках заменены медианными значениями соответствующих столбцов, что позволяет сохранить распределение признака и минимизировать влияние экстремальных значений. Для категориальных признаков пропущенные значения заменены на строковое значение "unknown".

Унификация типов данных. Идентификаторы столбцов приведены к нижнему регистру и очищены от избыточных пробельных символов. Числовые признаки преобразованы к типу `float64`, категориальные – к типу `string`.

Обработка выбросов. Произведена фильтрация статистических аномалий посредством ограничения значений в пределах физиологически и практически обоснованных диапазонов:

- возраст водителя: интервал [18; 80] лет;
- водительский стаж: интервал [0; 60] лет;
- мощность двигателя: интервал [60; 300] лошадиных сил;
- возраст транспортного средства: интервал [0; 30] лет;
- количество дней с последнего страхового случая: интервал [30; 1095] дней.

Кодирование категориальных признаков. Алгоритм CatBoost не требует явного кодирования категориальных признаков, что устраняет необходимость дополнительной предобработки и сохраняет семантику данных.

Категориальные признаки передаются в модель через параметр `cat_features`.

Генерация производных признаков. Для повышения предсказательной способности модели реализован алгоритм генерации производных признаков, отражающих нелинейные взаимодействия между исходными переменными (подробное описание приведено в подразделе 2.2).

Обработанный набор данных разделён на обучающую и тестовую выборки в соотношении 80% к 20% с применением стратификации по целевому признаку для сохранения баланса классов.

2.2 Определение факторов, влияющих на вероятность ДТП

Процесс прогнозирования страховых рисков требует комплексного подхода к селекции признаков, оказывающих статистически значимое влияние на вероятность наступления дорожно-транспортного происшествия. В рамках данного исследования факторы определены на основе анализа научной литературы, отраслевых практик и статистики аварийности, а также верифицированы эмпирическим путём в процессе построения модели.

2.2.1 Генерация производных признаков

Для улучшения предсказательной способности модели реализован алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между исходными переменными. В результате генерации были получены признаки, включающие в себя:

- **age_squared** – возраст водителя в квадрате, отражающий нелинейную зависимость риска от возрастной категории;
- **experience_ratio** – отношение водительского стажа к возрасту, характеризующее долю жизни, проведённую за управлением транспортным средством;
- **claims_per_year** – количество страховых обращений в год, нормализованное по стажу вождения;
- **violations_per_year** – количество нарушений правил дорожного движения в год, нормализованное по стажу вождения;
- **no_claims_long** – бинарный признак длительной безаварийной езды, а именно стаж ≥ 5 лет без страховых обращений;
- **experienced_clean** – бинарный признак опытного аккуратного водителя, под которым подразумевается стаж ≥ 10 лет, без страховых обращений и нарушений;
- **young_risky** – бинарный признак молодого рискованного водителя, включающий в себя такие факторы, как возраст < 26 лет, а так же наличие нарушений;
- **high_claims** – бинарный признак частых страховых обращений, а именно количество обращений ≥ 2 ;
- **night_x_trips** – произведение доли ночных поездок на количество поездок в неделю;
- **power_x_age** – произведение мощности двигателя на возраст транспортного средства.

Данные признаки позволяют модели учитывать сложные взаимосвязи между факторами риска без необходимости явного задания аналитических зависимостей.

2.3 Разработка модели прогнозирования аварийности

Процесс разработки модели прогнозирования аварийности основан на методах машинного обучения, в частности – на использовании алгоритма CatBoost как одного из наиболее подходящих для работы с табличными данными, содержащими как числовые, так и категориальные признаки.

2.3.1 Архитектурная структура модели

Разработанная модель машинного обучения инкапсулирована в объектно-ориентированный программный класс `InsuranceRiskModel`, который объединяет ключевые этапы работы: предобработку данных, обучение, прогноз вероятности и расчет тарифа.

Архитектура системы, представленная на рисунке 2.1, демонстрирует модульную структуру с четким разделением ответственности между компонентами. Система принимает входные данные из трех источников: CSV-датасета для обучения, веб-формы Flask для интерактивного взаимодействия с пользователем и телематических данных OBD для учета стиля вождения.

Центральным элементом разработанной архитектуры, обеспечивающим целостность и согласованность всех вычислительных процессов, является объектно-ориентированный программный класс `InsuranceRiskModel`, содержащий пять основных методов: `preprocess()` для предобработки данных, `train()` для обучения модели, `predict_proba()` для прогнозирования вероятности ДТП, `calculate_adjusted_kbm()` для расчета адаптивного коэффициента бонус-малус и `save_model()` для сериализации обученной модели.

Модульная структура включает три взаимосвязанных компонента. Модуль предобработки данных выполняет обработку пропущенных значений, клиппинг выбросов, генерацию производных признаков и кодирование категориальных переменных. Модель CatBoost Classifier с параметрами 1500 деревьев, глубиной 5 и скоростью обучения 0.03 загружается из бинарного файла формата `.cbm`. Модуль расчета КБМ трансформирует предсказанную вероятность риска в коэффициент

бонус-малус по формуле $KBM = base_kbm \times (1 + \beta \times (P_{risk} - P_{avg}))$ с ограничением диапазона $[0.46; 3.92]$.

Результаты работы модулей передаются в модуль прогнозирования, который возвращает вероятность наступления страхового случая $P(DTP)$, и далее в веб-интерфейс для визуализации результатов и предоставления пользователю финального тарифа.




Рис. 2.1 – Архитектурная схема системы прогнозирования страховых рисков на основе класса `InsuranceRiskModel`, отображающая потоки данных между модулями предобработки, обучения, прогнозирования и расчета тарифа

Такая модульная архитектура обеспечивает переиспользуемость кода, независимость компонентов от конкретного набора данных и удобство интеграции в прикладные системы страхования. Основные компоненты архитектуры:

- **Модуль предобработки данных** – очистка, нормализация, генерация признаков;
- **Модуль обучения модели** – инициализация CatBoostClassifier, подбор гиперпараметров, обучение с валидацией;
- **Модуль прогнозирования** – загрузка обученной модели, получение вероятности наступления страхового случая;
- **Модуль расчета тарифа** – трансформация вероятности в финансовый показатель через формулу динамического коэффициента бонус-малус;
- **Веб-интерфейс** – взаимодействие с пользователем через Flask-приложение.

2.3.2 Этапы построения модели

Разработка модели прогнозирования страховых рисков осуществлялась в рамках строго регламентированного процесса машинного обучения, включающего шесть последовательных этапов. Каждый этап сопровождался верификацией результатов и документированием принятых решений для обеспечения воспроизводимости исследования.

1. Выделение целевой переменной.

На первоначальном этапе была определена целевая переменная (**target**), представляющая собой бинарный индикатор факта наступления страхового случая. Формально целевая переменная описывается следующим образом:

$$y_i = \begin{cases} 1, & \text{если зафиксирован страховой случай (ДТП),} \\ 0, & \text{если страховой случай отсутствовал.} \end{cases}$$

Данная формулировка соответствует постановке задачи бинарной классификации, где модель обучается предсказывать вероятность принадлежности наблюдения к положительному классу ($y = 1$). Выбор бинарной целевой переменной обусловлен природой задачи страхования: страховую компанию интересует

факт наступления события, влекущего выплату, а не его тяжесть или стоимость на этапе первичной оценки риска.

Модель классификации направлена на прогнозирование условной вероятности $P(y = 1 \mid \mathbf{x})$, где $\mathbf{x}$ – вектор признаков страхователя. Полученная вероятность используется для расчета индивидуального страхового тарифа.

2. Формирование обучающей выборки.

На этапе формирования обучающей выборки исходный набор данных был разделён на три непересекающихся подмножества: обучающую выборку, валидационную выборку и тестовую выборку. Разделение производилось в соотношении 60%/20%/20% соответственно.

Для сохранения распределения целевого признака во всех подвыборках применялся метод стратификации:

$$P(y = 1 \mid X_{\text{train}}) \approx P(y = 1 \mid X_{\text{val}}) \approx P(y = 1 \mid X_{\text{test}}).$$

Стратификация критически важна в условиях дисбаланса классов, характерного для страховых данных, где количество страховых случаев существенно превышает количество безаварийных периодов.

Категориальные признаки не подвергались явному кодированию, а передавались в алгоритм CatBoost через параметр `cat_features`. Это позволило сохранить семантику категориальных переменных и избежать проклятия размерности, связанного с ростом пространства признаков при одном кодировании.

3. Инициализация и настройка алгоритма.

Для обучения модели использован класс `CatBoostClassifier` библиотеки CatBoost версии 1.2. Выбор данного алгоритма обоснован в разделе 2.4.1. Гиперпараметры модели подбирались в процессе предварительных экспериментов с использованием сеточного поиска и кросс-валидации. Итоговая конфигурация представлена ниже:

- `iterations = 1500` – количество деревьев в ансамбле. Большое число итераций обеспечивает высокую ёмкость модели и способность выявлять сложные закономерности;
- `learning_rate = 0.03` – скорость обучения (шаг градиентного спуска). Малое значение позволяет модели сходиться более плавно и снижает риск переобучения;

- `depth = 5` – максимальная глубина деревьев. Ограничение глубины контролирует сложность базовых классификаторов и предотвращает запоминание шума в данных;
- `eval_metric = 'AUC'` – метрика для ранней остановки. Площадь под ROC-кривой выбрана как устойчивая к дисбалансу классов метрика качества;
- `early_stopping_rounds = 100` – количество итераций без улучшения метрики на валидационной выборке для остановки обучения. Механизм ранней остановки предотвращает переобучение;
- `random_seed = 42` – фиксация генератора случайных чисел для обеспечения воспроизводимости результатов;
- `class_weights = 'balanced'` – автоматическая балансировка классов. Веса классов вычисляются по формуле:

$$w_k = \frac{N}{K \cdot N_k},$$

где N – общее число наблюдений, K – количество классов, N_k – число объектов класса k .

4. Обработка признаков внутри модели.

Алгоритм CatBoost реализует автоматическую обработку категориальных признаков посредством метода статистического сглаживания (Target-based Encoding). Для каждой категории c признака вычисляется кодированное значение:

$$\hat{x}_c = \frac{\sum_{i=1}^n \mathbb{I}(x_i = c) \cdot y_i + \alpha \cdot P}{\sum_{i=1}^n \mathbb{I}(x_i = c) + \alpha},$$

где α – параметр сглаживания, P – априорная вероятность положительного класса. Данный подход позволяет преобразовывать категории в числовые значения с учётом целевой переменной, минимизируя риск переобучения.

Дополнительно CatBoost применяет метод Ordered Boosting, который, в свою очередь, использует перестановки обучающей выборки для расчёта градиентов. Это устраняет смещение предсказаний и повышает обобщающую способность модели на новых данных. Пример реализации обработки признаков и обучения модели представлен в Приложении В.

5. Подбор оптимального порога классификации.

По умолчанию алгоритмы классификации используют порог $\theta = 0.5$ для бинарного решения: $\hat{y} = \mathbb{I}[P(y = 1 | \mathbf{x}) \geq \theta]$. Однако в задачах страхования критически важно минимизировать количество ложноотрицательных срабатываний (невыявленных рисков), что требует смещения порога в сторону большей чувствительности.

Подбор оптимального порога осуществлялся путём перебора значений $\theta \in [0.05; 0.5]$ с шагом 0.01. Для каждого значения порога вычислялись метрики Precision, Recall и F1-score на валидационной выборке. Оптимальный порог определялся как:

$$\theta^* = \arg \max_{\theta'} F1_{\theta'} \quad \text{при условии} \quad \text{Recall}_{\theta'} \geq 0.6.$$

Ограничение на Recall обусловлено тем фактом, что модель должна выявлять не менее 60% реальных страховых случаев. Итоговое значение порога составило $\theta^* = 0.30$, что обеспечивает баланс между точностью и полнотой прогнозов при соблюдении заданного ограничения. Результаты экспериментального подбора порога классификации, демонстрирующие зависимость метрик Precision, Recall и F1-score от значения θ , визуализированы в Приложении Г.

6. Сохранение обученной модели.

После завершения обучения и верификации качества модель была сериализована и сохранена в бинарном формате `.cbm` — нативном формате CatBoost. Сериализация осуществлялась методом `save_model()`, реализующим эффективное сжатие структуры ансамбля и параметров деревьев; программная реализация данного этапа, включая настройку путей сохранения и обработку исключений, представлена в листинге Приложения Д.

Данный формат обеспечивает компактное хранение структуры ансамбля и параметров деревьев, быструю загрузку модели без необходимости повторного обучения, возможность развёртывания модели в производственной среде без зависимостей от обучающего фреймворка.

Сохранённая модель впоследствии интегрируется в веб-приложение через класс `InsuranceRiskModel`, обеспечивая получение прогнозов в реальном времени при обработке запросов пользователей.

2.3.3 Анализ важности признаков

По завершении обучения модели и проведения валидации был выполнен этап интерпретации результатов посредством оценки значимости входных переменных. Анализ проводился с использованием встроенного механизма алгоритма CatBoost, который рассчитывает вклад каждого признака в снижение функции потерь на всех узлах разбиения деревьев ансамбля. Данный подход позволяет количественно оценить влияние каждого фактора на итоговый прогноз вероятности ДТП.

Визуализация результатов анализа в виде ранжированной горизонтальной столбчатой диаграммы представлена в Приложении Е. График демонстрирует распределение весов признаков, отсортированных по убыванию их информативности.

Детальный анализ полученной диаграммы позволяет выделить следующие ключевые закономерности:

1. **Доминирование внешних и поведенческих факторов.** Вопреки традиционным актуарным моделям, для которых история обращений часто является главным предиктором, в разработанной модели наибольший вклад вносят признаки, описывающие условия эксплуатации и стиль вождения. Лидером по значимости стал признак `pct_days_with_rain` (доля дней с осадками), что подтверждает критическое влияние погодных условий на безопасность дорожного движения. Высокие веса также зафиксированы для телематических признаков: `night_driving_ratio` (доля ночных поездок) и `avg_trips_per_week` (средняя частота поездок). Это свидетельствует о том, что интенсивность использования автомобиля и время суток являются более сильными индикаторами риска, чем статические демографические данные.
2. **Значимость технических характеристик.** Признак `engine_power` и производный признак `power_x_age` (взаимодействие мощности и возраста авто) вошли в список наиболее важных факторов. Это коррелирует с гипотезой о том, что мощные транспортные средства, особенно в сочетании с определенным возрастом, чаще эксплуатируются в агрессивном стиле или привлекают специфический контингент водителей, что повышает вероятность аварийности.

3. **Влияние истории рисков.** Признак `days_since_last_claim` (время, прошедшее с последнего страхового случая) занимает высокое место в рейтинге, подтверждая важность временного фактора в оценке текущего риска. В то же время, классические признаки `driver_age` (возраст водителя) и `driver_experience` (стаж) имеют меньший вес по сравнению с поведенческими метриками. Это указывает на то, что сам по себе возраст не является определяющим фактором: молодой водитель с аккуратным стилем вождения может быть менее рискованным, чем опытный водитель, часто едущий ночью в дождь.
4. **Эффективность генерации признаков.** Наличие в верхней части графика производных признаков, таких как `experience_ratio` (отношение стажа к возрасту) и `claims_per_year`, подтверждает целесообразность этапа Feature Engineering. Модель успешно использует эти синтетические переменные для выявления нелинейных зависимостей, которые трудно уловить при использовании только исходных данных.

Полученная структура важности признаков демонстрирует высокую степень согласованности с современной теорией безопасности дорожного движения и результатами телематических исследований. Тот факт, что модель самостоятельно выделила погодные условия и паттерны вождения как ключевые драйверы риска, validates корректность выбора архитектуры и состава входных данных. Данные результаты обосновывают переход от статических тарифов к динамическому ценообразованию, учитывающему реальные условия эксплуатации транспортного средства.

2.4 Тестирование модели и анализ результатов

Финальный этап исследования посвящен комплексной верификации разработанной системы прогнозирования страховых рисков и динамического расчета тарифов. Экспериментальная часть включала многоуровневое тестирование на отложенной выборке и серии синтетических сценариев, имитирующих различные профили водителей от низкорисковых до агрессивно управляющих транспортом. Результаты подтвердили высокую предсказательную способность модели CatBoost, которая продемонстрировала устойчивость к дисбалансу классов и корректное ранжирование страхователей согласно уровню их индивидуальной опас-

ности. Ключевым аспектом проверки стала оценка логики работы гибридного калькулятора коэффициента бонус-малус. Анализ сценариев выявил строго монотонную зависимость итогового тарифа от прогнозируемой вероятности ДТП: для аккуратных, не склонных к созданию аварийных ситуаций, водителей система обоснованно снижала коэффициент относительно базового значения, тогда как для групп высокого риска фиксировалось его закономерное повышение. Дополнительно была исследована чувствительность алгоритма к интеграции телематических данных, где наличие файлов бортовой диагностики с информацией о стиле вождения и технических неисправностях вносило предсказуемые корректировки в итоговую стоимость полиса. Обобщенные итоги экспериментов свидетельствуют о полной функциональной готовности комплекса, обеспечивающего прозрачное и математически обоснованное персонализированное ценообразование.

2.4.1 Метрики оценки качества и результаты тестирования

Для комплексной оценки качества разработанной модели в рамках данного исследования использована система метрик бинарной классификации, адаптированная под специфику задачи прогнозирования страховых рисков. Учитывая критическую важность минимизации ложноотрицательных срабатываний (невявленных аварий), приоритетным показателем выступила метрика полноты (Recall), дополненная показателями точности (Precision), гармонического среднего F1-score и интегральной характеристики разделяющей способности модели ROC-AUC.

Результаты тестирования модели на отложенной выборке продемонстрировали высокие показатели качества, подтверждающие эффективность выбранного подхода. Значение метрики Ассигасу составило 0.9675, что свидетельствует о корректной классификации подавляющего большинства наблюдений. При этом показатель Recall достиг значения 0.9970, указывая на способность модели выявлять практически все реальные страховые случаи, что является критически важным для страховой компании с точки зрения управления рисками. Метрика Precision составила 0.9563, подтверждая низкий уровень ложных срабатываний на благонадежных клиентах. Интегральный показатель F1-score, балансирующий между полнотой и точностью, достиг значения 0.9762, а площадь под ROC-кривой (AUC) составила 0.9919, что характеризует модель как обладающую превосходной способностью к разделению классов низкого и высокого риска.

Визуализация результатов классификации представлена в приложениях к

работе. Матрица ошибок (Приложение Ж) наглядно демонстрирует распределение истинно положительных, истинно отрицательных, ложноположительных и ложноотрицательных прогнозов, подтверждая доминирование корректных предсказаний в общей структуре результатов. ROC-кривая (Приложение З) иллюстрирует зависимость между долей верно предсказанных положительных случаев и долей ошибочно классифицированных отрицательных при варьировании порога отсечения, а высокая площадь под кривой ($AUC = 0.9919$) подтверждает устойчивость модели к выбору конкретного порога классификации. В том же приложении представлен блок с детальными значениями всех метрик, зафиксированных в ходе экспериментальной проверки.

Анализ важности признаков, выполненный посредством встроенного механизма алгоритма CatBoost, позволил ранжировать входные переменные по степени их влияния на итоговый прогноз. Результаты данного анализа, визуализированные в виде горизонтальной столбчатой диаграммы в Приложении И, показали, что наибольший вклад в предсказание вероятности ДТП вносят история страховых обращений, поведенческие характеристики вождения, возраст и стаж водителя, а также региональные и погодные условия. Полученная структура важности согласуется с отраслевой статистикой и подтверждает, что модель обучается интерпретируемым закономерностям, а не просто запоминает шумовые паттерны в данных.

2.4.2 Анализ зависимости тарифов от ключевых факторов риска

В рамках экспериментальной проверки была проведена серия визуальных исследований, направленных на анализ взаимосвязи между отдельными признаками и рассчитанным страховым тарифом. Для каждого из пяти наиболее значимых факторов построены графики зависимости итоговой стоимости полиса от значения признака при фиксированных значениях остальных переменных.

Анализ влияния возраста водителя выявил выраженную нелинейную зависимость: молодые страхователи в возрастной категории 18–30 лет характеризуются максимальными значениями тарифа, что соответствует статистике повышенной аварийности данной группы. Начиная с возраста 35 лет, наблюдается устойчивое снижение стоимости полиса, достигающее минимума для водителей средней возрастной группы. Влияние водительского стажа демонстрирует монотонную отрицательную корреляцию: увеличение опыта вождения последовательно

снижает прогнозируемый риск и, соответственно, итоговый тариф, причём наиболее существенное снижение фиксируется при переходе от стажа менее 5 лет к стажу свыше 10 лет.

Зависимость тарифа от количества исторических страховых обращений носит прямой характер: каждый дополнительный случай в прошлом ведёт к пропорциональному увеличению прогнозируемой вероятности будущего ДТП и соответствующей корректировке коэффициента бонус-малус. Влияние возраста транспортного средства оказалось более сложным: минимальные значения тарифа наблюдаются для автомобилей возрастом 5–6 лет, тогда как как новые, так и старые транспортные средства ассоциируются с повышенным риском, что может объясняться сочетанием факторов стоимости ремонта и частоты технических неисправностей. Наконец, анализ интегрального индекса аварийности подтвердил экспоненциальный характер зависимости: даже незначительный рост данного показателя ведёт к существенному увеличению итогового тарифа, что обеспечивает адекватное ценовое сигнализирование для высокорисковых профилей.

2.4.3 Интерпретация результатов и практическая значимость

Проведённый комплекс экспериментов подтвердил, что разработанный алгоритм прогнозирования страховых рисков обладает высокой чувствительностью к ключевым факторам, отражающим поведенческие особенности водителя, технические параметры транспортного средства и условия эксплуатации. Все выявленные закономерности демонстрируют интуитивно понятную и статистически обоснованную связь с уровнем риска, что критически важно для доверия со стороны бизнес-пользователей и регулятора.

Особое внимание заслуживает механизм динамического расчёта страхового тарифа, напрямую трансформирующий прогнозируемую моделью вероятность ДТП в финансовый показатель через формулу адаптивного коэффициента бонус-малус. Благодаря этому тариф формируется не на основе усреднённых категорий или жёстких фиксированных коэффициентов, а с учётом индивидуального уровня риска конкретного страхователя. Такой подход обеспечивает персонализированное ценообразование, позволяющее снизить уровень перекрёстного субсидирования между низко- и высокорисковыми клиентами, повысить точность оценки рисков и оптимизировать тарифную политику страховой компании.

Полученные метрики качества ($\text{Accuracy} = 0.9675$, $\text{Recall} = 0.9970$, AUC

= 0.9919) свидетельствуют о готовности модели к практическому внедрению в производственную среду. Высокая полнота прогноза гарантирует минимизацию необоснованных выплат, а превосходная разделяющая способность (ROC-AUC) обеспечивает надёжную сегментацию клиентской базы для дифференцированной тарифной политики. Разработанная система демонстрирует потенциал для масштабирования и может служить основой для дальнейшего развития в направлении телематического страхования и динамического ценообразования в реальном времени.

2.5 Реализация веб-интерфейса

Для обеспечения практической применимости разработанной модели и создания удобного инструмента взаимодействия с конечным пользователем осуществлена реализация веб-интерфейса, выступающего в качестве точки доступа к вычислительным алгоритмам системы. В данной подразделе обзревается полный цикл проектирования и разработки пользовательского интерфейса, который включает в себя поэтапные шаги реализации: от создания прототипа и обоснования UX/UI-решений до программной реализации клиент-серверной архитектуры и интеграции графической оболочки с модулем машинного обучения.

2.5.1 Проектирование пользовательского интерфейса и прототипирование

Непосредственная разработка пользовательского интерфейса веб-приложения осуществлялась в среде Figma и включала несколько последовательно идущих за собой этапов: формирование дизайн-концепции, создание дизайн-системы, прототипирование ключевых экранов и финальную визуализацию. Особое внимание уделялось обеспечению интуитивной понятности интерфейса, минимизации когнитивной нагрузки на пользователя при вводе большого объема параметров, а также созданию визуальной иерархии, направляющей пользователя от ввода данных к получению результата.

Основой визуального стиля приложения стала строго выверенная цветовая палитра, построенная на градиентных переходах темно-зеленых и изумрудных оттенков (Приложение К). Выбор данной цветовой гаммы обусловлен несколькими факторами: во-первых, зеленый цвет ассоциируется с финансовой сферой,

безопасностью и доверием, что критически важно для приложения, в основе которого лежит работа со страховыми данными; во-вторых, темный фон с градиентными акцентами обеспечивает комфортное восприятие информации при длительной работе и снижает нагрузку на глаза; в-третьих, контрастность выбранных оттенков гарантирует соответствие стандартам доступности. Дополнительный акцентный цвет (ярко-зеленый) используется для выделения ключевых элементов взаимодействия – кнопок призыва к действию, итоговых значений тарифов и положительных результатов расчета.

Центральным элементом пользовательского опыта является главная страница приложения (Приложение Л), выполняющая функцию точки входа и навигационного хаба. Дизайн главной страницы построен по принципу минимализма и фокусирует внимание пользователя на двух ключевых действиях: переходе к калькулятору и изучению документации.

Страница документации (Приложение М) решает задачу информирования пользователя о принципах работы системы и факторах, влияющих на формирование персонализированного тарифа. Структура страницы построена по модульному принципу и включает три смысловых блока. Каждый блок содержит лаконичное описание того, как соответствующие данные используются в алгоритме расчета, так же ниже на странице расположена визуализация в виде диаграммы Венна, демонстрирующая три ключевых преимущества системы. Такой подход к представлению информации позволяет пользователю быстро сформировать ментальную модель работы системы и понять ценность предоставляемых данных.

Форма ввода персональных данных водителя (Приложение Н) представляет собой наиболее функционально насыщенный интерфейс приложения. Дизайн формы продуман с точки зрения юзабилити и минимизации ошибок ввода: поля сгруппированы логически, каждое поле сопровождается понятной меткой и, при необходимости, примером заполнения. Для полей ввода дат реализованы календари с визуальным пикером, что исключает ошибки формата. Формы, в свою очередь разделены так же по группам и характеристикам вводимых данных. Валидация полей осуществляется в реальном времени с визуальной индикацией ошибок. Общий дизайн формы выдержан в фирменных цветах с достаточными отступами и визуальным разделением секций, что предотвращает когнитивную перегрузку пользователя при заполнении большого количества полей.

Страница результатов расчета (Приложение О) фокусируется на ясной и однозначной презентации итоговых значений. Центральным элементом является

блок с финальным тарифом ОСАГО, выделенный крупным шрифтом и акцентным цветом для немедленного привлечения внимания. Под стоимостью расположены коэффициенты: базовый и итоговый. Так же для обеспечения прозрачности расчета предусмотрены два выпадающих списка, детализирующие факторы, повлиявшие на корректировку базового тарифа. Так же предусмотрен функционал экспорта результатов реализован через кнопки, позволяющие пользователю сохранить расчет в удобном формате для дальнейшего анализа или предоставления в страховую компанию, и дополнительная ссылка, которая предоставляет возможность визуального сравнения индивидуального коэффициента со среднерыночным значением, что усиливает понимание пользователем своей позиции в общей выборке.

Прототипирование всех страниц веб-приложения осуществлялось с применением принципов адаптивного дизайна, обеспечивающих корректное отображение интерфейса на устройствах с различным разрешением экрана, включая десктопные компьютеры, планшетные устройства и мобильные телефоны. Данный подход к проектированию пользовательского интерфейса предполагает использование гибких сеток, относительных единиц измерения и медиа-запросов, что позволяет элементам интерфейса автоматически подстраиваться под размеры и ориентацию экрана без потери функциональности и визуальной привлекательности. Особое внимание в процессе прототипирования уделялось сохранению читаемости текстового контента, удобству навигации и доступности интерактивных элементов при использовании как мыши, так и сенсорного управления, что критически важно для обеспечения универсальности разработанного решения.

2.5.2 Архитектура веб-приложения и механизмы межкомпонентного взаимодействия

Общая структурная схема веб-приложения, отражающая навигационные связи между страницами и потоки данных между клиентом и сервером, представлена на рисунке 2.2.



Рис. 2.2 – Структурная схема веб-приложения с указанием навигационных связей и потоков данных

Архитектура разработанного веб-приложения построена на основе классической клиент-серверной модели с разделением ответственности между презентационным уровнем и вычислительным уровнем. Такая архитектура, в свою очередь, обеспечивает модульность системы, независимость компонентов и возможность горизонтального масштабирования. Взаимодействие между клиентской и серверной частями осуществляется по протоколу HTTP с использованием RESTful API, где клиент отправляет структурированные данные в формате JSON, а сервер возвращает результаты расчетов в аналогичном формате.

Презентационный уровень системы включает три основные страницы: главную страницу, страницу документации и страницу результатов расчета. Главная страница выполняет роль точки входа и навигационного хаба, предоставляя пользователю два ключевых маршрута: переход к калькулятору для выполнения расчета и переход к документации для изучения методологии системы. Навигация между страницами реализована через гипертекстовые ссылки и формы, что обеспечивает совместимость со всеми современными браузерами без необходимости использования дополнительных клиентских фреймворков.

Страница калькулятора содержит форму ввода данных, структурированную в соответствии с признаковым пространством модели машинного обучения. Формы включают разделы для ввода персональных данных водителя, характеристик транспортного средства, региональных и погодных условий, а также истории страховых обращений и нарушений. Клиентская часть выполняет первичную валидацию входных данных, к которой относится проверка форматов, диапазонов значений, обязательности полей, реализованная с использованием встроенных механизмов HTML и JavaScript, что предотвращает отправку заведомо некорректных запросов на сервер и снижает нагрузку на вычислительный уровень.

Серверная часть приложения реализована на основе микрофреймворка Flask, который обеспечивает легковесность, высокую производительность и гибкость маршрутизации HTTP-запросов. При старте сервера в память загружается сериализованная модель CatBoost в формате .cbm, что исключает необходимость повторной инициализации при каждом запросе и сокращает время отклика системы. Серверный модуль включает три последовательных этапа обработки запроса: валидацию данных, предобработку признаков и инференс модели.

На этапе валидации сервер проверяет наличие всех обязательных полей, соответствие типов данных и попадание числовых значений в допустимые диапазоны. При обнаружении нарушений сервер возвращает клиенту HTTP-ответ с кодом 400 и детальным описанием ошибок, что позволяет интерфейсу отобразить соответствующие сообщения пользователю.

Этап предобработки реализует конвейер трансформации сырых входных данных в формат, совместимый с моделью CatBoost. Данный конвейер включает заполнение пропущенных значений медианами, клиппинг выбросов, генерацию производных признаков, а также кодирование категориальных переменных. Реализация предобработки на стороне сервера гарантирует идентичность трансформаций при обучении модели и её эксплуатации, что критически важно для

корректности прогнозов.

Этап инференса модели выполняет получение вероятности наступления страхового случая на основе предобработанных данных. Алгоритм CatBoost возвращает значение $P(y = 1 | x)$ - вероятность принадлежности наблюдения к классу «страховой случай». Данное значение передается в модуль расчета коэффициента бонус-малус, который трансформирует вероятность в финансовый показатель по формуле динамического ценообразования. Итоговый расчет включает применение базовой ставки тарифа, региональных коэффициентов и корректировок на основе прогноза модели.

Страница результатов отображает пользователю ключевые показатели расчета: итоговую стоимость полиса ОСАГО, рекомендуемый коэффициент бонус-малус, базовый коэффициент и вероятность ДТП в процентном выражении. Дополнительно реализован функционал экспорта результатов в форматах CSV и PDF, а также возможность скачивания графика сравнения индивидуального КБМ со среднерыночным значением.

Страница документации предоставляет пользователю подробную информацию о методологии системы, включая описание используемой модели машинного обучения, математические формулы расчета тарифа, перечень факторов риска и результаты анализа важности признаков. Данная страница выполняет образовательную функцию и повышает прозрачность системы, что критически важно для формирования доверия пользователей к алгоритмическому ценообразованию.

Механизмы межкомпонентного взаимодействия в системе реализованы через синхронные HTTP-запросы с использованием метода POST для отправки данных формы и метода GET для навигации между страницами. Передача данных осуществляется в формате JSON, что обеспечивает структурированность, читаемость и совместимость с различными клиентскими приложениями. Обработка ошибок на всех уровнях системы, таких как клиентская валидация, серверная валидация, ошибки модели, реализована с использованием стандартных HTTP-кодов состояния и детализированных сообщений, что обеспечивает надежную диагностику проблем и корректное поведение интерфейса в нештатных ситуациях.

Архитектурные решения, принятые при разработке веб-приложения, обеспечивают баланс между производительностью, масштабируемостью и удобством сопровождения кода. Модульная структура системы позволяет независимо модифицировать клиентскую и серверную части, а интеграция с моделью CatBoost через стандартный интерфейс гарантирует возможность замены или обновления

модели без изменений в бизнес-логике приложения.

2.5.3 Разработка серверной части и интеграция с моделью машинного обучения

Серверная часть веб-приложения реализована на основе микрофреймворка Flask, представляющего собой легковесный, удобный инструмент для создания веб-приложений. Выбор данного фреймворка обусловлен его минималистичной архитектурой, высокой производительностью при обработке HTTP-запросов, гибкой системой маршрутизации и широкой экосистемой расширений, что делает его оптимальным решением для интеграции моделей машинного обучения в веб-интерфейс. В отличие от более тяжелых полнофункциональных фреймворков, Flask предоставляет максимальный контроль над структурой приложения и позволяет инкапсулировать вычислительные алгоритмы без избыточной абстракции.

Архитектура серверного приложения, представленная на рисунке 2.3, демонстрирует модульную структуру с четким разделением ответственности между компонентами. В основе архитектуры лежит паттерн проектирования MVC (Model-View-Controller), где контроллером выступают маршруты Flask API, моделью – класс `HybridKBMCALCULATOR` с загруженным классификатором CatBoost, а представлением – механизмы сериализации данных в формат JSON для передачи клиенту. Программная реализация серверной части, включая инициализацию приложения, конфигурацию сессий, загрузку модели при старте сервера и вспомогательные функции валидации данных, приведена в Приложении II.

Инициализация серверного приложения осуществляется в момент запуска процесса, когда создается экземпляр класса `Flask`, конфигурируются параметры сессий пользователя и выполняется предварительная загрузка сериализованной модели машинного обучения. Критически важным архитектурным решением является однократная загрузка модели CatBoost из бинарного файла формата `.cbm` в оперативную память при старте сервера, а не при обработке каждого запроса. Такой подход исключает накладные расходы на десериализацию модели, которая может занимать от нескольких сотен миллисекунд до нескольких секунд, и обеспечивает стабильное время отклика системы на уровне 10 – 20 миллисекунд на запрос. Модель инкапсулируется в объекте класса `HybridKBMCALCULATOR`, который, в свою очередь, содержит обученный классификатор и все необходимые

методы конвейера обработки данных, что гарантирует атомарность операций прогнозирования и расчета тарифа.




Рис. 2.3 – Схема архитектуры серверной части веб-приложения, отображающая взаимодействие между маршрутами Flask API, модулем валидации данных, классом `InsuranceRiskModel` и загруженной моделью `CatBoost`

Маршрутизация HTTP-запросов реализована через систему декораторов, связывающих URL-адреса с соответствующими функциями-обработчиками. Приложение предоставляет четыре ключевых эндпоинта: корневой маршрут для главной страницы, маршрут документации, маршрут калькулятора, принимающий как GET-, так и POST-запросы, а также маршруты экспорта результатов в форматах PDF, CSV и графического изображения. Детальная реализация маршрутов серверного приложения, включая обработку корневых запросов, документации, двунаправленного маршрута калькулятора и функций экспорта, представлена в Приложении Р. Каждый маршрут реализует строго определенную функцию в пользовательском сценарии: корневой маршрут и маршрут документации обслуживаются методами GET и возвращают статические HTML-шаблоны, тогда как маршрут калькулятора реализует двунаправленную логику – при GET-запросе отображается форма ввода данных, а при POST-запросе выполняется полный конвейер обра-

ботки данных, прогнозирования и расчета тарифа с последующим рендерингом страницы результатов.

Ключевым элементом серверной логики является многоуровневый конвейер обработки данных, обеспечивающий трансформацию сырых входных параметров в персонализированный страховой тариф. Данный конвейер, блок-схема которого представлена на рисунке 2.4, включает пять последовательных этапов, каждый из которых выполняет строго определенную функцию в процессе прогнозирования риска.




Рис. 2.4 – Блок-схема серверного конвейера обработки запросов, отображающая последовательность этапов от валидации входных данных до формирования JSON-ответа с рассчитанным тарифом и коэффициентом бонус-малус

Обработка POST-запросов на маршруте калькулятора представляет собой

наиболее сложный вычислительный сценарий серверной части, программная реализация которого приведена в Приложении С. При получении запроса сервер извлекает данные из HTML-формы, включая персональные параметры водителя, характеристики транспортного средства, регион эксплуатации и опционально загруженный CSV-файл с телематическими данными бортовой диагностики. Извлеченные данные проходят многоуровневую валидацию: проверка типов и диапазонов значений, расчет производных параметров (возраста водителя на основе даты рождения, стажа вождения на основе даты выдачи удостоверения, базового коэффициента бонус-малус на основе истории страховых случаев), нормализация категориальных признаков. Вспомогательные функции валидации реализуют принцип безопасного приведения типов с заданными значениями по умолчанию и ограничением диапазонов, что предотвращает попадание некорректных данных в модель машинного обучения.

Первый этап конвейера – валидация входных данных, которая выполняет проверку корректности и полноты переданных параметров. На данном этапе осуществляется верификация типов данных, а именно числовые, строковые, категориальные, проверка попадания значений в физиологически обоснованные диапазоны, а также контроль наличия всех обязательных полей. При обнаружении нарушений валидации сервер немедленно возвращает клиенту HTTP-ответ с кодом состояния 400 и детализированным описанием ошибок, что позволяет интерфейсу отобразить соответствующие сообщения пользователю без выполнения избыточных вычислений.

Вторым этапом выступает предобработка данных, который, в свою очередь, реализует конвейер трансформации, идентичный тому, что применялся при обучении модели. Данный механизм критически важен для обеспечения согласованности между этапами обучения и эксплуатации: любые расхождения в способах обработки данных приведут к деградации качества прогнозов. Конвейер предобработки включает заполнение пропущенных значений медианами соответствующих признаков, клиппинг статистических выбросов, нормализацию числовых переменных и приведение категориальных признаков к стандартному виду.

Третьим этапом выступает генерация производных признаков, выполняющая создание новых переменных на основе исходных данных, отражающих нелинейные взаимодействия между факторами риска. Алгоритм генерирует признаки `age_squared`, `experience_ratio`, `claims_per_year` (количество обращений в год), `violations_per_year` (количество нарушений в год), а также

бинарные индикаторы `young_risky`, `high_claims`, `no_claims_long`. Использование данных признаков позволяет модели CatBoost выявлять сложные закономерности, которые не могут быть обнаружены при анализе исходных переменных по отдельности.

Четвертый этап представляет собой инференс модели машинного обучения, который представляет собой наиболее вычислительно емкую операцию конвейера. На данном этапе предобработанные и обогащенные признаки передаются в метод `predict_proba()` класса `InsuranceRiskModel`, который возвращает вероятность принадлежности наблюдения к положительному классу $P(y = 1 | x)$. Алгоритм CatBoost выполняет проход по ансамблю из 1500 деревьев глубины 5, агрегируя результаты каждого базового классификатора с учетом весовых коэффициентов. Несмотря на значительное количество деревьев, время выполнения прогноза не превышает 10–15 миллисекунд благодаря оптимизированной реализации CatBoost и заблаговременной загрузке модели в память.

Пятым этапом является непосредственный расчет финального тарифа и коэффициента бонус-малус, который трансформирует предсказанную вероятность риска в финансовый показатель, понятный пользователю. Модуль расчета КБМ применяет формулу динамического ценообразования $\text{КБМ} = \text{base_kbm} \times (1 + \beta \times (P_{\text{risk}} - P_{\text{avg}}))$, где коэффициент чувствительности $\beta = 1.5$ регулирует степень влияния прогнозируемого риска на итоговую стоимость полиса. Полученное значение ограничивается диапазоном $[0.46; 3.92]$ в соответствии с требованиями регулятора, после чего вычисляется итоговый тариф как произведение базовой ставки на рассчитанный коэффициент.

После успешной валидации и обработки данные трансформируются в структуру, совместимую с интерфейсом класса `InsuranceRiskModel`, и передаются в метод `calculate()`, который выполняет полный конвейер обработки: предобработку сырых признаков, генерацию производных переменных, инференс модели CatBoost для получения вероятности ДТП, расчет адаптивного коэффициента бонус-малус по формуле динамического ценообразования и формирование итогового тарифа. Результаты расчета сохраняются в серверной сессии пользователя, что обеспечивает доступность данных при последующих операциях экспорта, и передаются в HTML-шаблон страницы результатов для визуализации.

Интеграция с моделью машинного обучения реализована через объектно-ориентированный интерфейс, что обеспечивает строгое разделение ответственности между веб-сервером и вычислительным ядром. Flask-приложение не содер-

жит логики прогнозирования или расчета тарифа, а выступает исключительно в роли контроллера, координирующего потоки данных между клиентом и моделью. Такой подход позволяет независимо модифицировать модель машинного обучения, добавлять новые источники данных или изменять формулу ценообразования без внесения изменений в код веб-сервера, что критически важно для долгосрочной поддержки и развития системы.

Обработка ошибок реализована на всех уровнях серверного приложения с применением механизмов перехвата исключений и детализированного журналирования. Каждый маршрут обернут в блоки обработки исключений, перехватывающие потенциальные ошибки валидации входных данных, сбои файловой системы при загрузке телематических файлов, ошибки инференса модели и ошибки рендеринга шаблонов. В случае возникновения критической ошибки сервер возвращает клиенту HTTP-ответ с кодом состояния 500 и отображает страницу с техническими деталями ошибки в режиме отладки, что существенно упрощает диагностику проблем в процессе разработки и тестирования. В производственном режиме детали ошибки скрываются от пользователя, а полное трассирование стека вызовов записывается в журнал сервера для последующего анализа.

Функционал экспорта результатов расчета реализован через три специализированных маршрута, генерирующих выходные документы в форматах PDF, CSV и PNG, программная реализация которых представлена в Приложении Т. Маршрут экспорта в PDF использует библиотеку ReportLab для формирования стилизованного документа с таблицей результатов, оформленного в соответствии с фирменной цветовой палитрой приложения. Маршрут экспорта в CSV применяет стандартный модуль csv для создания структурированного текстового файла, совместимого с электронными таблицами и системами обработки данных. Маршрут экспорта графика использует библиотеку Matplotlib для визуализации сравнения индивидуального коэффициента бонус-малус пользователя со среднерыночным значением, что усиливает прозрачность расчета и помогает пользователю осознать свою позицию в общей выборке страхователей.

Завершающей стадией обработки является формирование JSON-ответа, которое осуществляет сериализацию результатов расчета в структурированный формат, включающий предсказанную вероятность ДТП, базовый и итоговый коэффициенты КБМ, финальную стоимость полиса, а также детализацию факторов, повлиявших на корректировку тарифа. Данный ответ передается клиенту с HTTP-кодом состояния 200, что сигнализирует об успешном завершении запроса.

Конфигурация серверного приложения включает механизмы управления пользовательскими сессиями на основе файлового хранилища, что обеспечивает сохранение результатов последнего расчета между запросами без необходимости использования базы данных. Такой подход упрощает развертывание приложения и снижает зависимости от внешних сервисов, сохраняя при этом полный функционал экспорта и анализа результатов.

Разработанная серверная архитектура демонстрирует высокую степень масштабируемости: модульная структура позволяет независимо модифицировать компоненты конвейера, заменять модель машинного обучения или добавлять новые источники данных без внесения изменений в бизнес-логику приложения. Инкапсуляция всех вычислительных процессов в рамках класса `InsuranceRiskModel` обеспечивает переиспользуемость кода и упрощает тестирование отдельных модулей системы.

2.5.4 Реализация клиентской части и механизмов визуализации данных

2.5.5 Пользовательские сценарии и функциональное тестирование интерфейса