



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Дальневосточный федеральный университет»
(ДВФУ)

**ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
(ШКОЛА)**

Департамент математического и компьютерного моделирования

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по образовательной программе подготовки бакалавров
по направлению 02.03.01 «Математика и компьютерные науки»
профиль « Сквозные цифровые технологии »

**Разработка модели прогнозирования страховых рисков в системе ОСАГО с
использованием гибридного подхода и телематических данных**

Работа защищена
с оценкой _____

Студент группы № Б9122-01.03.02мкт

(подпись) Винницкая Д.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

Регистрационный номер _____
« __ » _____ 20 __ г.

Руководитель _____
(должность, учёное звание)

(подпись) Кузнецов К.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

г. Владивосток

2026

Содержание

Аннотация	3
Введение	4
Термины, определения и сокращения	8
1 Анализ предметной области и существующих решений	11
1.1 Модели, используемые для расчета страховых тарифов	11
1.2 Методы машинного обучения в мировой практике страхования . .	12

АННОТАЦИЯ

Данная выпускная квалификационная работа посвящена разработке интеллектуальной системы прогнозирования страховых рисков и динамического расчета страховых тарифов в автостраховании на основе методов машинного обучения.

В ходе работы был проведен анализ традиционных методов, нацеленных на оценку рисков и обоснована необходимость перехода к вероятностной модели прогнозирования. В качестве основополагающего алгоритма был выбран CatBoost, который обеспечивает высокую точность в работе с категориальными признаками и гетерогенными данными. Разработана математическая модель бинарной классификации и формула динамического расчета коэффициента бонус-малус на основе предсказанной вероятности ДТП. Реализованы программные модули предобработки данных, обучения модели и расчета страхового тарифа с веб-интерфейсом, а тестирование модели метриками качества классификации подтвердило её предсказательную способность и чувствительность к ключевым факторам риска.

Разработанное решение может быть применено в сфере автострахования для внедрения персонализированного ценообразования, которое повысит точность оценки рисков и оптимизирует тарифную политику данной области.

ВВЕДЕНИЕ

В настоящее время, на фоне активной цифровизации и глобальной автоматизации финансовой отрасли и усиления конкурентной борьбы в сегменте автострахования, вопросы, касающиеся точного прогнозирования страховых рисков и научно обоснованного расчета тарифов, выходят на первый план, становясь определяющим фактором устойчивого развития и финансовой стабильности страховых организаций. В связи с ежегодным заключением договоров обязательного и добровольного страхования миллионами водителей, формируется постоянно растущий объем данных о страховых случаях, поведенческих факторах водителей, характеристиках транспортных средств, требующий детализированный, структурированный анализ для принятия взвешенных, обоснованных управленческих решений.

Формируется ряд фундаментальных проблем, вызванных тем, что существующие технологические решения в области актуарных расчетов в полной мере не удовлетворяют критериям и требованиям современного страхового рынка. Во-первых, наблюдается методологическая ограниченность традиционных подходов, а именно: страховые организации вынуждены использовать статические формулы с фиксированными коэффициентами, основанные на линейных зависимостях между признаками и уровнем риска. Такой процесс не учитывает нелинейный характер реальных взаимосвязей и приводит к искажению прогнозов, особенно при работе со сложными, неоднозначными профилями клиентов.

Во-вторых, традиционные бонус-малус системы и регрессионные модели не учитывают корреляцию между факторами риска, что приводит к упрощённой оценке и значительному снижению точности тарифов. Не менее важные данные, такие как стиль вождения, погодные условия, плотность трафика в населенном пункте и технические характеристики автомобиля, обычно не используются в полной мере, что ограничивает возможность персонализированной, точной оценки риска.

В-третьих, существующие методы не обладают способностью к динамической адаптации, а именно тарифы: пересматриваются редко и носят сугубо статичный характер, что, в свою очередь, не позволяет адаптироваться к изменяющимся поведенческим характеристикам водителя. Динамика улучшения или, наоборот, ухудшения стиля вождения не отражается на тарифе до следующего отчетного периода, а новые риски, связанные с изменениями в инфраструктуре или автомо-

бильных технологиях, учитываются с существенной, значимой задержкой. Таким образом, на данный момент на рынке отсутствует универсальная, адаптивная и технологически

Указанные обстоятельства обуславливают актуальность реализации модульной программной системы, которая обеспечивает полный цикл обработки страховых данных, используя алгоритмы градиентного бустинга и поддерживая идею персонализированного расчета тарифа.

Проблематика прогнозирования страховых рисков исследуется в работах как зарубежных, так и отечественных деятелей науки. Весомый вклад в развитие методов актуарного анализа внесли фундаментальные исследования в области теории риска, математической теории страхования и основ страховой математики. Современные подходы к оценке финансовых рисков рассмотрены в ряде работ, посвящённых моделированию неопределённости и управлению рисками в страховой сфере. Особое внимание в последние годы уделяется применению алгоритмов машинного обучения, в частности методов градиентного бустинга, таких как CatBoost, которые демонстрируют высокую эффективность при работе с гетерогенными данными, содержащими как числовые, так и категориальные признаки. В то же время вопросы проектирования интегрированных систем машинного обучения для автострахования, объединяющих алгоритмы классификации с механизмами динамического ценообразования и ориентированных на практическое внедрение в российские страховые компании, остаются недостаточно проработанными.

Цель работы — реализация интеллектуальной системы прогнозирования страховых рисков и расчета страхового тарифа в автостраховании на основе машинного обучения.

Для достижения поставленной цели необходимо решить комплекс взаимосвязанных **задач**:

1. провести анализ традиционных актуарных методов и систем бонус-малус для выявления их ограничений;
2. исследовать эффективность алгоритмов классификации и обосновать выбора модели CatBoost;
3. разработать методику предварительной обработки входных данных, включающую очистку выбросов, нормализацию числовых признаков и автоматическое кодирование категориальных переменных;

4. реализовать алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между возрастом водителя, стажем вождения и историей страховых обращений;
5. разработать программный модуль динамического расчета страхового тарифа, трансформирующий предсказанную вероятность риска в финансовый показатель с использованием коэффициента чувствительности;
6. разработать веб-интерфейс на базе Flask для взаимодействия с пользователем, обеспечивающий ввод параметров водителя и транспортного средства через форму и загрузку файлов;
7. разработать программный конвейер обработки данных, объединяющий этапы предобработки, загрузки обученной модели и получения прогноза в единый автоматизированный процесс;
8. оценить качества модели с использованием метрик accuracy, precision, recall и F1-меры.

Объектом исследования является процесс управления страховыми рисками в сфере автострахования.

Предметом исследования выступают математические методы и алгоритмы машинного обучения, направленные на прогнозирование вероятности наступления страховых случаев и расчет персонализированных страховых тарифов.

Методы исследования. В работе используются методы математической статистики и теории вероятностей для анализа данных и оценки рисков, алгоритмы машинного обучения с учителем, в частности градиентный бустинг на базе CatBoost, методы разведочного анализа данных для выявления корреляции между признаками, методы кросс-валидации для оценки обобщающей способности модели, метрики качества классификации для сравнительного анализа, а также методы визуализации данных для интерпретации результатов моделирования.

Практическая значимость работы определяется возможностью применения разработанной модели в реальных страховых компаниях для повышения точности оценки рисков, оптимизации тарифной политики и внедрения персонализированных страховых продуктов. Интеграция интеллектуальной системы прогнозирования позволит страховым компаниям сократить количество необоснованных выплат, повысить точность оценки профилей клиентов и усилить доверие

к страховой системе за счет более прозрачного, чуткого и справедливого ценообразования.

Структура работы. Выпускная квалификационная работа состоит из введения, трёх глав, заключения, списка литературы и приложений.

В первой главе проводится анализ предметной области автострахования: формализуется задача прогнозирования страховых рисков, выполняется обзор традиционных актуарных методов, систем бонус-малус и современных подходов на основе машинного обучения [prokhorenkova2018catboost], а также сравнительный анализ существующих программных решений. По результатам анализа обосновывается выбор алгоритма CatBoost для решения задачи бинарной классификации и формулируются требования к разрабатываемой системе.

Во второй главе описывается разработка прогнозной модели: этапы подготовки и предобработки данных, архитектурная структура модели, процесс обучения классификатора, тестирование метриками качества (accuracy, precision, recall, F1), а также реализация веб-интерфейса для динамического расчета страховых тарифов на основе предсказанной вероятности ДТП.

В третьей главе представлены перспективы внедрения системы: рассмотрены организационные и технические аспекты интеграции модели в практику страховых компаний, регуляторные требования Центрального банка РФ, возможности масштабирования и расширения признаков (телематические данные), а также оценка потенциального экономического эффекта от внедрения интеллектуального ценообразования.

ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ

Термины и определения

Актuariальные модели — это математические и статистические инструменты, используемые для оценки рисков, прогнозирования финансовых последствий неопределённостей, а также для расчёта страховых взносов, управления активами и обязательствами в различных сферах, прежде всего в страховании.

Бонус-малус система (БМС) — механизм индивидуализации страхового тарифа на основе страховой истории клиента, предусматривающий применение скидок (бонусов) за безаварийную езду и надбавок (малусов) за наличие страховых выплат; в работе рассматривается как традиционный метод, подлежащий оптимизации средствами машинного обучения.

Градиентный бустинг (Gradient Boosting) — ансамблевый алгоритм машинного обучения, основанный на последовательном построении композиции моделей, где каждая следующая модель обучается минимизировать ошибки предыдущих; в работе используется как основной метод прогнозирования вероятности ДТП.

Страховой риск — предполагаемое событие, обладающее признаками вероятности и случайности, при наступлении которого возникает обязательство страховщика произвести страховую выплату; в контексте работы: вероятность наступления дорожно-транспортного происшествия (ДТП).

Страховой тариф — цена страхового риска, выраженная в денежной сумме, относящаяся к единице страховой суммы или процентной доле от нее; в работе рассчитывается на основе прогнозной вероятности ДТП, полученной моделью машинного обучения.

Телематическое страхование (Usage-Based Insurance, UBI) — вид страхования, при котором страховой тариф формируется на основе данных о реальном поведении водителя (скорость, пробег, стиль вождения), фиксируемых специальными устройствами; рассматривается в работе как перспективное направление расширения признаков модели.

Переобучение (Overfitting) — ситуация в машинном обучении, при которой модель чрезмерно точно воспроизводит закономерности обучающей выборки, включая шум и выбросы, что приводит к снижению качества предсказаний на новых данных; для предотвращения используется метод Ordered Boosting в алго-

ритме CatBoost.

Важность признаков (Feature Importance) — метрика, оценивающая вклад каждого входного параметра в прогноз модели машинного обучения; используется в работе для интерпретации результатов и выявления ключевых факторов риска.

Метрики классификации — количественные показатели качества работы модели бинарной классификации; в работе используются Accuracy (точность), Precision (точность положительного класса), Recall (полнота), F1-score (гармоническое среднее) и ROC-AUC (площадь под ROC-кривой).

Конвейер обработки данных (Data Pipeline) — последовательность этапов обработки информации, включающая в себя сбор, очистку, нормализацию данных, обучение модели и получение прогноза; в работе реализован в виде программного класса InsuranceRiskModel.

Целевая переменная (Target) — бинарный индикатор факта дорожно-транспортного происшествия, соответствующий значению 1 при наличии страхового случая и 0 при его отсутствии; является объектом прогнозирования в задаче классификации.

Категориальный признак — переменная, которая принимает дискретный набор значений (например, тип автомобиля, регион, погодные условия); в работе обрабатывается алгоритмом CatBoost без предварительного кодирования.

Базовая ставка тарифа — минимальная стоимость страхового полиса, устанавливаемая страховой компанией для низкорисковых клиентов; служит основой для динамического расчета итогового тарифа.

Коэффициент чувствительности к риску — параметр, отвечающий за степень влияния прогнозируемой вероятности ДТП на итоговую стоимость страхового полиса; регулируется экспертно в зависимости от бизнес-политики страховщика.

Перечень сокращений

ОСАГО	Обязательное страхование гражданской ответственности владельцев транспортных средств
КАСКО	Комплексное автострахование, кроме ответственности (добровольное страхование транспортного средства от ущерба и угона)
ДТП	Дорожно-транспортное происшествие
ПДД	Правила дорожного движения
ЦБ РФ	Центральный банк Российской Федерации (регулятор страхового рынка)
ФАС	Федеральная антимонопольная служба
МЛ / ML	Machine Learning — машинное обучение
ИИ / AI	Artificial Intelligence — искусственный интеллект
EDA	Exploratory Data Analysis — разведочный анализ данных
CatBoost	Categorical Boosting — алгоритм градиентного бустинга
XGBoost	eXtreme Gradient Boosting — алгоритм градиентного бустинга
LightGBM	Light Gradient Boosting Machine — алгоритм градиентного бустинга
ROC-AUC	Receiver Operating Characteristic – Area Under Curve
F1-score	Гармоническое среднее между Precision и Recall
Precision	Доля правильно предсказанных положительных случаев
Recall	Доля правильно предсказанных случаев среди всех истинных
Accuracy	Доля правильно классифицированных объектов
UBI	Usage-Based Insurance — телематическое страхование
GAP	Guaranteed Asset Protection — страхование разницы стоимости
API	Application Programming Interface — программный интерфейс
CPU	Central Processing Unit — центральный процессор
GPU	Graphics Processing Unit — графический процессор
JSON	JavaScript Object Notation — формат обмена данными

1 Анализ предметной области и существующих решений

1.1 Модели, используемые для расчета страховых тарифов

В современных условиях автострахования выделяют несколько основополагающих подходов, применяемых для расчета страховых тарифов, каждый из которых основывается на специфических математических моделях оценки риска.

Традиционная модель ОСАГО применяет мультипликативную формулу:

$$R_{\text{ОСАГО}} = T_{\text{баз}} \times \prod K_i, \quad (1)$$

где итоговая стоимость определяется произведением базовой ставки на набор фиксированных коэффициентов, что создает ограничения из-за предположения о линейной независимости факторов риска.

Модели КАСКО, в свою очередь, оперируют аддитивным принципом расчета ожидаемых убытков, выражаемым формулой:

$$S_{\text{КАСКО}} = P_{\text{ДТП}} \times C_{\text{ремонт}} + P_{\text{угон}} \times C_{\text{выпл}} + C_{\text{админ}}, \quad (2)$$

где вероятность наступления страхового случая оценивается с помощью алгоритмов классификации, таких как логистическая регрессия:

$$P(y = 1) = \frac{1}{1 + e^{-z}} \quad (3)$$

или градиентный бустинг.

Наиболее прогрессивным направлением является телематическое страхование (Usage-Based Insurance, UBI), применяющее динамическую формулу:

$$S_{\text{UBI}} = T_{\text{баз}} \times K_{\text{пробег}} \times K_{\text{стиль}} \times K_{\text{время}}, \quad (4)$$

которая позволяет в реальном времени подстраивать тариф под фактическое поведение водителя, фиксируемое датчиками.

Тем не менее, широкое применение телематических моделей ограничено потребностью в масштабных массивах данных и необходимостью оснащения автомобилей специализированным оборудованием, в то время как алгоритмы машинного обучения в рамках КАСКО уже продемонстрировали высокую результативность при обнаружении скрытых нелинейных взаимосвязей между параметрами.

1.2 Методы машинного обучения в мировой практике страхования

В международной практике страхования наблюдается устойчивая тенденция к применению различных алгоритмов машинного обучения, предназначенных для решения задач прогнозирования рисков, каждый из которых имеет свою математическую основу и специфическую область практического применения.

Ансамблевые методы на основе деревьев решений, в частности алгоритм Random Forest, характеризуются высокой устойчивостью к переобучению и способностью выявлять нелинейные закономерности в данных. Математическая формализация модели случайного леса представляет собой ансамбль из M решающих деревьев, где итоговый прогноз формируется посредством усреднения предсказаний отдельных деревьев:

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x) \quad (5)$$

где $T_m(x)$ — прогноз m -го дерева для входного вектора признаков x . Для задач бинарной классификации применяется голосование большинством:

$$\hat{y} = \operatorname{argmax}_k \sum_{m=1}^M \mathbb{I}(T_m(x) = k) \quad (6)$$

Данный подход обеспечивает снижение дисперсии модели за счёт декорреляции отдельных деревьев через бутстрэппинг и случайный выбор признаков.

Алгоритмы градиентного бустинга, такие как XGBoost и LightGBM, проявили себя как эффективные инструменты, подходящие для задач бинарной классификации, обеспечивая, в свою очередь, высокую точность предсказаний при работе с табличными данными. Принцип работы основывается на поэтапном построении ансамбля деревьев, в котором каждое новое дерево обучается минимизировать остатки предыдущих:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x) \quad (7)$$

где $F_t(x)$ — прогноз на шаге t , η — скорость обучения, $h_t(x)$ — новое дерево, обученное на градиентах функции потерь. XGBoost использует регуляризованный обьектив:

$$\mathcal{L} = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (8)$$

где $\Omega(f_k)$ — штраф за сложность дерева, который предотвращает переобучение.

Архитектуры глубокого обучения и искусственные нейронные сети эффективно применяются для решения задач высокой сложности, требующих обработки неструктурированных данных. В частности, данные методы используются в области компьютерного зрения для автоматизированной оценки ущерба транспортных средств после дорожно-транспортных происшествий, а также в задачах обработки естественного языка для семантического анализа текстовой документации страховых заявлений. Архитектуры глубокого обучения обеспечивают аппроксимацию высокосложных нелинейных зависимостей в высокоразмерных пространствах признаков посредством иерархической композиции нелинейных преобразований:

$$a^{[l]} = \sigma(W^{[l]}a^{[l-1]} + b^{[l]}) \quad (9)$$

где $a^{[l]}$ — активации l -го слоя, $W^{[l]}$ — матрица весов, $b^{[l]}$ — вектор смещений, σ — функция активации. Тем не менее такие модели требуют значительных вычислительных ресурсов и больших размеченных выборок для обучения.

Методы кластеризации, такие как K-means и DBSCAN, используются для сегментации клиентов по уровню риска, что позволяет страховым компаниям разрабатывать дифференцированные тарифные планы. Алгоритм K-means минимизирует внутрикластерную дисперсию:

$$J = \sum_{j=1}^K \sum_{i=1}^N \mathbb{I}(x_i \in C_j) \|x_i - \mu_j\|^2 \quad (10)$$

где μ_j — центроид кластера C_j . Методы снижения размерности, включая РСА, применяются для визуализации многомерных данных и ускорения обучения моделей. Метод главных компонент (РСА) находит ортогональные направления максимальной дисперсии:

$$\max_w w^T \Sigma w \quad \text{при условии} \quad \|w\| = 1 \quad (11)$$

где Σ — ковариационная матрица признаков.

В области телематического страхования повсеместно применяются методы обучения с подкреплением для задач динамического ценообразования, в которых модель обучается выбирать оптимальные тарифы, получая обратную связь от системы. Данный процесс формализуется через марковский процесс принятия решений (MDP), в котором агент максимизирует ожидаемую награду:

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (12)$$

где π — политика выбора действий, R — функция награды, γ — коэффициент дисконтирования.

Современные исследования также демонстрируют хорошие показатели эффективности внедрения ансамблевых методов, которые комбинируют несколько алгоритмов в целях повышения точности прогнозов. Стекинг объединяет предсказания базовых моделей через мета-обучение:

$$\hat{y} = g(h_1(x), h_2(x), \dots, h_k(x)) \quad (13)$$

где g — мета-модель, обученная на выходах базовых алгоритмов h_i . Данный подход предоставляет возможность компенсировать индивидуальные слабости отдельных моделей и достигать более стабильных результатов, что подтверждает целесообразность использования интеллектуальных алгоритмов в современном страховании.