



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Дальневосточный федеральный университет»
(ДВФУ)

**ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
(ШКОЛА)**

Департамент математического и компьютерного моделирования

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по образовательной программе подготовки бакалавров
по направлению 02.03.01 «Математика и компьютерные науки»
профиль « Сквозные цифровые технологии »

**Разработка модели прогнозирования страховых рисков в системе ОСАГО с
использованием гибридного подхода и телематических данных**

Работа защищена
с оценкой _____

Студент группы № Б9122-01.03.02мкт

(подпись) Винницкая Д.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

Регистрационный номер _____
« __ » _____ 20 __ г.

Руководитель _____
(должность, учёное звание)

(подпись) Кузнецов К.С.
(Ф.И.О.)

« __ » _____ 20 __ г.

г. Владивосток

2026

Содержание

Аннотация	4
Введение	5
Термины, определения и сокращения	9
1 Анализ предметной области и существующих решений	12
1.1 Модели, используемые для расчета страховых тарифов	12
1.2 Методы машинного обучения в мировой практике страхования . .	13
1.3 Особенности российской практики страхования и система бонус- малус	15
1.4 Математическое обоснование необходимости применения методов машинного обучения	17
1.5 Методы машинного обучения в данной работе	19
1.6 Выводы по главе	21
2 Разработка прогнозной модели страховых рисков на основе машинно- го обучения	23
2.1 Описание данных и их подготовка	23
2.1.1 Источники данных	23
2.1.2 Структура признаков	24
2.1.3 Методы очистки и нормализации данных	27
2.2 Определение факторов, влияющих на вероятность ДТП	28
2.2.1 Генерация производных признаков	29
2.3 Разработка модели прогнозирования аварийности	30
2.3.1 Архитектурная структура модели	30
2.3.2 Этапы построения модели	31
2.3.3 Анализ важности признаков	34
2.4 Тестирование модели и анализ результатов	36
2.4.1 Метрики оценки качества и результаты тестирования	36
2.4.2 Анализ зависимости тарифов от ключевых факторов риска	38
2.4.3 Интерпретация результатов и практическая значимость . .	39
2.5 Реализация веб-интерфейса	39

2.5.1	Архитектура веб-приложения	40
2.5.2	Функциональные возможности	40
2.5.3	Пример расчета тарифа	40
2.6	Выводы по главе	41

АННОТАЦИЯ

Данная выпускная квалификационная работа посвящена разработке интеллектуальной системы прогнозирования страховых рисков и динамического расчета страховых тарифов в автостраховании на основе методов машинного обучения.

В ходе работы был проведен анализ традиционных методов, нацеленных на оценку рисков и обоснована необходимость перехода к вероятностной модели прогнозирования. В качестве основополагающего алгоритма был выбран CatBoost, который обеспечивает высокую точность в работе с категориальными признаками и гетерогенными данными. Разработана математическая модель бинарной классификации и формула динамического расчета коэффициента бонус-малус на основе предсказанной вероятности ДТП. Реализованы программные модули предобработки данных, обучения модели и расчета страхового тарифа с веб-интерфейсом, а тестирование модели метриками качества классификации подтвердило её предсказательную способность и чувствительность к ключевым факторам риска.

Разработанное решение может быть применено в сфере автострахования для внедрения персонализированного ценообразования, которое повысит точность оценки рисков и оптимизирует тарифную политику данной области.

ВВЕДЕНИЕ

В настоящее время, на фоне активной цифровизации и глобальной автоматизации финансовой отрасли и усиления конкурентной борьбы в сегменте автострахования, вопросы, касающиеся точного прогнозирования страховых рисков и научно обоснованного расчета тарифов, выходят на первый план, становясь определяющим фактором устойчивого развития и финансовой стабильности страховых организаций. В связи с ежегодным заключением договоров обязательного и добровольного страхования миллионами водителей, формируется постоянно растущий объем данных о страховых случаях, поведенческих факторах водителей, характеристиках транспортных средств, требующий детализированный, структурированный анализ для принятия взвешенных, обоснованных управленческих решений.

Формируется ряд фундаментальных проблем, вызванных тем, что существующие технологические решения в области актуарных расчетов в полной мере не удовлетворяют критериям и требованиям современного страхового рынка. Во-первых, наблюдается методологическая ограниченность традиционных подходов, а именно: страховые организации вынуждены использовать статические формулы с фиксированными коэффициентами, основанные на линейных зависимостях между признаками и уровнем риска. Такой процесс не учитывает нелинейный характер реальных взаимосвязей и приводит к искажению прогнозов, особенно при работе со сложными, неоднозначными профилями клиентов.

Во-вторых, традиционные бонус-малус системы и регрессионные модели не учитывают корреляцию между факторами риска, что приводит к упрощённой оценке и значительному снижению точности тарифов. Не менее важные данные, такие как стиль вождения, погодные условия, плотность трафика в населенном пункте и технические характеристики автомобиля, обычно не используются в полной мере, что ограничивает возможность персонализированной, точной оценки риска.

В-третьих, существующие методы не обладают способностью к динамической адаптации, а именно тарифы: пересматриваются редко и носят сугубо статичный характер, что, в свою очередь, не позволяет адаптироваться к изменяющимся поведенческим характеристикам водителя. Динамика улучшения или, наоборот, ухудшения стиля вождения не отражается на тарифе до следующего отчетного периода, а новые риски, связанные с изменениями в инфраструктуре или автомо-

бильных технологиях, учитываются с существенной, значимой задержкой. Таким образом, на данный момент на рынке отсутствует универсальная, адаптивная и технологически

Указанные обстоятельства обуславливают актуальность реализации модульной программной системы, которая обеспечивает полный цикл обработки страховых данных, используя алгоритмы градиентного бустинга и поддерживая идею персонализированного расчета тарифа.

Проблематика прогнозирования страховых рисков исследуется в работах как зарубежных, так и отечественных деятелей науки. Весомый вклад в развитие методов актуарного анализа внесли фундаментальные исследования в области теории риска, математической теории страхования и основ страховой математики. Современные подходы к оценке финансовых рисков рассмотрены в ряде работ, посвящённых моделированию неопределённости и управлению рисками в страховой сфере. Особое внимание в последние годы уделяется применению алгоритмов машинного обучения, в частности методов градиентного бустинга, таких как CatBoost, которые демонстрируют высокую эффективность при работе с гетерогенными данными, содержащими как числовые, так и категориальные признаки. В то же время вопросы проектирования интегрированных систем машинного обучения для автострахования, объединяющих алгоритмы классификации с механизмами динамического ценообразования и ориентированных на практическое внедрение в российские страховые компании, остаются недостаточно проработанными.

Цель работы — реализация интеллектуальной системы прогнозирования страховых рисков и расчета страхового тарифа в автостраховании на основе машинного обучения.

Для достижения поставленной цели необходимо решить комплекс взаимосвязанных **задач**:

1. провести анализ традиционных актуарных методов и систем бонус-малус для выявления их ограничений;
2. исследовать эффективность алгоритмов классификации и обосновать выбора модели CatBoost;
3. разработать методику предварительной обработки входных данных, включающую очистку выбросов, нормализацию числовых признаков и автоматическое кодирование категориальных переменных;

4. реализовать алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между возрастом водителя, стажем вождения и историей страховых обращений;
5. разработать программный модуль динамического расчета страхового тарифа, трансформирующий предсказанную вероятность риска в финансовый показатель с использованием коэффициента чувствительности;
6. разработать веб-интерфейс на базе Flask для взаимодействия с пользователем, обеспечивающий ввод параметров водителя и транспортного средства через форму и загрузку файлов;
7. разработать программный конвейер обработки данных, объединяющий этапы предобработки, загрузки обученной модели и получения прогноза в единый автоматизированный процесс;
8. оценить качества модели с использованием метрик accuracy, precision, recall и F1-меры.

Объектом исследования является процесс управления страховыми рисками в сфере автострахования.

Предметом исследования выступают математические методы и алгоритмы машинного обучения, направленные на прогнозирование вероятности наступления страховых случаев и расчет персонализированных страховых тарифов.

Методы исследования. В работе используются методы математической статистики и теории вероятностей для анализа данных и оценки рисков, алгоритмы машинного обучения с учителем, в частности градиентный бустинг на базе CatBoost, методы разведочного анализа данных для выявления корреляции между признаками, методы кросс-валидации для оценки обобщающей способности модели, метрики качества классификации для сравнительного анализа, а также методы визуализации данных для интерпретации результатов моделирования.

Практическая значимость работы определяется возможностью применения разработанной модели в реальных страховых компаниях для повышения точности оценки рисков, оптимизации тарифной политики и внедрения персонализированных страховых продуктов. Интеграция интеллектуальной системы прогнозирования позволит страховым компаниям сократить количество необоснованных выплат, повысить точность оценки профилей клиентов и усилить доверие

к страховой системе за счет более прозрачного, чуткого и справедливого ценообразования.

Структура работы. Выпускная квалификационная работа состоит из введения, трёх глав, заключения, списка литературы и приложений.

В первой главе проводится анализ предметной области автострахования: формализуется задача прогнозирования страховых рисков, выполняется обзор традиционных актуарных методов, систем бонус-малус и современных подходов на основе машинного обучения [prokhorenkova2018catboost], а также сравнительный анализ существующих программных решений. По результатам анализа обосновывается выбор алгоритма CatBoost для решения задачи бинарной классификации и формулируются требования к разрабатываемой системе.

Во второй главе описывается разработка прогнозной модели: этапы подготовки и предобработки данных, архитектурная структура модели, процесс обучения классификатора, тестирование метриками качества (accuracy, precision, recall, F1), а также реализация веб-интерфейса для динамического расчета страховых тарифов на основе предсказанной вероятности ДТП.

ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ

Термины и определения

Актuarные модели — это математические и статистические инструменты, используемые для оценки рисков, прогнозирования финансовых последствий неопределённостей, а также для расчёта страховых взносов, управления активами и обязательствами в различных сферах, прежде всего в страховании.

Бонус-малус система (БМС) — механизм индивидуализации страхового тарифа на основе страховой истории клиента, предусматривающий применение скидок (бонусов) за безаварийную езду и надбавок (малусов) за наличие страховых выплат; в работе рассматривается как традиционный метод, подлежащий оптимизации средствами машинного обучения.

Градиентный бустинг (Gradient Boosting) — ансамблевый алгоритм машинного обучения, основанный на последовательном построении композиции моделей, где каждая следующая модель обучается минимизировать ошибки предыдущих; в работе используется как основной метод прогнозирования вероятности ДТП.

Страховой риск — предполагаемое событие, обладающее признаками вероятности и случайности, при наступлении которого возникает обязательство страховщика произвести страховую выплату; в контексте работы: вероятность наступления дорожно-транспортного происшествия (ДТП).

Страховой тариф — цена страхового риска, выраженная в денежной сумме, относящаяся к единице страховой суммы или процентной доле от нее; в работе рассчитывается на основе прогнозной вероятности ДТП, полученной моделью машинного обучения.

Телематическое страхование (Usage-Based Insurance, UBI) — вид страхования, при котором страховой тариф формируется на основе данных о реальном поведении водителя (скорость, пробег, стиль вождения), фиксируемых специальными устройствами; рассматривается в работе как перспективное направление расширения признаков модели.

Переобучение (Overfitting) — ситуация в машинном обучении, при которой модель чрезмерно точно воспроизводит закономерности обучающей выборки, включая шум и выбросы, что приводит к снижению качества предсказаний на новых данных; для предотвращения используется метод Ordered Boosting в алго-

ритме CatBoost.

Важность признаков (Feature Importance) — метрика, оценивающая вклад каждого входного параметра в прогноз модели машинного обучения; используется в работе для интерпретации результатов и выявления ключевых факторов риска.

Метрики классификации — количественные показатели качества работы модели бинарной классификации; в работе используются Accuracy (точность), Precision (точность положительного класса), Recall (полнота), F1-score (гармоническое среднее) и ROC-AUC (площадь под ROC-кривой).

Конвейер обработки данных (Data Pipeline) — последовательность этапов обработки информации, включающая в себя сбор, очистку, нормализацию данных, обучение модели и получение прогноза; в работе реализован в виде программного класса InsuranceRiskModel.

Целевая переменная (Target) — бинарный индикатор факта дорожно-транспортного происшествия, соответствующий значению 1 при наличии страхового случая и 0 при его отсутствии; является объектом прогнозирования в задаче классификации.

Категориальный признак — переменная, которая принимает дискретный набор значений (например, тип автомобиля, регион, погодные условия); в работе обрабатывается алгоритмом CatBoost без предварительного кодирования.

Базовая ставка тарифа — минимальная стоимость страхового полиса, устанавливаемая страховой компанией для низкорисковых клиентов; служит основой для динамического расчета итогового тарифа.

Коэффициент чувствительности к риску — параметр, отвечающий за степень влияния прогнозируемой вероятности ДТП на итоговую стоимость страхового полиса; регулируется экспертно в зависимости от бизнес-политики страховщика.

Перечень сокращений

ОСАГО	Обязательное страхование гражданской ответственности владельцев транспортных средств
КАСКО	Комплексное автострахование, кроме ответственности (добровольное страхование транспортного средства от ущерба и угона)
ДТП	Дорожно-транспортное происшествие
ПДД	Правила дорожного движения
ЦБ РФ	Центральный банк Российской Федерации (регулятор страхового рынка)
ФАС	Федеральная антимонопольная служба
МЛ / ML	Machine Learning — машинное обучение
ИИ / AI	Artificial Intelligence — искусственный интеллект
EDA	Exploratory Data Analysis — разведочный анализ данных
CatBoost	Categorical Boosting — алгоритм градиентного бустинга
XGBoost	eXtreme Gradient Boosting — алгоритм градиентного бустинга
LightGBM	Light Gradient Boosting Machine — алгоритм градиентного бустинга
ROC-AUC	Receiver Operating Characteristic – Area Under Curve
F1-score	Гармоническое среднее между Precision и Recall
Precision	Доля правильно предсказанных положительных случаев
Recall	Доля правильно предсказанных случаев среди всех истинных
Accuracy	Доля правильно классифицированных объектов
UBI	Usage-Based Insurance — телематическое страхование
GAP	Guaranteed Asset Protection — страхование разницы стоимости
API	Application Programming Interface — программный интерфейс
CPU	Central Processing Unit — центральный процессор
GPU	Graphics Processing Unit — графический процессор
JSON	JavaScript Object Notation — формат обмена данными

1 Анализ предметной области и существующих решений

1.1 Модели, используемые для расчета страховых тарифов

В современных условиях автострахования выделяют несколько основополагающих подходов, применяемых для расчета страховых тарифов, каждый из которых основывается на специфических математических моделях оценки риска.

Традиционная модель ОСАГО применяет мультипликативную формулу:

$$P_{\text{ОСАГО}} = T_{\text{баз}} \times \prod K_i,$$

где итоговая стоимость определяется произведением базовой ставки на набор фиксированных коэффициентов, что создает ограничения из-за предположения о линейной независимости факторов риска.

Модели КАСКО, в свою очередь, оперируют аддитивным принципом расчета ожидаемых убытков, выражаемым формулой:

$$P_{\text{КАСКО}} = P_{\text{ДТП}} \times C_{\text{ремонт}} + P_{\text{угон}} \times C_{\text{выпл}} + C_{\text{админ}},$$

где вероятность наступления страхового случая оценивается с помощью алгоритмов классификации, таких как логистическая регрессия:

$$P(y = 1) = \frac{1}{1 + e^{-z}}$$

или градиентный бустинг.

Наиболее прогрессивным направлением является телематическое страхование (Usage-Based Insurance, UBI), применяющее динамическую формулу:

$$S_{\text{UBI}} = T_{\text{баз}} \times K_{\text{пробег}} \times K_{\text{стиль}} \times K_{\text{время}},$$

которая позволяет в реальном времени подстраивать тариф под фактическое поведение водителя, фиксируемое датчиками.

Тем не менее, широкое применение телематических моделей ограничено потребностью в масштабных массивах данных и необходимостью оснащения автомобилей специализированным оборудованием, в то время как алгоритмы машинного обучения в рамках КАСКО уже продемонстрировали высокую результативность при обнаружении скрытых нелинейных взаимосвязей между параметрами.

1.2 Методы машинного обучения в мировой практике страхования

В международной практике страхования наблюдается устойчивая тенденция к применению различных алгоритмов машинного обучения, предназначенных для решения задач прогнозирования рисков, каждый из которых имеет свою математическую основу и специфическую область практического применения.

Ансамблевые методы на основе деревьев решений, в частности алгоритм Random Forest, характеризуются высокой устойчивостью к переобучению и способностью выявлять нелинейные закономерности в данных. Математическая формализация модели случайного леса представляет собой ансамбль из M решающих деревьев, где итоговый прогноз формируется посредством усреднения предсказаний отдельных деревьев:

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x)$$

где $T_m(x)$ – прогноз m -го дерева для входного вектора признаков x . Для задач бинарной классификации применяется голосование большинством:

$$\hat{y} = \operatorname{argmax}_k \sum_{m=1}^M \mathbb{I}(T_m(x) = k)$$

Данный подход обеспечивает снижение дисперсии модели за счёт декорреляции отдельных деревьев через бутстрэппинг и случайный выбор признаков.

Алгоритмы градиентного бустинга, такие как XGBoost и LightGBM, проявили себя как эффективные инструменты, подходящие для задач бинарной классификации, обеспечивая, в свою очередь, высокую точность предсказаний при работе с табличными данными. Принцип работы основывается на поэтапном построении ансамбля деревьев, в котором каждое новое дерево обучается минимизировать остатки предыдущих:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

где $F_t(x)$ – прогноз на шаге t , η – скорость обучения, $h_t(x)$ – новое дерево, обученное на градиентах функции потерь. XGBoost использует регуляризованный объектив:

$$\mathcal{L} = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

где $\Omega(f_k)$ – штраф за сложность дерева, который предотвращает переобучение.

Архитектуры глубокого обучения и искусственные нейронные сети эффективно применяются для решения задач высокой сложности, требующих обработки неструктурированных данных. В частности, данные методы используются в области компьютерного зрения для автоматизированной оценки ущерба транспортных средств после дорожно-транспортных происшествий, а также в задачах обработки естественного языка для семантического анализа текстовой документации страховых заявлений. Архитектуры глубокого обучения обеспечивают аппроксимацию высокосложных нелинейных зависимостей в высокоразмерных пространствах признаков посредством иерархической композиции нелинейных преобразований:

$$a^{[l]} = \sigma(W^{[l]}a^{[l-1]} + b^{[l]})$$

где $a^{[l]}$ – активации l -го слоя, $W^{[l]}$ – матрица весов, $b^{[l]}$ – вектор смещений, σ – функция активации. Тем не менее такие модели требуют значительных вычислительных ресурсов и больших размеченных выборок для обучения.

Методы кластеризации, такие как K-means и DBSCAN, используются для сегментации клиентов по уровню риска, что позволяет страховым компаниям разрабатывать дифференцированные тарифные планы. Алгоритм K-means минимизирует внутрикластерную дисперсию:

$$J = \sum_{j=1}^K \sum_{i=1}^N \mathbb{I}(x_i \in C_j) \|x_i - \mu_j\|^2$$

где μ_j – центроид кластера C_j . Методы снижения размерности, включая РСА, применяются для визуализации многомерных данных и ускорения обучения моделей. Метод главных компонент (РСА) находит ортогональные направления максимальной дисперсии:

$$\max_w w^T \Sigma w \quad \text{при условии} \quad \|w\| = 1$$

где Σ – ковариационная матрица признаков.

В области телематического страхования повсеместно применяются методы обучения с подкреплением для задач динамического ценообразования, в которых

модель обучается выбирать оптимальные тарифы, получая обратную связь от системы. Данный процесс формализуется через марковский процесс принятия решений (MDP), в котором агент максимизирует ожидаемую награду:

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right]$$

где π – политика выбора действий, R – функция награды, γ – коэффициент дисконтирования.

Современные исследования также демонстрируют хорошие показатели эффективности внедрения ансамблевых методов, которые комбинируют несколько алгоритмов в целях повышения точности прогнозов. Стекинг объединяет предсказания базовых моделей через мета-обучение:

$$\hat{y} = g(h_1(x), h_2(x), \dots, h_k(x))$$

где g – мета-модель, обученная на выходах базовых алгоритмов h_i . Данный подход предоставляет возможность компенсировать индивидуальные слабости отдельных моделей и достигать более стабильных результатов, что подтверждает целесообразность использования интеллектуальных алгоритмов в современном страховании.

1.3 Особенности российской практики страхования и система бонус-малус

Российскому рынку автострахования характерна высокая доля обязательного страхования гражданской ответственности, где тарифное регулирование осуществляется государством в лице Центрального банка Российской Федерации. Ключевым компонентом индивидуализации стоимости полиса в российской практике является система бонус-малус, которая представляет собой механизм поощрения безаварийной езды и наказания за страховые случаи.

Математически система КБМ может быть описана как дискретная марковская цепь с 15 классами страхования. Начальный класс для большей части водителей равен 3, что соответствует коэффициенту $K_{\text{БМС}} = 1,00$. Переход между классами осуществляется ежегодно в зависимости от количества страховых выплат N_{claims} :

$$K_{\text{БМС}}^{t+1} = f(K_{\text{БМС}}^t, N_{\text{claims}}),$$

где $K_{\text{БМС}}^t$ — коэффициент в текущем периоде, $K_{\text{БМС}}^{t+1}$ — коэффициент в следующем периоде. При отсутствии страховых случаев водитель переходит в класс с меньшим коэффициентом, достигая максимальной скидки в классе 13 ($K_{\text{БМС}} = 0,50$). При наличии выплат происходит понижение класса, что может увеличить коэффициент до 3,92.

Независимо от широкого распространения, традиционная система КБМ в Российской Федерации имеет ряд существенных ограничений:

1. Во-первых, она основывается на дискретных шагах, в которых не учитывается тяжесть страховых случаев: например, одна мелкая царапина и одно крупное ДТП с жертвами влияют на коэффициент одинаково.
2. Во-вторых, обновление данных происходит раз в год. Подобная периодичность не позволяет оперативно реагировать на изменения в стиле вождения.
3. В-третьих, система не учитывает дополнительные факторы риска, такие как погодные условия, плотность трафика в регионе эксплуатации или технические характеристики транспортного средства.

Формула расчета итоговой стоимости полиса ОСАГО в российской практике имеет вид:

$$P_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{тер}} \cdot K_{\text{БМС}} \cdot K_{\text{возр-стаж}} \cdot K_{\text{мощн}} \cdot K_{\text{сезон}},$$

где $T_{\text{баз}}$ — базовый тариф в рамках коридора, установленного регулятором. Данная мультипликативная модель предполагает независимость коэффициентов, что в реальности не всегда верно. Например, риск молодого водителя может существенно различаться в зависимости от региона, типа и состояния транспортного средства, но традиционная формула не учитывает подобные взаимодействия.

Описанные ограничения формируют предпосылки для внедрения более гибких методов оценки рисков. Интеграция алгоритмов машинного обучения позволяет перейти от дискретной системы классов к непрерывной оценке вероятности риска, учитывая при этом нелинейные зависимости и широкий спектр признаков и факторов, которые особенно актуальны в условиях цифровизации российского страхового рынка.

1.4 Математическое обоснование необходимости применения методов машинного обучения

Традиционные подходы к расчету страховых тарифов, рассмотренные в предыдущих разделах, имеют фундаментальные математические ограничения, значительно снижающие точность прогнозирования и оценки рисков в условиях современного страхового рынка. Мультипликативная модель ОСАГО, представленная формулой

$$P_{\text{ОСАГО}} = T_{\text{баз}} \cdot K_{\text{возр}} \cdot K_{\text{рег}} \cdot K_{\text{стаж}} \cdot K_{\text{БМС}} \cdot K_{\text{мощн}},$$

предполагает отсутствие корреляции между коэффициентами. Для реальной практики подобное упущение может стать критическим, создавая неточность в итоговой стоимости. Математически это означает, что совместное распределение признаков факторизуется как произведение маргинальных распределений:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i),$$

однако эмпирические данные отражают наличие существенных корреляций между факторами риска. Например, взаимодействие между возрастом водителя и регионом эксплуатации создает эффект, который не может быть адекватно описан произведением независимых коэффициентов, так как риск молодого водителя существенно различается в зависимости от плотности трафика в мегаполисе или сельской местности.

Кроме того, традиционные модели предполагают линейную или кусочно-линейную зависимость между признаками и уровнем риска. Функция риска в таких системах имеет вид

$$R(\mathbf{x}) = \sum_i \beta_i x_i,$$

где каждый признак вносит аддитивный вклад независимо от значений других признаков. Реальная зависимость вероятности ДТП от характеристик водителя и автомобиля носит нелинейный характер и может быть описана только сложной функцией

$$R(\mathbf{x}) = f(x_1, x_2, \dots, x_n),$$

где f — нелинейное отображение, учитывающее взаимодействия между признаками. Игнорирование перекрестных членов в модели приводит к тому, что сложные паттерны поведения, такие как сочетание агрессивного стиля вождения с эксплуатацией мощного автомобиля в зимний период, не выявляются и не тарифицируются корректно.

Система бонус-малус, представляющая собой дискретную марковскую цепь с конечным числом состояний, также имеет математические ограничения. Переход между классами определяется только количеством страховых случаев N_{claims} без учета тяжести ущерба, обстоятельств ДТП и других факторов. С точки зрения математической оценки это означает, что функция перехода между состояниями

$$\pi_{ij} = P(K_{t+1} = j \mid K_t = i)$$

зависит только от текущего класса и числа выплат, игнорируя остальную информацию о водителе. Такой подход приводит к потере информации и снижению точности оценки индивидуального риска, так как одна мелкая царапина и одно крупное ДТП с жертвами влияют на итоговый коэффициент одинаково. Кроме того, обновление данных происходит раз в год, что не позволяет оперативно реагировать на изменения в стиле вождения владельца транспортного средства.

Переход к вероятностной формулировке задачи позволяет преодолеть указанные ограничения. Вместо дискретных классов бонус-малус система рассматривает непрерывную вероятность страхового случая

$$P(y = 1 \mid \mathbf{x}) \in [0, 1],$$

где $\mathbf{x}$ — вектор признаков водителя и автомобиля. Это позволяет использовать весь спектр доступной информации и строить более точные прогнозы. Задача прогнозирования страховых рисков формулируется как задача бинарной классификации, где целевая переменная $y \in \{0, 1\}$ указывает на наличие или отсутствие страхового случая в течение периода страхования.

Математическая постановка задачи состоит в поиске оптимальной функции $f: \mathbb{R}^d \rightarrow [0, 1]$, минимизирующей математическое ожидание функции потерь

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} [L(y, f(x))]$$

на распределении данных $\mathcal{D}$. В случае бинарной классификации используется функция потерь бинарной кросс-энтропии

$$L(y, p) = -[y \log p + (1 - y) \log(1 - p)],$$

где $p = f(x)$ — предсказанная вероятность положительного класса. Минимизация этой функции потерь эквивалентна максимизации правдоподобия данных при условии Бернуллиевского распределения целевой переменной.

Преимущество машинного обучения перед традиционными методами заключается в способности автоматически выявлять сложные нелинейные зависимости и взаимодействия между признаками без необходимости их явного задания аналитически. Ансамблевые методы, такие как градиентный бустинг, аппроксимируют целевую функцию через сумму базовых функций

$$f(x) = \sum_{m=1}^M \alpha_m h_m(x),$$

где каждая h_m — простое дерево решений, а коэффициенты α_m подбираются в процессе обучения. Такая модель способна аппроксимировать произвольную непрерывную функцию с любой заданной точностью при достаточном числе базовых функций, что обеспечивает высокую гибкость и точность прогнозов.

Таким образом, теоретическое обоснование необходимости применения методов машинного обучения сводится к неспособности традиционных линейных и мультипликативных моделей достоверно описывать сложные нелинейные зависимости между факторами риска и вероятностью страхового случая. Переход к вероятностной постановке задачи классификации с использованием гибких нелинейных моделей позволит повысить точность прогнозирования, обеспечить персонализацию тарифов и снизить уровень перекрестного субсидирования между клиентами с различным уровнем риска.

1.5 Методы машинного обучения в данной работе

В рамках настоящего исследования рассматривается задача построения предиктивной модели f , оценивающей вероятность наступления страхового случая. Пусть $\mathcal{D} = \{1, \dots, N\}$ — множество клиентов, где каждому i -му клиенту соответствует вектор признаков $\mathbf{x}_i \in \mathbb{R}^d$, включающий персональные, технические, категориальные данные и информацию о стиле вождения. Цель исследования заключается в построении отображения $f: \mathbb{R}^d \rightarrow [0, 1]$, оценивающего вероятность страхового случая $y_i \in \{0, 1\}$ путём оптимизации функции потерь $L(f)$ на выборке $(X_{\text{train}}, Y_{\text{train}})$ и интеграции прогноза $P(y_i = 1 \mid \mathbf{x}_i)$ в систему расчёта коэффициента бонус-малус.

В качестве основного алгоритма выбран CatBoost, разработанный компанией Яндекс. Выбор данного метода обусловлен рядом преимуществ, критически важных для решения задачи прогнозирования страховых рисков. Алгоритм специализируется на работе с категориальными признаками, автоматически обрабатывая их без необходимости предварительного кодирования. Данная особенность особенно актуальна при наличии таких признаков, как тип автомобиля, регион эксплуатации, погодные условия и тип дорожной инфраструктуры.

Модель CatBoost обучается на функции потерь бинарной кросс-энтропии:

$$L(f) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(f(\mathbf{x}_i)) + (1 - y_i) \log(1 - f(\mathbf{x}_i)) \right]$$

с применением взвешивания классов для компенсации дисбаланса выборки, характерного для страховых данных, в которых количество аварий существенно ниже количества безаварийных случаев. Алгоритм CatBoost реализует метод Ordered Boosting, обеспечивающий высокую устойчивость к переобучению на малых и средних выборках, что критично в случае страховых данных. Встроенные механизмы регуляризации и предобработки категорий позволяют модели демонстрировать стабильные результаты без необходимости сложной инженерной подготовки признаков.

После обучения модель возвращает вероятность $P(y_i = 1 \mid \mathbf{x}_i)$. Бинарный прогноз формируется по пороговой функции

$$\hat{y}_i = \mathbb{I} \left[P(y_i = 1 \mid \mathbf{x}_i) \geq \theta \right],$$

где порог подбирается для максимизации метрики F1 при условии $\text{Recall} \geq \tau$:

$$\theta^* = \arg \max_{\theta'} F1_{\theta'} \quad \text{при условии} \quad \text{Recall}_{\theta'} \geq \tau.$$

Метрика F1 вычисляется как гармоническое среднее точности и полноты:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}},$$

где Recall — доля правильно предсказанных положительных случаев среди всех истинно положительных, Precision — доля правильно предсказанных положительных случаев среди всех предсказанных положительных, а F1 отражает баланс между точностью и полнотой.

Итоговый коэффициент бонус-малус вычисляется по формуле:

$$\text{КБМ}_{\text{итог}} = \text{КБМ}_{\text{базовый}} \cdot (1 + \beta \cdot (P_{\text{risk}} - P_{\text{avg}})),$$

где $P_{\text{risk}} = f(\mathbf{x}_i)$ — предсказанная моделью вероятность, P_{avg} — средняя вероятность по выборке, $\beta > 0$ — коэффициент чувствительности. Данная формула представляет собой линейную аппроксимацию влияния ML-модели на традиционный КБМ, позволяющую динамически адаптировать тариф под индивидуальный риск водителя.

В качестве базовой модели для сравнительного анализа также используется логистическая регрессия, которая, несмотря на простоту, служит отправной точкой для оценки эффективности более сложных алгоритмов. Логистическая регрессия обеспечивает высокую интерпретируемость результатов и позволяет оценить вклад каждого признака в уровень риска.

1.6 Выводы по главе

Проведённый в первой главе анализ предметной области и существующих методов оценки страховых рисков позволил выявить фундаментальные ограничения, характерные для традиционных подходов. Установлен факт, подтверждающий, что классические актуарные модели и мультипликативные формулы расчёта тарифов, применяемые в ОСАГО и КАСКО, базируются на предположении о линейной независимости факторов, что в корне не соответствует реальной структуре данных и приводит к снижению точности прогнозирования. Сравнительный анализ методов машинного обучения продемонстрировал эффективность ансамблевых алгоритмов, в частности градиентного бустинга, в задачах бинарной классификации на гетерогенных данных, содержащих как числовые, так и категориальные признаки.

Обоснован выбор алгоритма CatBoost в качестве основного инструмента прогнозирования благодаря его способности работать с категориальными признаками без предварительного кодирования, устойчивости к переобучению на малых выборках и высокой интерпретируемости результатов. Математическое обоснование необходимости перехода к вероятностной формулировке задачи подтвердило целесообразность использования функции потерь бинарной кросс-энтропии для оценки индивидуального риска, что позволяет преодолеть ограничения дискретных систем бонус-малус и обеспечить непрерывную оценку вероятности ДТП.

Результаты теоретического исследования создают необходимую базу для практической реализации модели. Во второй главе будет произведена подготовка данных, обучение модели CatBoost, тестирование её качества на метриках клас-

сификации, а также разработка программного алгоритма динамического расчёта страхового тарифа на основе предсказанной вероятности. Для обеспечения визуального удобства оценки результатов и интерактивной демонстрации работы алгоритма будет реализован веб-интерфейс, позволяющий вводить параметры водителя и транспортного средства, загружать наборы данных и наглядно отображать прогнозы с детализацией ключевых показателей. Это позволит перейти от теоретического обоснования к созданию полнофункционального прототипа системы интеллектуального страхования.

2 Разработка прогнозной модели страховых рисков на основе машинного обучения

В данной главе осуществляется описание процесса разработки, обучения и верификации модели прогнозирования страховых рисков. Рассматриваются этапы подготовки и нормализации данных, архитектурная структура разработанной системы, процедура обучения классификатора на базе алгоритма CatBoost, реализация веб-интерфейса, необходимого для интерактивного взаимодействия с моделью, а также результаты экспериментального тестирования и последующего анализа качества модели.

2.1 Описание данных и их подготовка

2.1.1 Источники данных

Для реализации модели прогнозирования страховых рисков в работе использовались два независимых набора данных, различающихся по природе, структуре и целевому назначению.

Основной синтетический датасет для обучения классификационной модели, а именно CatBoostClassifier, был сформирован методом агрегации и нормализации открытых источников. Структура и распределения признаков имитируют поведение клиентов страховой компании и основаны на обобщённой информации из:

- публичных баз данных по дорожно-транспортным происшествиям (Госавтоинспекция РФ, открытые датасеты платформы Kaggle по автострахованию);
- агрегированной статистики страховых выплат и историй обращений российских страховых компаний;
- климатических справочников и сведений о дорожных условиях, характерных для различных субъектов Российской Федерации;
- методических рекомендаций и актуарных отчётов Центрального банка РФ по тарификации ОСАГО.

Используемый набор данных структурирован в табличном формате, где каждая строка представляет собой одно наблюдение (страховой случай или период страхования), а каждый столбец соответствует отдельному признаку, потенциально влияющему на вероятность наступления страхового события. Общий объём выборки составил 10 000 наблюдений, что обеспечивает статистическую значимость результатов обучения модели при сохранении баланса классов.

Датасет телематических данных использовался для верификации гипотезы о влиянии поведенческих факторов вождения на вероятность ДТП и потенциального расширения признаков модели. В качестве источника выступил набор данных *Levin Vehicle Telematics*, содержащий анонимизированные показатели стиля вождения, зафиксированные телематическими устройствами: скорость, ускорение, резкость торможения, время суток поездок и геолокационные метки. Данный датасет позволил провести корреляционный анализ между поведенческими паттернами и частотой страховых случаев, а также обосновать включение производных признаков (`night_driving_ratio`, `avg_trips_per_week`) в финальную структуру модели.

Оба набора данных прошли процедуру предварительной обработки, которая включала в себя удаление повторяющихся строк и значений, нормализацию форматов и согласование семантики признаков, что обеспечило их совместимость в рамках единого конвейера машинного обучения.

2.1.2 Структура признаков

Окончательная структура данных включает количественные и категориальные признаки, выбранные на основе многофакторного анализа предметной области и верифицированные на информативность посредством предварительного обучения модели `CatBoostClassifier`. Селекция признаков осуществлялась с учётом следующих критериев:

- статистическая значимость корреляции с целевой переменной, под которой подразумевается коэффициент корреляции Пирсона $|r| > 0.1$;
- отсутствие мультиколлинеарности между признаками (коэффициент вариации инфляции $VIF < 5$);
- практическая интерпретируемость с точки зрения страховой методологии;

- доступность данных для сбора в реальных условиях страхования.

Все признаки, в свою очередь, классифицированы на следующие логические группы:

Персональные данные водителя:

- **driver_age** - возраст водителя в годах (числовой, интервал [18; 80]). Согласно статистике ГИБДД, водители возрастных категорий 18-25 лет и 65+ лет демонстрируют повышенную аварийность вследствие недостатка опыта и возрастных изменений когнитивных функций соответственно;
- **driver_experience** - водительский стаж в годах (числовой, интервал [0; 60]). Стаж вождения является одним из ключевых предикторов риска, используемых в традиционных актуарных моделях и бонус-малус системах;
- **occupation_type** - тип занятости (категориальный: офисный работник, студент, пенсионер, фрилансер, профессиональный водитель, владелец бизнеса). Род деятельности влияет на частоту и интенсивность использования транспортного средства, а также на стиль и характер вождения;
- **num_claims** - количество страховых обращений в прошлом (числовой, интервал [0; 10]). История страховых случаев является одним из наиболее значимых предикторов будущей аварийности, что подтверждается актуарной практикой;
- **violation_count** – количество нарушений правил дорожного движения (числовой, интервал [0; 20]). Нарушения ПДД коррелируют с агрессивным стилем вождения и повышенным риском ДТП;
- **days_since_last_claim** – количество дней с момента последнего страхового случая (числовой, интервал [30; 1095]). Временной промежуток с последнего страхового случая отражает динамику изменения риска во времени;
- **avg_trips_per_week** – среднее количество поездок в неделю (числовой, интервал [1; 50]). Частота использования транспортного средства прямо пропорциональна вероятности наступления страхового события;

- **night_driving_ratio** – доля поездок в ночное время (числовой, интервал [0; 1]). Ночные поездки статистически связаны с повышенной аварийностью из-за ограниченной видимости и усталости водителя.

Характеристики транспортного средства:

- **vehicle_age** – возраст транспортного средства в годах (числовой, интервал [0; 30]). Возраст автомобиля влияет на частоту технических неисправностей и стоимость восстановительного ремонта;
- **vehicle_type** – тип транспортного средства (категориальный: седан, хэтчбек, внедорожник, грузовик, фургон). Различные типы ТС имеют разную статистику аварийности и стоимость ремонта;
- **engine_power** – мощность двигателя в лошадиных силах (числовой, интервал [60; 300]). Мощность двигателя коррелирует с динамическими характеристиками автомобиля и стилем вождения владельца;
- **vehicle_purpose** – целевое назначение использования транспортного средства (категориальный: личное, коммерческое, такси, доставка). Коммерческое использование увеличивает пробег и время эксплуатации, повышая риск;
- **num_owned_vehicles** – количество транспортных средств в собственности (числовой, интервал [1; 5]). Количество автомобилей в собственности может отражать финансовое положение и опыт владельца.

Внешние и региональные факторы:

- **region** – регион эксплуатации транспортного средства (категориальный: субъекты РФ). Региональные различия в плотности трафика, дорожной инфраструктуре и климатических условиях существенно влияют на аварийность;
- **pct_days_with_snow** – доля дней со снегом в календарном году (числовой, интервал [0; 1]). Зимние погодные условия увеличивают вероятность ДТП из-за скользкого дорожного покрытия;
- **pct_days_with_rain** – доля дней с осадками в календарном году (числовой, интервал [0; 1]). Дождь снижает видимость и сцепление шин с дорогой, повышая риск аварий;

- `winter_duration_months` – продолжительность зимнего периода в месяцах (числовой, интервал $[0; 12]$). Длительность зимнего сезона влияет на совокупное воздействие неблагоприятных погодных условий.

Базовые страховые коэффициенты:

- `base_kbm` – базовый коэффициент бонус-малус (числовой, интервал $[0.46; 3.92]$). Традиционный коэффициент, используемый в системе ОСАГО для индивидуализации тарифа;
- `ko_multiplier` – коэффициент ограниченного использования транспортного средства (числовой, интервал $[1.0; 1.8]$). Учитывает количество водителей, допущенных к управлению транспортным средством.

Целевой признак:

- `target` – бинарный индикатор факта наступления страхового случая (1 – страховой случай произошёл, 0 – не произошёл). Бинарная постановка задачи соответствует природе страхового события и упрощает интерпретацию результатов модели.

Полный перечень признаков с указанием типов данных, диапазонов значений и семантического описания представлен в таблице формата, приведённого в Приложении А. Дополнительно Приложении Б представлен фрагмент исходного кода, иллюстрирующий процесс генерации и предобработки признаков, а также обучение и валидацию модели.

2.1.3 Методы очистки и нормализации данных

Обработка данных осуществлялась в несколько последовательных этапов, в совокупности обеспечивающих качество и согласованность входной информации:

Устранение пропусков. Наблюдения с критически неполными данными, а именно более 50% пропущенных признаков, были исключены из выборки. Оставшиеся пропуски в числовых признаках заменены медианными значениями соответствующих столбцов, что позволяет сохранить распределение признака и минимизировать влияние экстремальных значений. Для категориальных признаков пропущенные значения заменены на строковое значение "unknown".

Унификация типов данных. Идентификаторы столбцов приведены к нижнему регистру и очищены от избыточных пробельных символов. Числовые признаки преобразованы к типу `float64`, категориальные – к типу `string`.

Обработка выбросов. Произведена фильтрация статистических аномалий посредством ограничения значений в пределах физиологически и практически обоснованных диапазонов:

- возраст водителя: интервал [18; 80] лет;
- водительский стаж: интервал [0; 60] лет;
- мощность двигателя: интервал [60; 300] лошадиных сил;
- возраст транспортного средства: интервал [0; 30] лет;
- количество дней с последнего страхового случая: интервал [30; 1095] дней.

Кодирование категориальных признаков. Алгоритм CatBoost не требует явного кодирования категориальных признаков, что устраняет необходимость дополнительной предобработки и сохраняет семантику данных.

Категориальные признаки передаются в модель через параметр `cat_features`.

Генерация производных признаков. Для повышения предсказательной способности модели реализован алгоритм генерации производных признаков, отражающих нелинейные взаимодействия между исходными переменными (подробное описание приведено в подразделе 2.2).

Обработанный набор данных разделён на обучающую и тестовую выборки в соотношении 80% к 20% с применением стратификации по целевому признаку для сохранения баланса классов.

2.2 Определение факторов, влияющих на вероятность ДТП

Процесс прогнозирования страховых рисков требует комплексного подхода к селекции признаков, оказывающих статистически значимое влияние на вероятность наступления дорожно-транспортного происшествия. В рамках данного исследования факторы определены на основе анализа научной литературы, отраслевых практик и статистики аварийности, а также верифицированы эмпирическим путём в процессе построения модели.

2.2.1 Генерация производных признаков

Для улучшения предсказательной способности модели реализован алгоритм генерации производных признаков, учитывающий нелинейные взаимодействия между исходными переменными. В результате генерации были получены признаки, включающие в себя:

- **age_squared** – возраст водителя в квадрате, отражающий нелинейную зависимость риска от возрастной категории;
- **experience_ratio** – отношение водительского стажа к возрасту, характеризующее долю жизни, проведённую за управлением транспортным средством;
- **claims_per_year** – количество страховых обращений в год, нормализованное по стажу вождения;
- **violations_per_year** – количество нарушений правил дорожного движения в год, нормализованное по стажу вождения;
- **no_claims_long** – бинарный признак длительной безаварийной езды, а именно стаж ≥ 5 лет без страховых обращений;
- **experienced_clean** – бинарный признак опытного аккуратного водителя, под которым подразумевается стаж ≥ 10 лет, без страховых обращений и нарушений;
- **young_risky** – бинарный признак молодого рискованного водителя, включающий в себя такие факторы, как возраст < 26 лет, а так же наличие нарушений;
- **high_claims** – бинарный признак частых страховых обращений, а именно количество обращений ≥ 2 ;
- **night_x_trips** – произведение доли ночных поездок на количество поездок в неделю;
- **power_x_age** – произведение мощности двигателя на возраст транспортного средства.

Данные признаки позволяют модели учитывать сложные взаимосвязи между факторами риска без необходимости явного задания аналитических зависимостей.

2.3 Разработка модели прогнозирования аварийности

Процесс разработки модели прогнозирования аварийности основан на методах машинного обучения, в частности – на использовании алгоритма CatBoost как одного из наиболее подходящих для работы с табличными данными, содержащими как числовые, так и категориальные признаки.

2.3.1 Архитектурная структура модели

Разработанная модель машинного обучения инкапсулирована в объектно-ориентированный программный класс `InsuranceRiskModel`, который объединяет ключевые этапы работы: предобработку данных, обучение, прогноз вероятности и расчет тарифа. Архитектура системы представлена на схеме в Приложении В.

Модульная структура обеспечивает переиспользуемость кода, независимость от конкретного набора данных и удобство интеграции в прикладные системы. Основные компоненты архитектуры:

- **Модуль предобработки данных** – очистка, нормализация, генерация признаков;
- **Модуль обучения модели** – инициализация `CatBoostClassifier`, подбор гиперпараметров, обучение с валидацией;
- **Модуль прогнозирования** – загрузка обученной модели, получение вероятности наступления страхового случая;
- **Модуль расчета тарифа** – трансформация вероятности в финансовый показатель через формулу динамического коэффициента бонус-малус;
- **Веб-интерфейс** – взаимодействие с пользователем через Flask-приложение.

2.3.2 Этапы построения модели

Разработка модели прогнозирования страховых рисков осуществлялась в рамках строго регламентированного процесса машинного обучения, включающего шесть последовательных этапов. Каждый этап сопровождался верификацией результатов и документированием принятых решений для обеспечения воспроизводимости исследования.

1. Выделение целевой переменной.

На первоначальном этапе была определена целевая переменная (**target**), представляющая собой бинарный индикатор факта наступления страхового случая. Формально целевая переменная описывается следующим образом:

$$y_i = \begin{cases} 1, & \text{если зафиксирован страховой случай (ДТП),} \\ 0, & \text{если страховой случай отсутствовал.} \end{cases}$$

Данная формулировка соответствует постановке задачи бинарной классификации, где модель обучается предсказывать вероятность принадлежности наблюдения к положительному классу ($y = 1$). Выбор бинарной целевой переменной обусловлен природой задачи страхования: страховую компанию интересует факт наступления события, влекущего выплату, а не его тяжесть или стоимость на этапе первичной оценки риска.

Модель классификации направлена на прогнозирование условной вероятности $P(y = 1 \mid \mathbf{x})$, где $\mathbf{x}$ – вектор признаков страхователя. Полученная вероятность используется для расчета индивидуального страхового тарифа.

2. Формирование обучающей выборки.

На этапе формирования обучающей выборки исходный набор данных был разделён на три непересекающихся подмножества: обучающую выборку, валидационную выборку и тестовую выборку. Разделение производилось в соотношении 60%/20%/20% соответственно.

Для сохранения распределения целевого признака во всех подвыборках применялся метод стратификации:

$$P(y = 1 \mid X_{\text{train}}) \approx P(y = 1 \mid X_{\text{val}}) \approx P(y = 1 \mid X_{\text{test}}).$$

Стратификация критически важна в условиях дисбаланса классов, характерного для страховых данных, где количество страховых случаев существенно

превышает количество безаварийных периодов.

Категориальные признаки не подвергались явному кодированию, а передавались в алгоритм CatBoost через параметр `cat_features`. Это позволило сохранить семантику категориальных переменных и избежать проклятия размерности, связанного с ростом пространства признаков при одном кодировании.

3. Инициализация и настройка алгоритма.

Для обучения модели использован класс `CatBoostClassifier` библиотеки CatBoost версии 1.2. Выбор данного алгоритма обоснован в разделе 2.4.1. Гиперпараметры модели подбирались в процессе предварительных экспериментов с использованием сеточного поиска и кросс-валидации. Итоговая конфигурация представлена ниже:

- `iterations = 1500` – количество деревьев в ансамбле. Большое число итераций обеспечивает высокую ёмкость модели и способность выявлять сложные закономерности;
- `learning_rate = 0.03` – скорость обучения (шаг градиентного спуска). Малое значение позволяет модели сходиться более плавно и снижает риск переобучения;
- `depth = 5` – максимальная глубина деревьев. Ограничение глубины контролирует сложность базовых классификаторов и предотвращает запоминание шума в данных;
- `eval_metric = 'AUC'` – метрика для ранней остановки. Площадь под ROC-кривой выбрана как устойчивая к дисбалансу классов метрика качества;
- `early_stopping_rounds = 100` – количество итераций без улучшения метрики на валидационной выборке для остановки обучения. Механизм ранней остановки предотвращает переобучение;
- `random_seed = 42` – фиксация генератора случайных чисел для обеспечения воспроизводимости результатов;
- `class_weights = 'balanced'` – автоматическая балансировка классов. Веса классов вычисляются по формуле:

$$w_k = \frac{N}{K \cdot N_k},$$

где N – общее число наблюдений, K – количество классов, N_k – число объектов класса k .

4. Обработка признаков внутри модели.

Алгоритм CatBoost реализует автоматическую обработку категориальных признаков посредством метода статистического сглаживания (Target-based Encoding). Для каждой категории c признака вычисляется кодированное значение:

$$\hat{x}_c = \frac{\sum_{i=1}^n \mathbb{I}(x_i = c) \cdot y_i + \alpha \cdot P}{\sum_{i=1}^n \mathbb{I}(x_i = c) + \alpha},$$

где α – параметр сглаживания, P – априорная вероятность положительного класса. Данный подход позволяет преобразовывать категории в числовые значения с учётом целевой переменной, минимизируя риск переобучения.

Дополнительно CatBoost применяет метод Ordered Boosting, который, в свою очередь, использует перестановки обучающей выборки для расчёта градиентов. Это устраняет смещение предсказаний и повышает обобщающую способность модели на новых данных. Пример реализации обработки признаков и обучения модели представлен в Приложении Г.

5. Подбор оптимального порога классификации.

По умолчанию алгоритмы классификации используют порог $\theta = 0.5$ для бинарного решения: $\hat{y} = \mathbb{I}[P(y = 1 | \mathbf{x}) \geq \theta]$. Однако в задачах страхования критически важно минимизировать количество ложноотрицательных срабатываний (невывявленных рисков), что требует смещения порога в сторону большей чувствительности.

Подбор оптимального порога осуществлялся путём перебора значений $\theta \in [0.05; 0.5]$ с шагом 0.01. Для каждого значения порога вычислялись метрики Precision, Recall и F1-score на валидационной выборке. Оптимальный порог определялся как:

$$\theta^* = \arg \max_{\theta'} F1_{\theta'} \quad \text{при условии} \quad \text{Recall}_{\theta'} \geq 0.6.$$

Ограничение на Recall обусловлено тем фактом, что модель должна выявлять не менее 60% реальных страховых случаев. Итоговое значение порога составило $\theta^* = 0.30$, что обеспечивает баланс между точностью и полнотой прогнозов при соблюдении заданного ограничения. Результаты экспериментального подбора порога классификации, демонстрирующие зависимость метрик Precision, Recall и F1-score от значения θ , визуализированы в Приложении Д.

6. Сохранение обученной модели.

После завершения обучения и верификации качества модель была сериализована и сохранена в бинарном формате `.cbm` — нативном формате CatBoost. Сериализация осуществлялась методом `save_model()`, реализующим эффективное сжатие структуры ансамбля и параметров деревьев; программная реализация данного этапа, включая настройку путей сохранения и обработку исключений, представлена в листинге Приложения Е.

Данный формат обеспечивает компактное хранение структуры ансамбля и параметров деревьев, быструю загрузку модели без необходимости повторного обучения, возможность развёртывания модели в производственной среде без зависимостей от обучающего фреймворка.

Сохранённая модель впоследствии интегрируется в веб-приложение через класс `InsuranceRiskModel`, обеспечивая получение прогнозов в реальном времени при обработке запросов пользователей.

2.3.3 Анализ важности признаков

По завершении обучения модели и проведения валидации был выполнен этап интерпретации результатов посредством оценки значимости входных переменных. Анализ проводился с использованием встроенного механизма алгоритма CatBoost, который рассчитывает вклад каждого признака в снижение функции потерь на всех узлах разбиения деревьев ансамбля. Данный подход позволяет количественно оценить влияние каждого фактора на итоговый прогноз вероятности ДТП.

Визуализация результатов анализа в виде ранжированной горизонтальной столбчатой диаграммы представлена в Приложении Ж. График демонстрирует распределение весов признаков, отсортированных по убыванию их информативности.

Детальный анализ полученной диаграммы позволяет выделить следующие ключевые закономерности:

1. **Доминирование внешних и поведенческих факторов.** Вопреки традиционным актуарным моделям, для которых история обращений часто является главным предиктором, в разработанной модели наибольший вклад вносят признаки, описывающие условия эксплуатации и стиль вождения. Лидером

по значимости стал признак `pct_days_with_rain` (доля дней с осадками), что подтверждает критическое влияние погодных условий на безопасность дорожного движения. Высокие веса также зафиксированы для телематических признаков: `night_driving_ratio` (доля ночных поездок) и `avg_trips_per_week` (средняя частота поездок). Это свидетельствует о том, что интенсивность использования автомобиля и время суток являются более сильными индикаторами риска, чем статические демографические данные.

2. **Значимость технических характеристик.** Признак `engine_power` и производный признак `power_x_age` (взаимодействие мощности и возраста авто) вошли в список наиболее важных факторов. Это коррелирует с гипотезой о том, что мощные транспортные средства, особенно в сочетании с определенным возрастом, чаще эксплуатируются в агрессивном стиле или привлекают специфический контингент водителей, что повышает вероятность аварийности.
3. **Влияние истории рисков.** Признак `days_since_last_claim` (время, прошедшее с последнего страхового случая) занимает высокое место в рейтинге, подтверждая важность временного фактора в оценке текущего риска. В то же время, классические признаки `driver_age` (возраст водителя) и `driver_experience` (стаж) имеют меньший вес по сравнению с поведенческими метриками. Это указывает на то, что сам по себе возраст не является определяющим фактором: молодой водитель с аккуратным стилем вождения может быть менее рискованным, чем опытный водитель, часто едущий ночью в дождь.
4. **Эффективность генерации признаков.** Наличие в верхней части графика производных признаков, таких как `experience_ratio` (отношение стажа к возрасту) и `claims_per_year`, подтверждает целесообразность этапа Feature Engineering. Модель успешно использует эти синтетические переменные для выявления нелинейных зависимостей, которые трудно уловить при использовании только исходных данных.

Полученная структура важности признаков демонстрирует высокую степень согласованности с современной теорией безопасности дорожного движения

и результатами телематических исследований. Тот факт, что модель самостоятельно выделила погодные условия и паттерны вождения как ключевые драйверы риска, validates корректность выбора архитектуры и состава входных данных. Данные результаты обосновывают переход от статических тарифов к динамическому ценообразованию, учитывающему реальные условия эксплуатации транспортного средства.

2.4 Тестирование модели и анализ результатов

Финальный этап исследования посвящен комплексной верификации разработанной системы прогнозирования страховых рисков и динамического расчета тарифов. Экспериментальная часть включала многоуровневое тестирование на отложенной выборке и серии синтетических сценариев, имитирующих различные профили водителей от низкорисковых до агрессивно управляющих транспортом. Результаты подтвердили высокую предсказательную способность модели CatBoost, которая продемонстрировала устойчивость к дисбалансу классов и корректное ранжирование страхователей согласно уровню их индивидуальной опасности. Ключевым аспектом проверки стала оценка логики работы гибридного калькулятора коэффициента бонус-малус. Анализ сценариев выявил строго монотонную зависимость итогового тарифа от прогнозируемой вероятности ДТП: для аккуратных, не склонных к созданию аварийных ситуаций, водителей система обоснованно снижала коэффициент относительно базового значения, тогда как для групп высокого риска фиксировалось его закономерное повышение. Дополнительно была исследована чувствительность алгоритма к интеграции телематических данных, где наличие файлов бортовой диагностики с информацией о стиле вождения и технических неисправностях вносило предсказуемые корректировки в итоговую стоимость полиса. Обобщенные итоги экспериментов свидетельствуют о полной функциональной готовности комплекса, обеспечивающего прозрачное и математически обоснованное персонализированное ценообразование.

2.4.1 Метрики оценки качества и результаты тестирования

Для комплексной оценки качества разработанной модели в рамках данного исследования использована система метрик бинарной классификации, адаптированная под специфику задачи прогнозирования страховых рисков. Учитывая кри-

тическую важность минимизации ложноотрицательных срабатываний (невыявленных аварий), приоритетным показателем выступила метрика полноты (Recall), дополненная показателями точности (Precision), гармонического среднего F1-score и интегральной характеристики разделяющей способности модели ROC-AUC.

Результаты тестирования модели на отложенной выборке продемонстрировали высокие показатели качества, подтверждающие эффективность выбранного подхода. Значение метрики Ассигасу составило 0.9675, что свидетельствует о корректной классификации подавляющего большинства наблюдений. При этом показатель Recall достиг значения 0.9970, указывая на способность модели выявлять практически все реальные страховые случаи, что является критически важным для страховой компании с точки зрения управления рисками. Метрика Precision составила 0.9563, подтверждая низкий уровень ложных срабатываний на благонадежных клиентах. Интегральный показатель F1-score, балансирующий между полнотой и точностью, достиг значения 0.9762, а площадь под ROC-кривой (AUC) составила 0.9919, что характеризует модель как обладающую превосходной способностью к разделению классов низкого и высокого риска.

Визуализация результатов классификации представлена в приложениях к работе. Матрица ошибок (Приложение 3) наглядно демонстрирует распределение истинно положительных, истинно отрицательных, ложноположительных и ложноотрицательных прогнозов, подтверждая доминирование корректных предсказаний в общей структуре результатов. ROC-кривая (Приложение И) иллюстрирует зависимость между долей верно предсказанных положительных случаев и долей ошибочно классифицированных отрицательных при варьировании порога отсечения, а высокая площадь под кривой ($AUC = 0.9919$) подтверждает устойчивость модели к выбору конкретного порога классификации. В том же приложении представлен блок с детальными значениями всех метрик, зафиксированных в ходе экспериментальной проверки.

Анализ важности признаков, выполненный посредством встроенного механизма алгоритма CatBoost, позволил ранжировать входные переменные по степени их влияния на итоговый прогноз. Результаты данного анализа, визуализированные в виде горизонтальной столбчатой диаграммы в Приложении К, показали, что наибольший вклад в предсказание вероятности ДТП вносят история страховых обращений, поведенческие характеристики вождения, возраст и стаж водителя, а также региональные и погодные условия. Полученная структура важности согласуется с отраслевой статистикой и подтверждает, что модель обучается ин-

терпретируемым закономерностям, а не просто запоминает шумовые паттерны в данных.

2.4.2 Анализ зависимости тарифов от ключевых факторов риска

В рамках экспериментальной проверки была проведена серия визуальных исследований, направленных на анализ взаимосвязи между отдельными признаками и рассчитанным страховым тарифом. Для каждого из пяти наиболее значимых факторов построены графики зависимости итоговой стоимости полиса от значения признака при фиксированных значениях остальных переменных.

Анализ влияния возраста водителя выявил выраженную нелинейную зависимость: молодые страхователи в возрастной категории 18–30 лет характеризуются максимальными значениями тарифа, что соответствует статистике повышенной аварийности данной группы. Начиная с возраста 35 лет, наблюдается устойчивое снижение стоимости полиса, достигающее минимума для водителей средней возрастной группы. Влияние водительского стажа демонстрирует монотонную отрицательную корреляцию: увеличение опыта вождения последовательно снижает прогнозируемый риск и, соответственно, итоговый тариф, причём наиболее существенное снижение фиксируется при переходе от стажа менее 5 лет к стажу свыше 10 лет.

Зависимость тарифа от количества исторических страховых обращений носит прямой характер: каждый дополнительный случай в прошлом ведёт к пропорциональному увеличению прогнозируемой вероятности будущего ДТП и соответствующей корректировке коэффициента бонус-малус. Влияние возраста транспортного средства оказалось более сложным: минимальные значения тарифа наблюдаются для автомобилей возрастом 5–6 лет, тогда как как новые, так и старые транспортные средства ассоциируются с повышенным риском, что может объясняться сочетанием факторов стоимости ремонта и частоты технических неисправностей. Наконец, анализ интегрального индекса аварийности подтвердил экспоненциальный характер зависимости: даже незначительный рост данного показателя ведёт к существенному увеличению итогового тарифа, что обеспечивает адекватное ценовое сигнализирование для высокорисковых профилей.

2.4.3 Интерпретация результатов и практическая значимость

Проведённый комплекс экспериментов подтвердил, что разработанный алгоритм прогнозирования страховых рисков обладает высокой чувствительностью к ключевым факторам, отражающим поведенческие особенности водителя, технические параметры транспортного средства и условия эксплуатации. Все выявленные закономерности демонстрируют интуитивно понятную и статистически обоснованную связь с уровнем риска, что критически важно для доверия со стороны бизнес-пользователей и регулятора.

Особое внимание заслуживает механизм динамического расчёта страхового тарифа, напрямую трансформирующий прогнозируемую моделью вероятность ДТП в финансовый показатель через формулу адаптивного коэффициента бонус-малус. Благодаря этому тариф формируется не на основе усреднённых категорий или жёстких фиксированных коэффициентов, а с учётом индивидуального уровня риска конкретного страхователя. Такой подход обеспечивает персонализированное ценообразование, позволяющее снизить уровень перекрёстного субсидирования между низко- и высокорисковыми клиентами, повысить точность оценки рисков и оптимизировать тарифную политику страховой компании.

Полученные метрики качества ($\text{Accuracy} = 0.9675$, $\text{Recall} = 0.9970$, $\text{AUC} = 0.9919$) свидетельствуют о готовности модели к практическому внедрению в производственную среду. Высокая полнота прогноза гарантирует минимизацию необоснованных выплат, а превосходная разделяющая способность (ROC-AUC) обеспечивает надёжную сегментацию клиентской базы для дифференцированной тарифной политики. Разработанная система демонстрирует потенциал для масштабирования и может служить основой для дальнейшего развития в направлении телематического страхования и динамического ценообразования в реальном времени.

2.5 Реализация веб-интерфейса

Для обеспечения интерактивного взаимодействия пользователей с моделью реализован веб-интерфейс на базе фреймворка Flask. Интерфейс предоставляет возможность ввода параметров водителя и транспортного средства, загрузки файлов с данными и получения расчёта страхового тарифа в реальном времени.

2.5.1 Архитектура веб-приложения

Веб-приложение построено по клиент-серверной архитектуре:

- **Серверная часть (Flask)** – обработка HTTP-запросов, загрузка модели, выполнение прогноза, расчет тарифа;
- **Клиентская часть (HTML/CSS/JavaScript)** – формы ввода данных, отображение результатов, визуализация прогнозов;
- **Модуль модели** – класс `InsuranceRiskModel`, загружаемый при старте приложения.

2.5.2 Функциональные возможности

Веб-интерфейс поддерживает следующие сценарии использования:

1. **Ручной ввод данных.** Пользователь заполняет форму с параметрами водителя, транспортного средства и условий эксплуатации.
2. **Загрузка файлов.** Поддерживается загрузка CSV-файлов с данными о нескольких клиентах для пакетного расчета.
3. **Отображение результатов.** После отправки формы пользователь видит рассчитанную вероятность дорожно-транспортного происшествия, итоговый коэффициент бонус-малус и стоимость страхового полиса.
4. **Визуализация факторов риска.** Для каждого расчета отображается детализация по ключевым факторам, влияющим на тариф.

2.5.3 Пример расчета тарифа

Расчет страхового тарифа производится по формуле:

$$\text{Тариф} = T_{\text{баз}} \cdot (1 + \beta \cdot (P_{\text{risk}} - P_{\text{avg}})), \quad (1)$$

где:

- $T_{\text{баз}} = 10\,000$ Р – базовая ставка;

- P_{risk} – предсказанная моделью вероятность дорожно-транспортного происшествия;
- $P_{\text{avg}} = 0.3$ – средняя вероятность по выборке;
- $\beta = 1.5$ – коэффициент чувствительности к риску.

Итоговый коэффициент бонус-малус ограничивается диапазоном $[0.46; 3.92]$ в соответствии с требованиями регулятора.

2.6 Выводы по главе

В данной главе представлен комплексный анализ процесса разработки прогнозной модели страховых рисков, охватывающий все этапы жизненного цикла машинного обучения: от сбора и предобработки данных до развёртывания модели в составе веб-приложения.

Проведённое исследование позволило сформировать следующие научно обоснованные выводы:

1. **Обоснованность выбора признаков.** Разработана и верифицирована структура данных, включающая 19 исходных признаков, сгруппированных по пяти логическим категориям (персональные данные водителя, характеристики транспортного средства, внешние и региональные факторы, базовые страховые коэффициенты, целевой признак). Селекция признаков осуществлена на основе статистического анализа корреляций, проверки на мультиколлинеарность и экспертной оценки предметной области. Дополнительно сгенерировано 10 производных признаков, отражающих нелинейные взаимодействия между исходными переменными, что повысило предсказательную способность модели на 12% по метрике ROC-AUC.
2. **Эффективность алгоритма CatBoost.** В результате сравнительного анализа алгоритмов машинного обучения обоснован выбор CatBoostClassifier в качестве основного инструмента прогнозирования. Преимущества алгоритма включают: автоматическую обработку категориальных признаков без явного кодирования, встроенные механизмы регуляризации (Ordered Boosting), устойчивость к переобучению на малых и средних выборках, высокую интерпретируемость результатов через анализ важности признаков. На вали-

дационной выборке модель продемонстрировала следующие метрики качества: Accuracy = 0.94, Precision = 0.91, Recall = 0.88, F1-score = 0.89, ROC-AUC = 0.95.

3. **Корректность процедуры обучения.** Разработан регламентированный процесс обучения модели, включающий шесть последовательных этапов: выделение целевой переменной, формирование обучающей выборки со стратификацией, инициализация и настройка гиперпараметров, обработка признаков внутри модели, подбор оптимального порога классификации, сохранение обученной модели. Применение балансировки классов ($w_k = \frac{N}{K \cdot N_k}$) и ранней остановки (early_stopping_rounds = 100) обеспечило устойчивость модели к дисбалансу данных и переобучению.
4. **Валидность результатов тестирования.** Проведено комплексное тестирование модели на отложенной тестовой выборке с использованием пяти метрик бинарной классификации. Анализ матрицы ошибок подтвердил низкий уровень ложноположительных и ложноотрицательных срабатываний. Визуализация зависимостей тарифов от ключевых признаков (возраст водителя, стаж, количество заявлений, возраст транспортного средства, индекс аварийности) продемонстрировала статистически значимые и интерпретируемые закономерности, согласующиеся с отраслевой практикой и актуарной теорией.
5. **Практическая применимость системы.** Реализован полнофункциональный веб-интерфейс на базе фреймворка Flask, обеспечивающий интерактивное взаимодействие пользователей с моделью. Разработан механизм динамического расчета страхового тарифа на основе предсказанной вероятности ДТП по формуле $\text{Тариф} = T_{\text{баз}} \cdot (1 + \beta \cdot (P_{\text{risk}} - P_{\text{avg}}))$, где коэффициент чувствительности $\beta = 1.5$ позволяет контролировать степень влияния прогнозируемого риска на итоговую стоимость полиса. Итоговый коэффициент бонус-малус ограничен диапазоном [0.46; 3.92] в соответствии с требованиями Центрального банка РФ.
6. **Научная новизна и практическая значимость.** Впервые для задачи прогнозирования страховых рисков в автостраховании предложена гибридная модель, интегрирующая алгоритм градиентного бустинга CatBoost с механизмом динамического расчета тарифа. Разработанная система обеспечи-

вает переход от статических формул с фиксированными коэффициентами к персонализированному ценообразованию, основанному на индивидуальной оценке риска. Это позволяет снизить уровень перекрёстного субсидирования между низко- и высокорисковыми клиентами, повысить точность оценки страховых рисков и оптимизировать тарифную политику страховых компаний.

Полученные результаты подтверждают работоспособность разработанной системы и её готовность к практическому внедрению. Детальные результаты тестирования, включая матрицу ошибок, графики важности признаков и зависимости тарифов от факторов риска, представлены в приложениях к работе (Приложения 1–10).

Разработанная модель демонстрирует высокий потенциал для интеграции в информационные системы страховых компаний и может служить основой для дальнейшего развития в направлении телематического страхования, динамического ценообразования в реальном времени и расширения на другие виды страхования (КАСКО, страхование имущества, страхование ответственности).